

# Introdução ao *Machine Learning*

**Prof. Dr. Diego Bruno**

Education Tech Lead na DIO

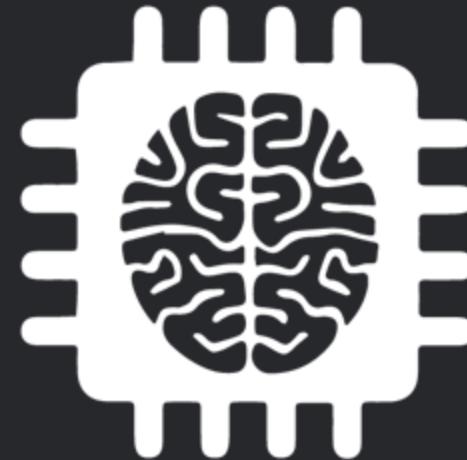
Doutor em Robótica e *Machine Learning* pelo ICMC-USP



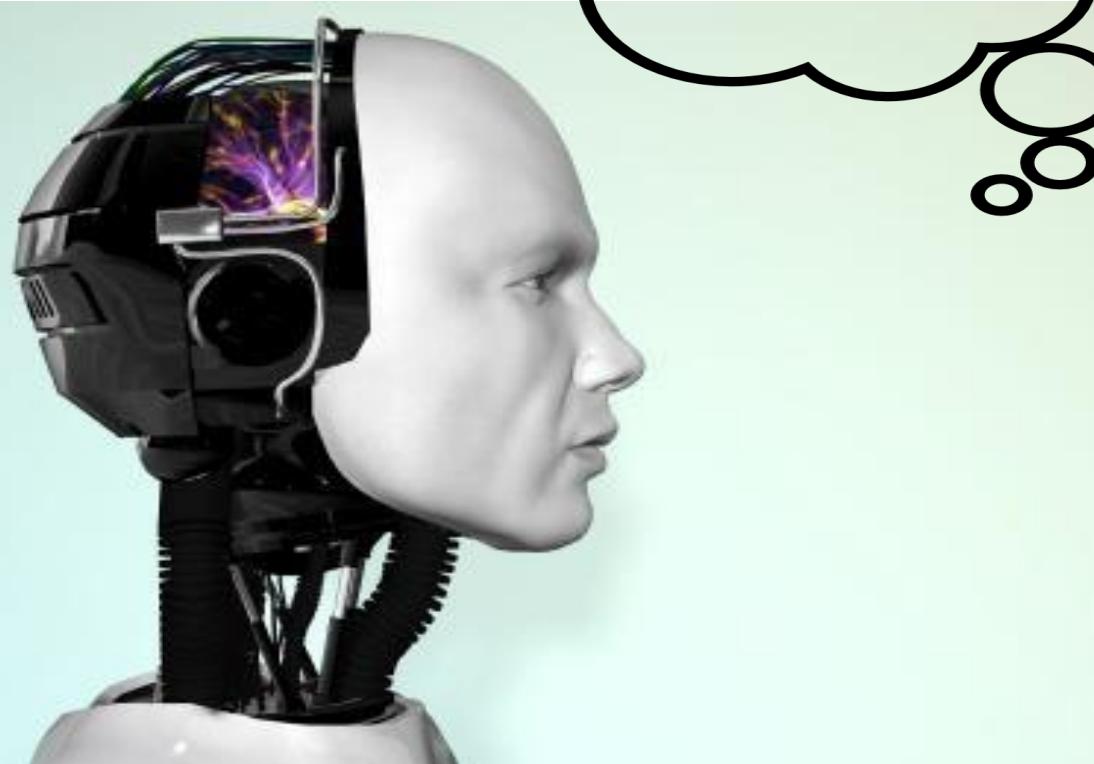
# Machine Learning

**Machine Learning**

Prof. Dr. Diego Bruno



# Máquinas que pensam como humanos



- Treinamento de sistemas de **Inteligência Artificial**;
- Tomada de decisão com suporte de **base de regras** bem definidas;
- Não toma decisão com base na emoção;
- Automação para correção e suporte de falhas humanas.

# Como a IA é vista hoje?

IA Geral

IA Restrita

Aprendizado de Máquina



*Steven Spielberg*

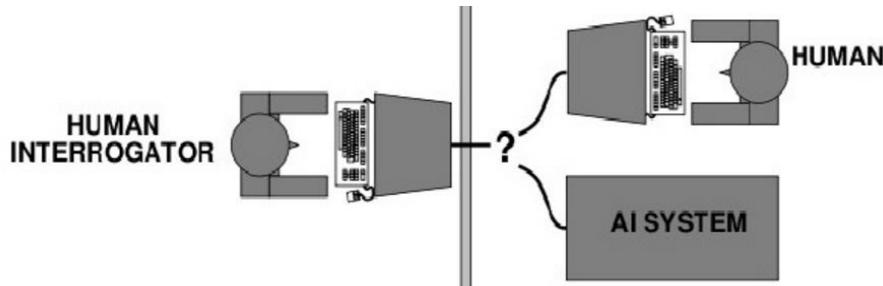
# Ficção Científica



# Ex Machina

Um humano escolhido para o **teste de Turing** com uma máquina com IA:

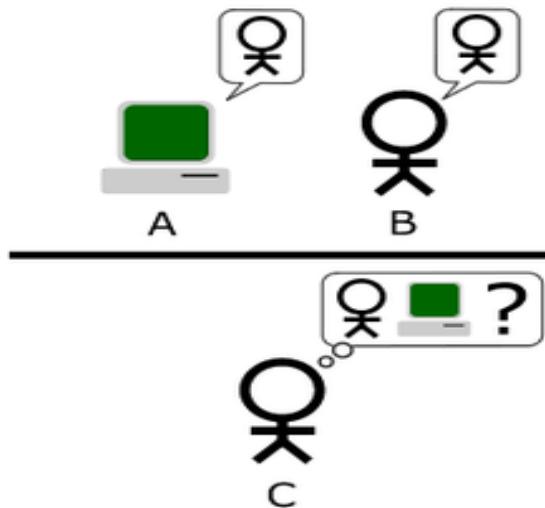
- **Baseado no jogo da imitação**



ex machina

# Ex Machina

Um humano escolhido aplicando o **teste de Turing** em uma máquina:

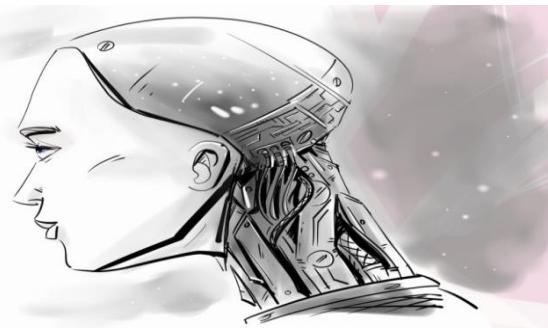


O **Teste de Turing** testa a capacidade de uma máquina exibir comportamento inteligente equivalente a um ser humano, ou indistinguível deste.

# Primeiro Robô a ter cidadania

## Interação humano-robô

- Capaz de reproduzir 62 expressões faciais
- Objetivo é conseguir uma maior aceitação da robótica no mesmo ambiente humano
- Ainda não consegue passar no teste de Turing

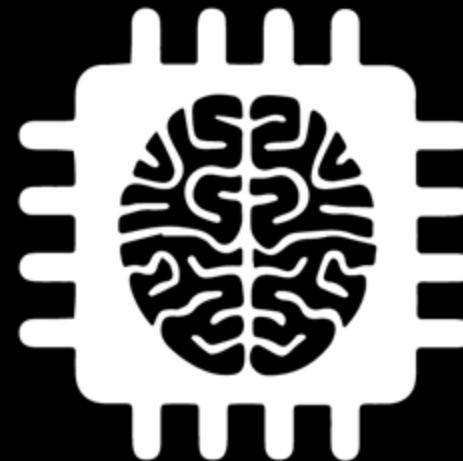


**Sophia**

A photograph of Sophia, a humanoid robot with a bald head, blue eyes, and a gentle smile. She is wearing a dark blue jacket over a patterned top. The background is a blurred indoor setting with screens and lights.

<b>Fabricante</b>	Hanson Robotics
<b>Inventor</b>	David Hanson
<b>Ano de criação</b>	2015
<b>Tipo</b>	Robô humanoide
<b>País</b>	Hong Kong, Arábia Saudita
<b>Website</b>	<a href="http://sophiabot.com">sophiabot.com</a>

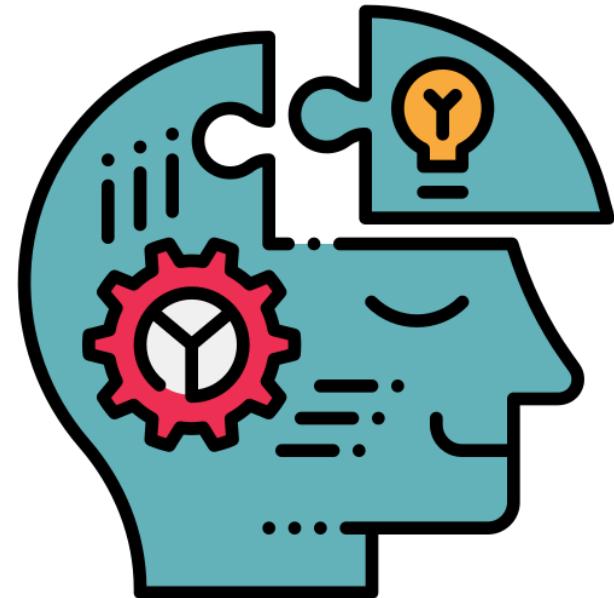
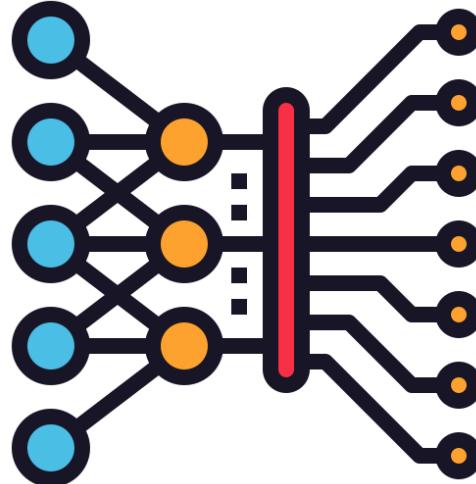
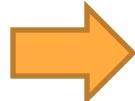
Mas qual a  
relação entre ML e  
IA?



# Mas qual a Relação entre ML e IA?

Por meio do **ML** obtemos (ou não) uma **IA** restrita.

Aprendizado de  
Máquina  
(Treinamento)



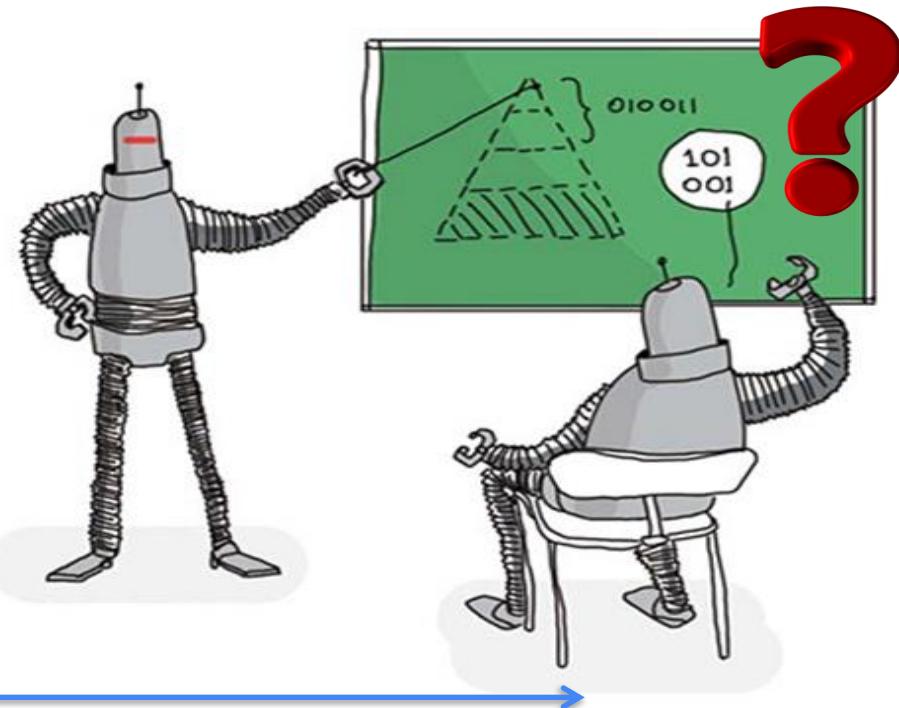
Inteligência Artificial

# Mas o que é Machine Learning?

Dependente de uma base de conhecimento...

O objetivo do aprendizado de máquina (ou "*machine learning*") é programar computadores para aprender um determinado comportamento ou padrão automaticamente a partir de exemplos ou observações.

**DATASETS**



# Inteligência Artificial Restrita

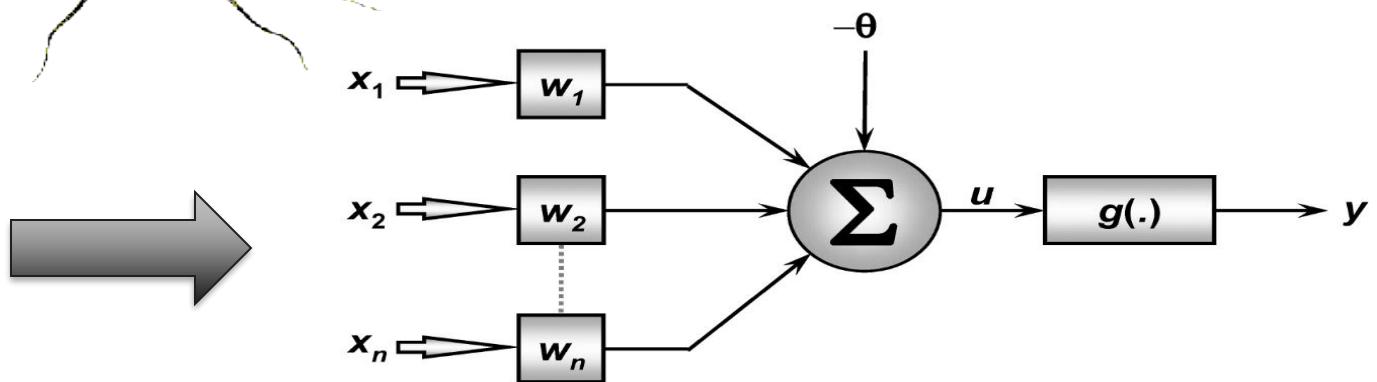
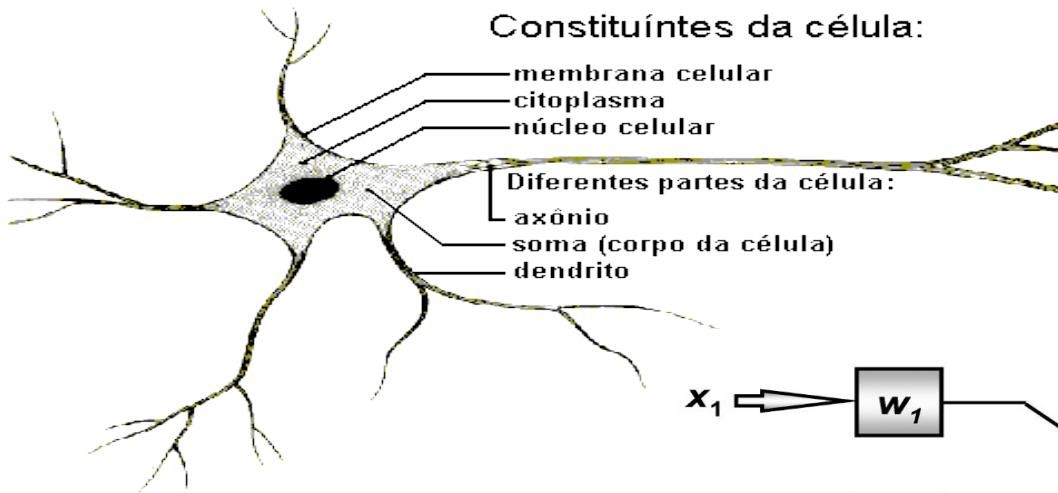


# Exemplo de Aprendizado



Aprendizado por Reforço

# Inteligência Artificial Restrita



# Aplicações em Veículos Autônomos



# Pesquisa em Veículos - ADAS



Trabalho de doutorado:  
Diego Renan Bruno



Serviço

# SMART CITY



**WAYMO**



# Trabalhos Realizados



**Laboratório de Robótica Móvel**  
ICMC/USP - São Carlos

CARINA 1



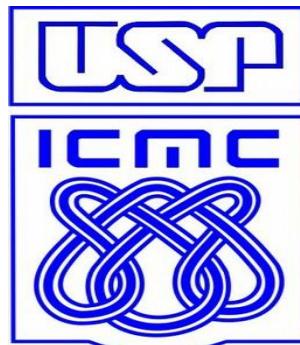
CARINA 2



# Trabalhos Realizados



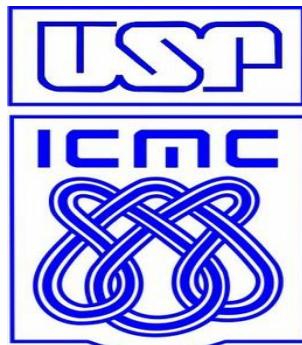
**Laboratório de Robótica Móvel**  
ICMC/USP - São Carlos



# Trabalhos Realizados



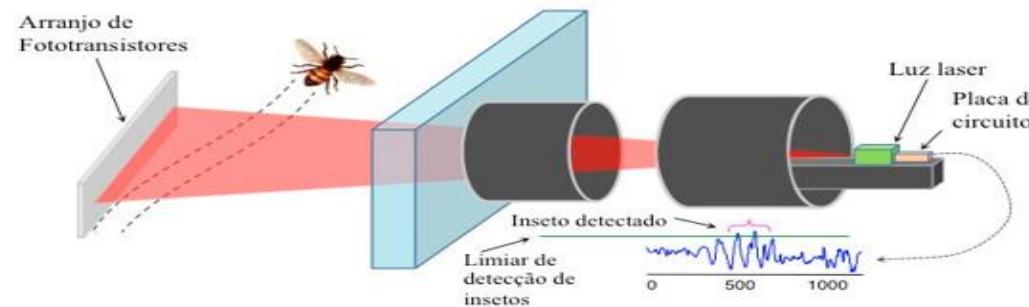
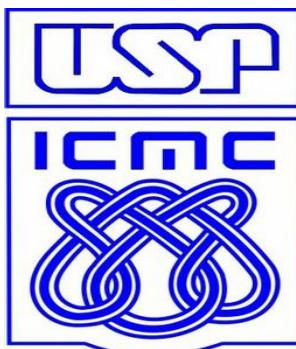
**Laboratório de Robótica Móvel**  
ICMC/USP - São Carlos



**SCANIA**



# Trabalhos Realizados

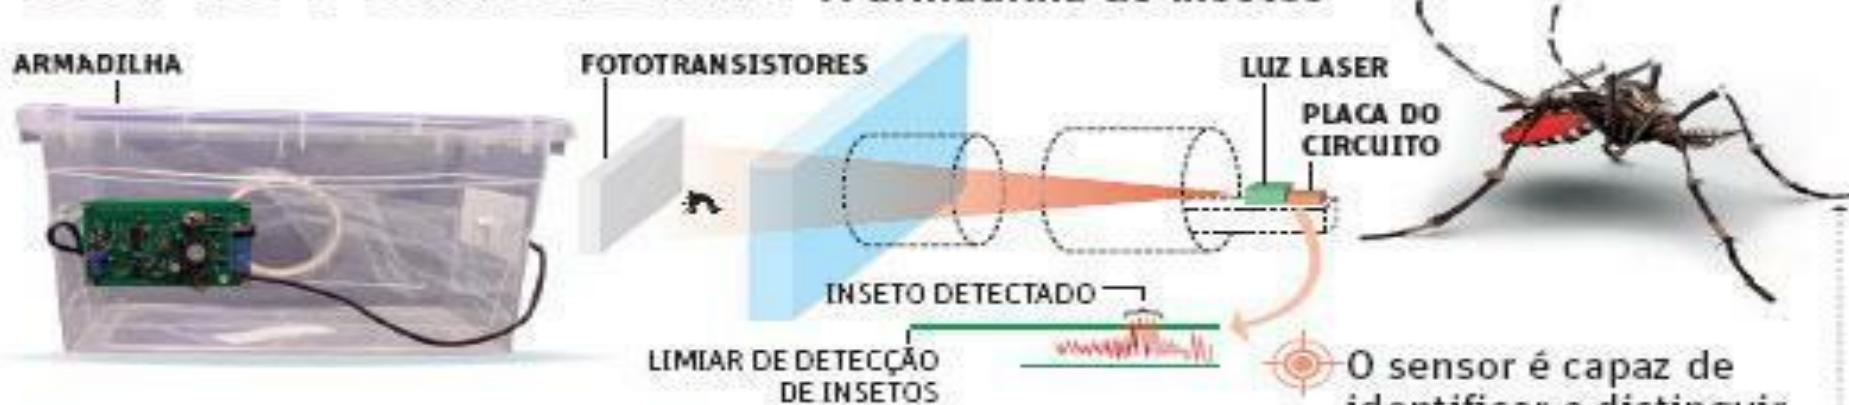


# Trabalhos Realizados

EDITORIA DE ARTE / O TEMPO

## COMO FUNCIONA

### A armadilha de insetos

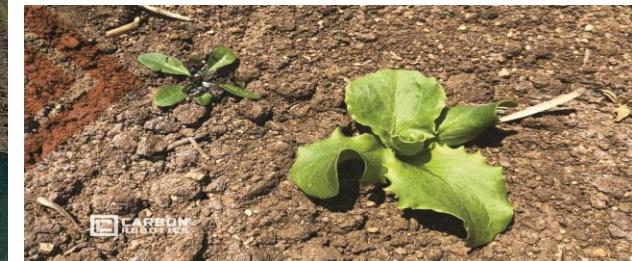


O mosquito é atraído por dióxido de carbono. Depois, ele é puxado por um fluxo de ar em direção ao sensor e lá é identificado.

A armadilha possui um dispositivo que emite uma luz a laser. Ao atravessá-la, as variações das asas do mosquito são captadas.

O sensor é capaz de identificar e distinguir até o **Aedes aegypti** macho da fêmea. Isso é importante porque são as fêmeas que transmitem doenças como zika, dengue e chikungunya.

# Trabalhos na agricultura



# Trabalhos Realizados

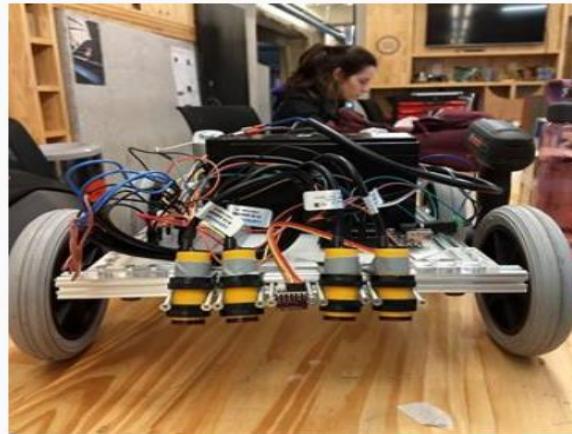


# Trabalhos Realizados



# Cão-guia Robótico V2

- *Hardware*
- *Controle*
- *Visão Computacional*



# Dataset

*Transfer Learning: Dataset de treinamento para o sistema*



150 imagens



100 imagens



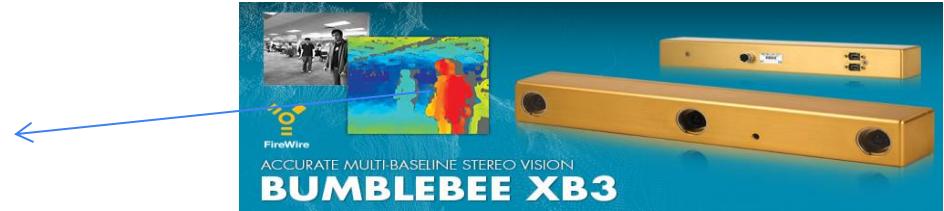
300 imagens

# Sensoriamento: Dados gerados

## Fusão de Sensores para Visão Computacional:

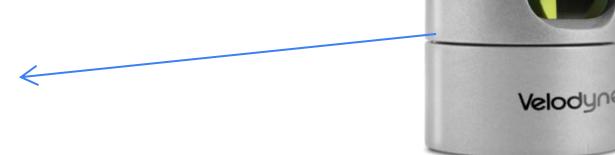
### ➤ Câmera estéreo 3D:

- Imagen 3D – (para detecção)
- Imagen 2D – (para reconhecimento)



### ➤ LIDAR - *Velodyne HDL- 32E*:

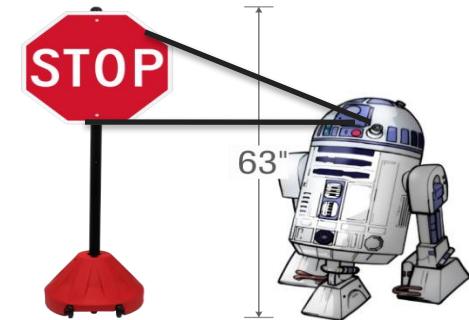
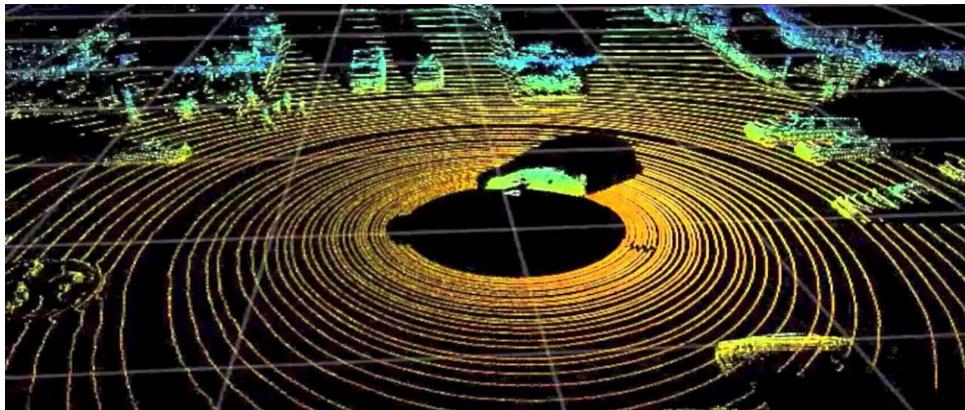
- Nuvem de pontos 3D – (para detecção)
- Fator de refletância dos objetos placas



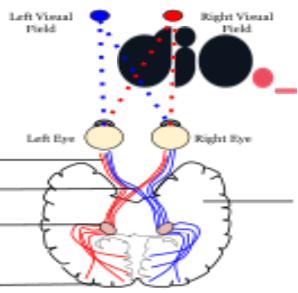
# Sensoriamento

dio.

Fusão de Sensores para Visão Computacional:



# Deep Learning - TensorFlow



## Extração de features 2D:

- CNN: Aprendem automaticamente a extrair *features* em imagens 2D

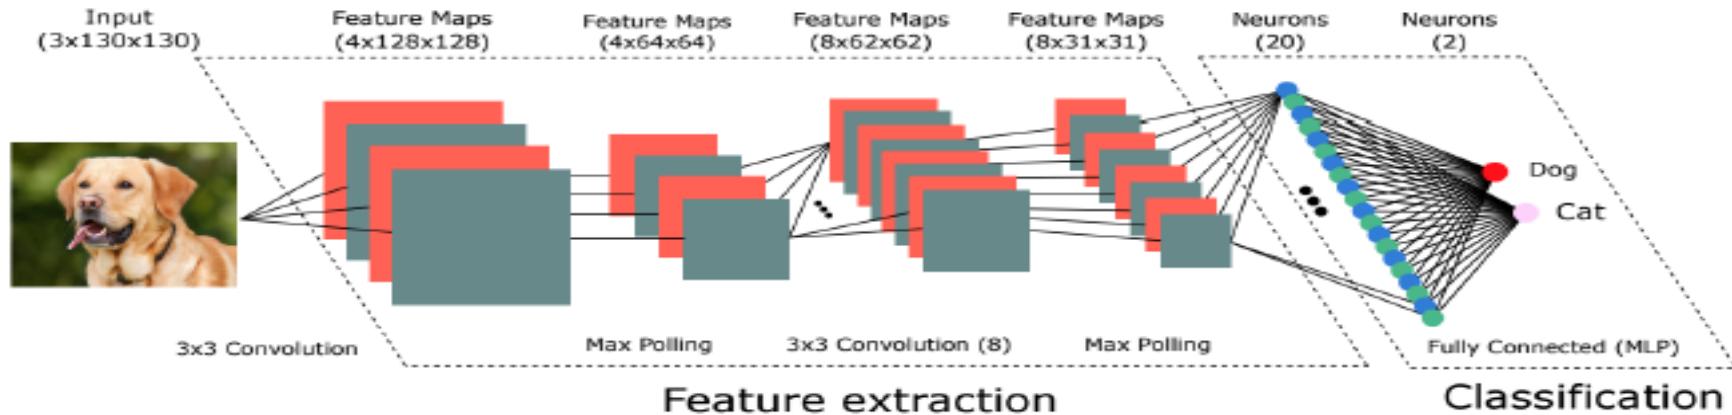
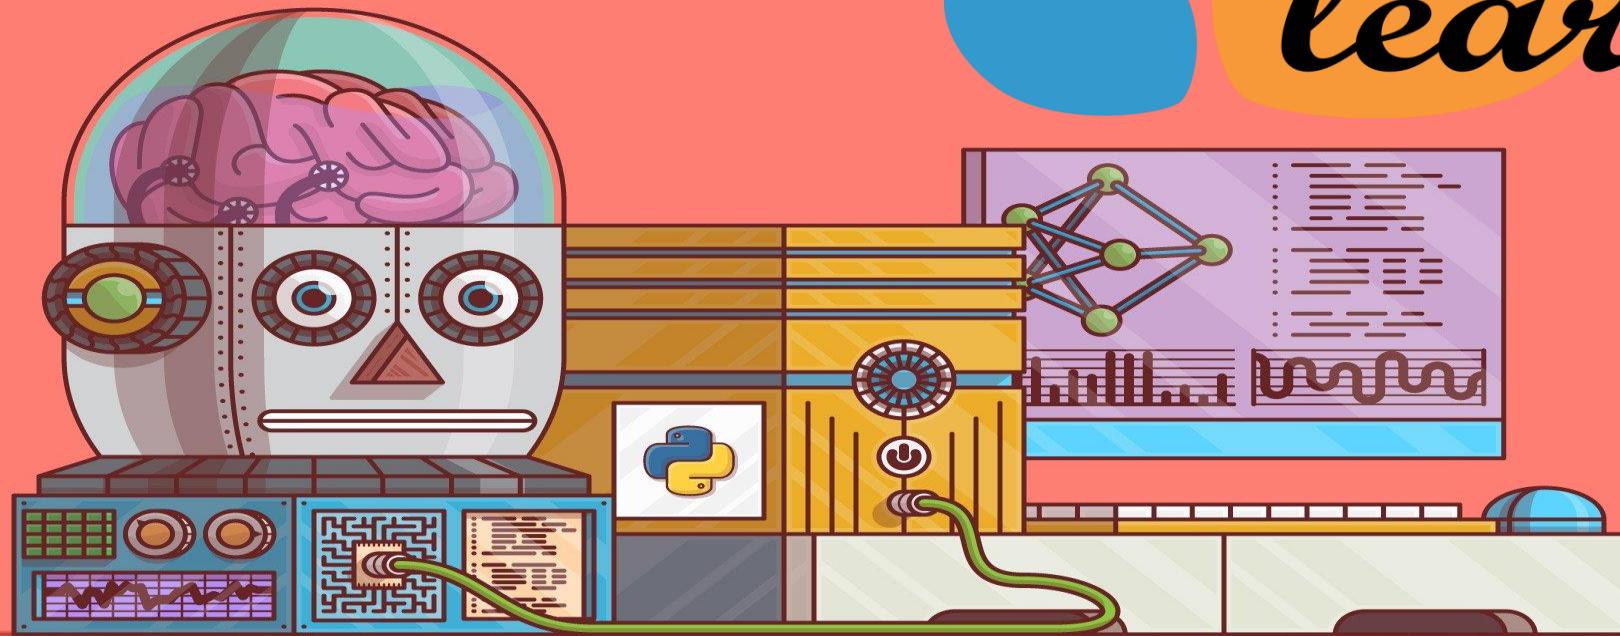


Figura 2: DCNN – [TensorFlow]

# Bibliotecas de ML

dio.



scikit  
*learn*

Real Python

# Bibliotecas de ML



In [23]:

```
# The convention is to import Pandas with abbreviaton "pd"
import pandas as pd
# Import
```

In [23]:

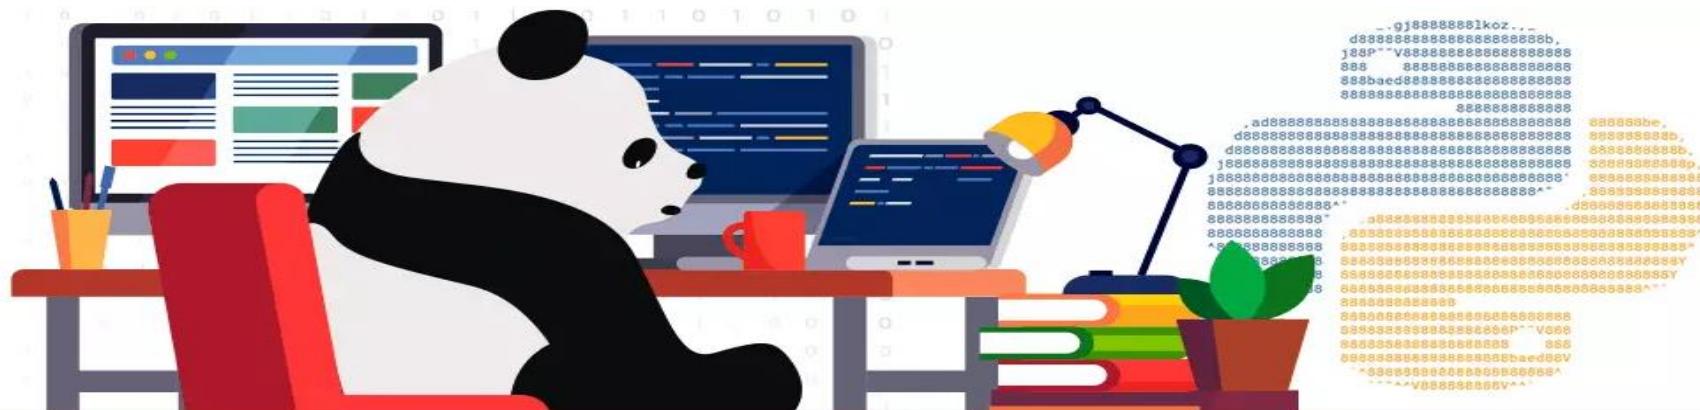
```
# You can create a database using a dictionary of lists.
# Each column is a dictionary key and the key denotes the column name.
# All the lists need to be the same length, and then become the rows.
new_database = [
    {
        "column_1": 1,
        "another_column": "Aaa",
        "string": "string",
        "binary": b"binary"
    },
    {
        "column_1": 2,
        "another_column": "Baa",
        "string": "string",
        "binary": b"binary"
    }
]
```

In [23]:

```
# you can look at the new_dataframe
another_column
```

Out[23]:

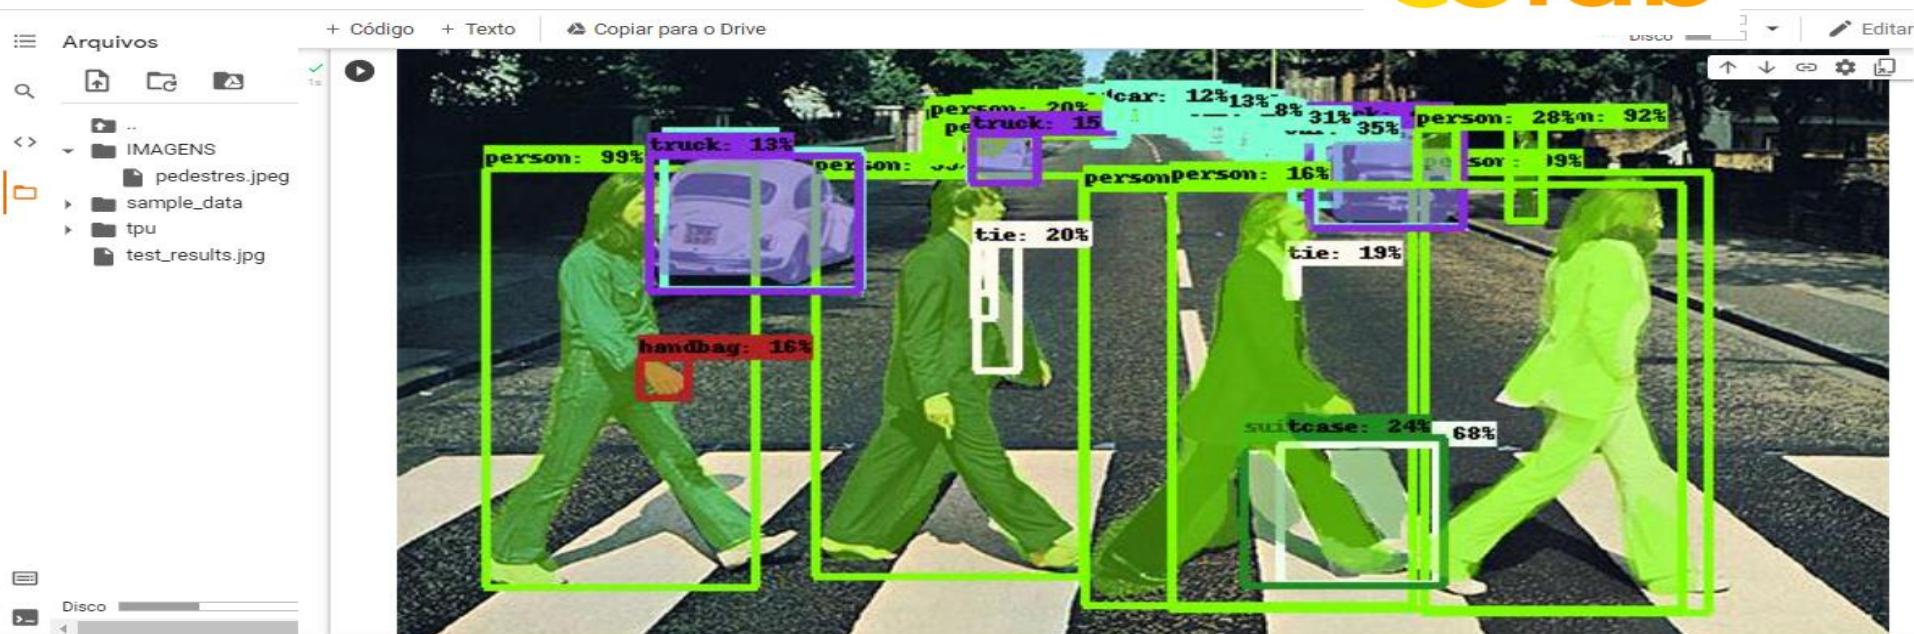
column_1	another_column	string	binary
1	Aaa	string	b"binary"
2	Baa	string	b"binary"



# Vamos ver algo na prática?

dio.

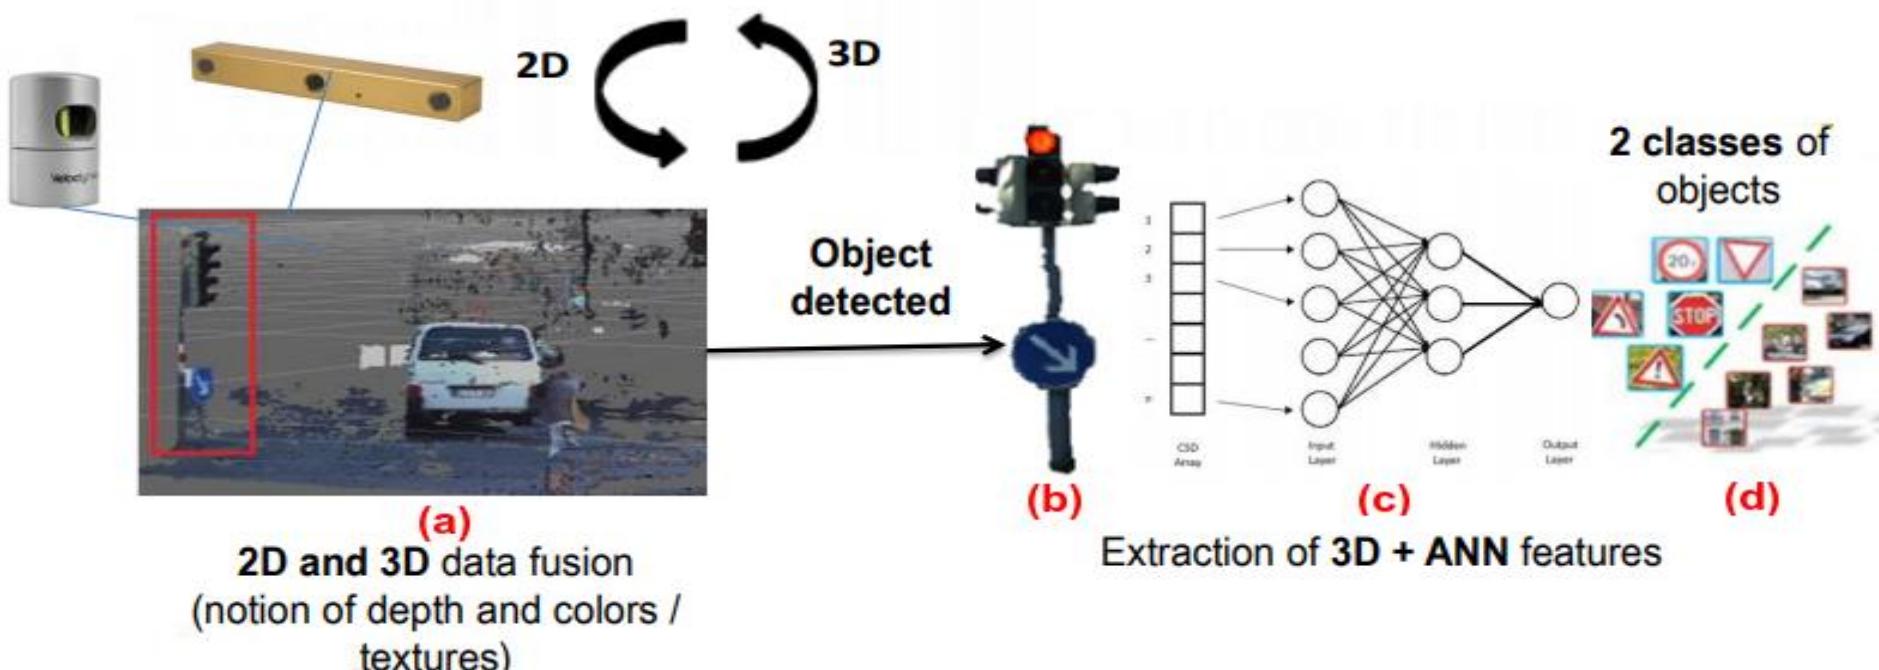
colab



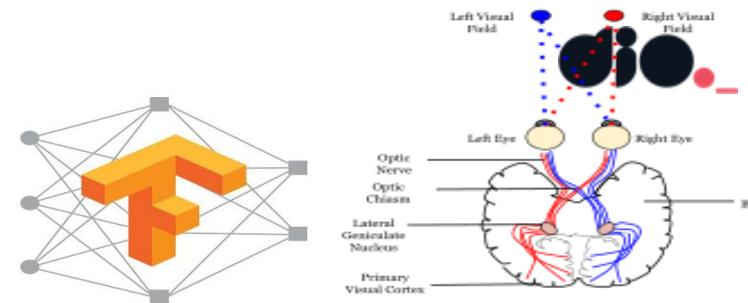
**COLAB:** Ferramenta online de Machine Learning

# Contextualização e motivação

## Detecção de placas e semáforos de trânsito



# Redes de Detecção

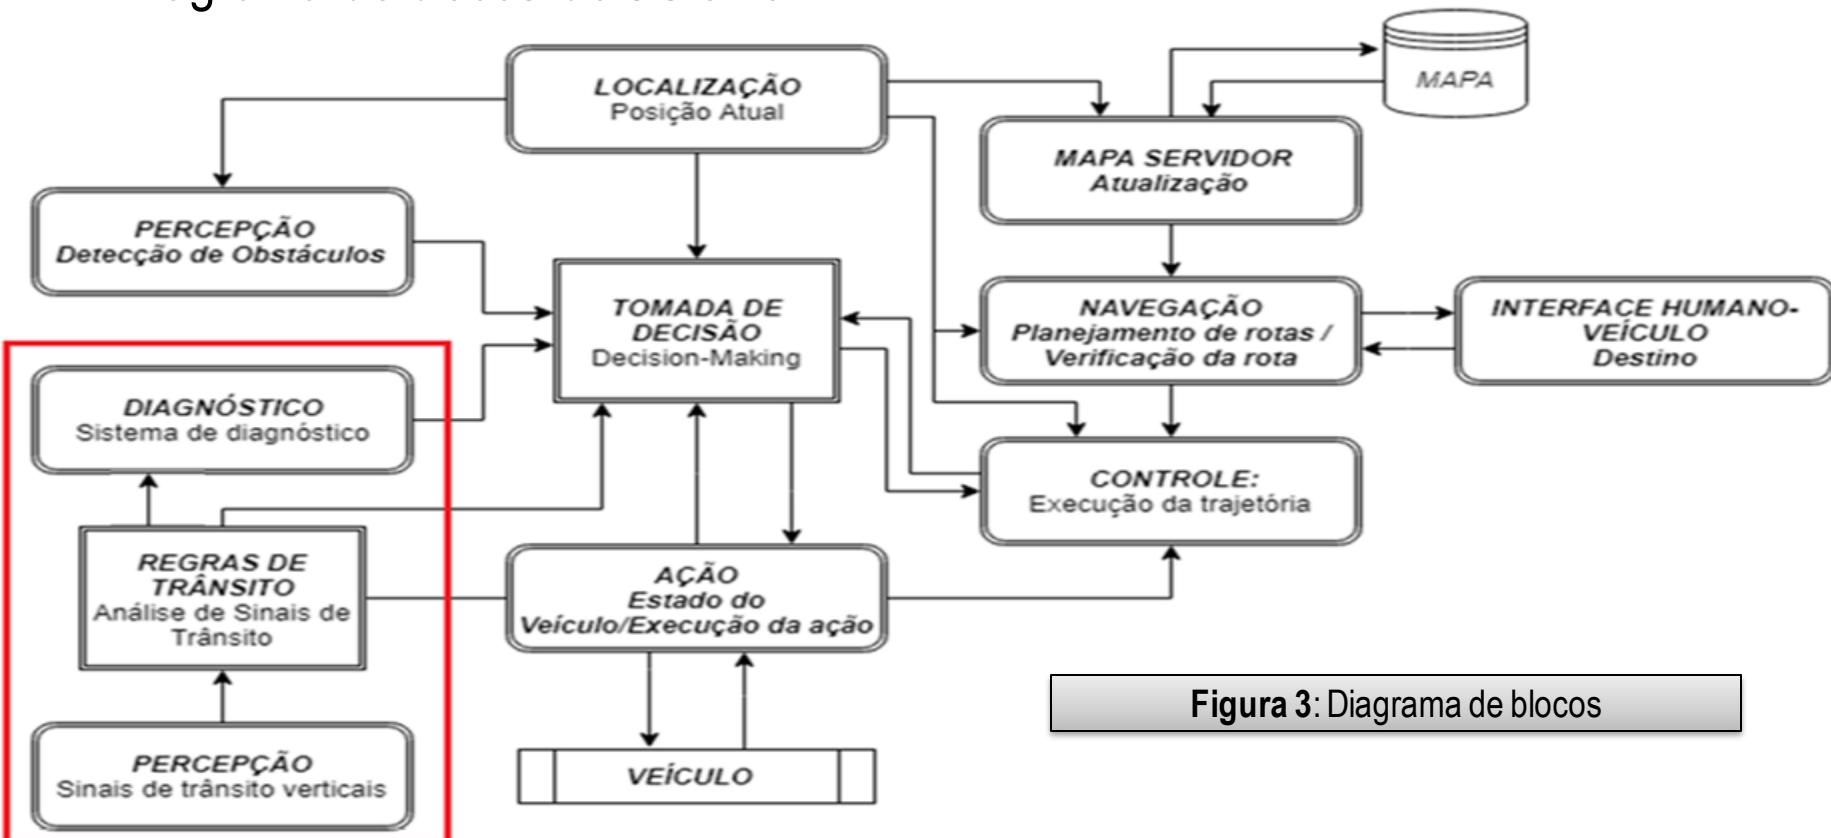


**YOLO - VGG + Inception V3**

Figura 2: Transfer Learning

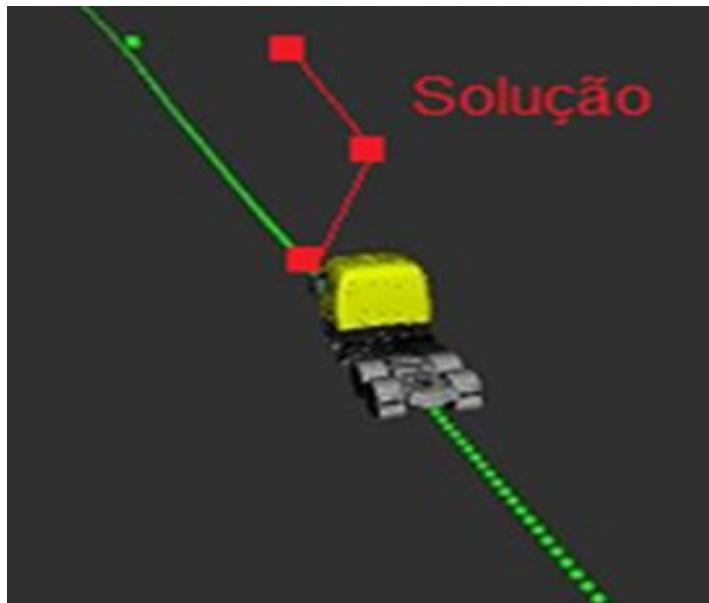
# Arquitetura de um Carro Autônomo

Diagrama de blocos do sistema

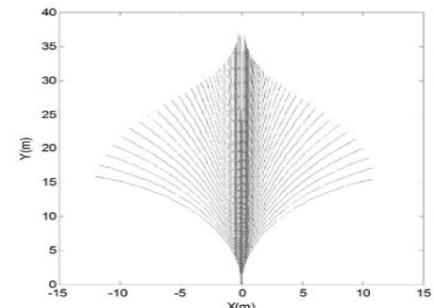


# Seguidores de linha (GPS)

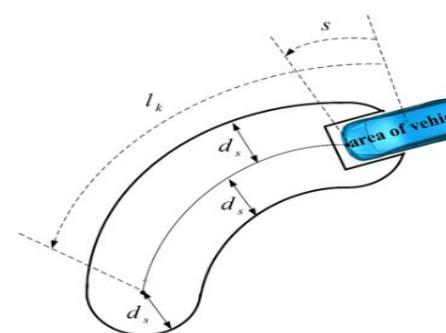
## Planejamento de rotas - GPS



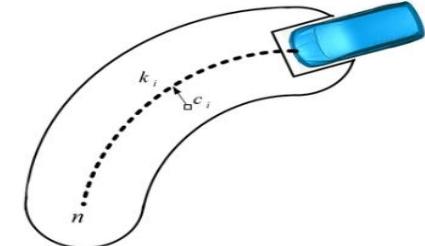
A Occupancy Grid



B 81 Tentacles in One Speed Set



C Support Area



D Obstacle Detection

# Problemas...

Detecção de placas móveis – (rotas não mapeadas):

- Atenção Visual: Desvios, trechos em obras, perigo na pista;

O mapeamento dos sinais de trânsito não seria eficiente neste tipo de situação



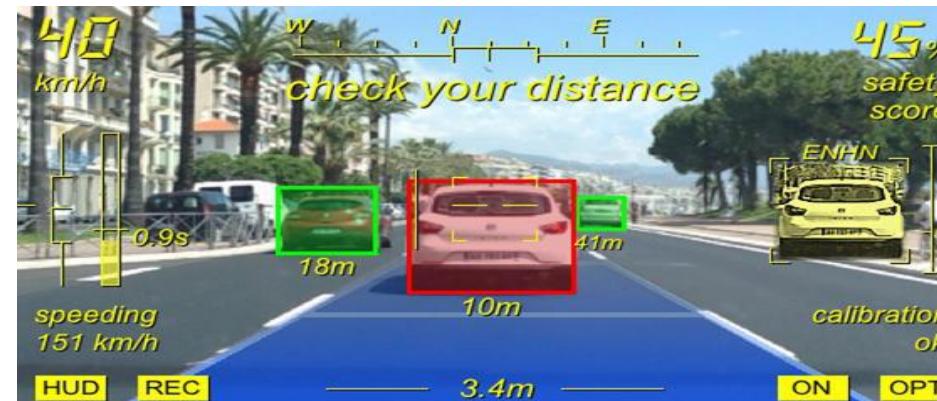
Desvios: Rota auxiliar



Trecho em obras: Velocidade reduzida

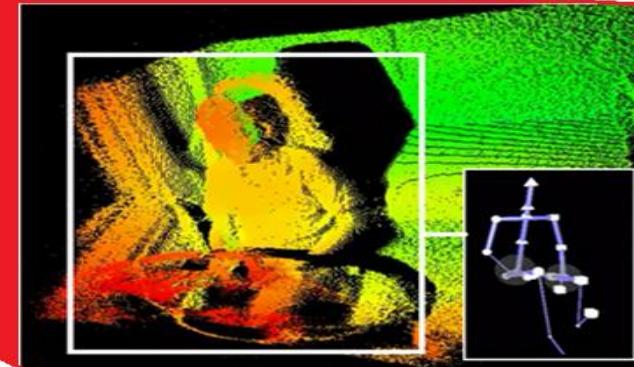


# Planejamento de rotas



# Atenção visual

Análise do ambiente de navegação com regras de trânsito  
em conjunto com o comportamento do condutor

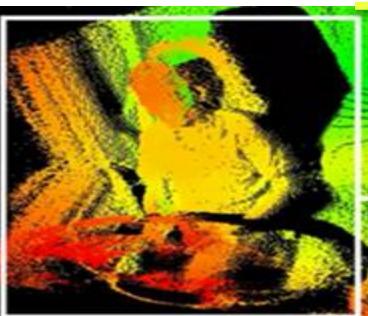


**DRIVER ASSISTANCE**  
DRIVE SMARTER. DRIVE SAFER.

# Funcionamento do Sistema

ADAS proposto:

Percepção externa + percepção interna



## Máquina de Estados + RNA

### Classificação dos problemas de desrespeito as leis de trânsito

- Suporte ao controle autônomo ou semi-autônomo;
- Neuro-FSM: Suporte a detecção e correção de falhas.



Figura 28: Mapa utilizado

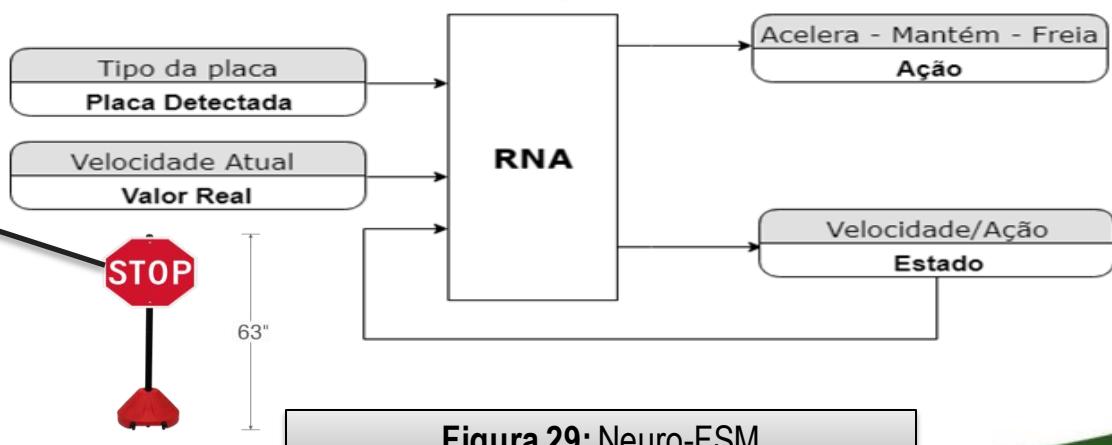
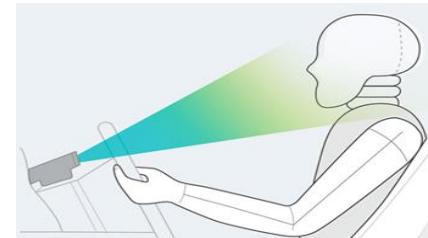


Figura 29: Neuro-FSM



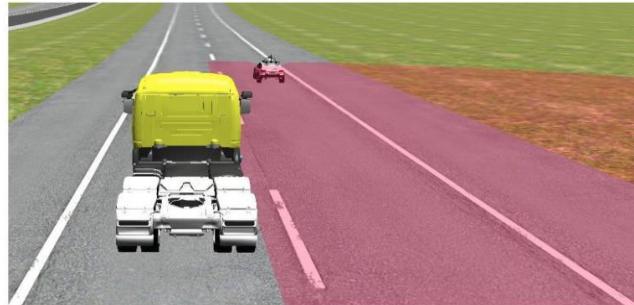
# ADAS para correção de falhas humanas

**Rotinas automáticas para suporte a tomada de decisão:**

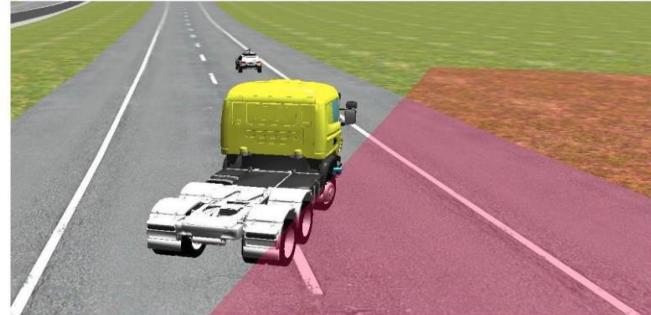
- Detecção de falhas humanas;
- Detecção de falhas de controle autônomo.



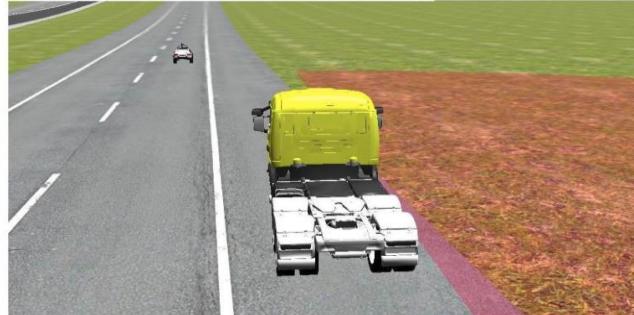
(a)



(b)



(c)



(d)

# Resultados obtidos

Artigo para o LARS (*Latin American Robotics Symposium*) - 2017

**Image classification system based on Deep Learning applied to the recognition of traffic signs for intelligent robotic vehicle navigation purposes**

*Diego Renan Bruno., and Fernando Santos Osório., Member, IEEE - University of São Paulo*

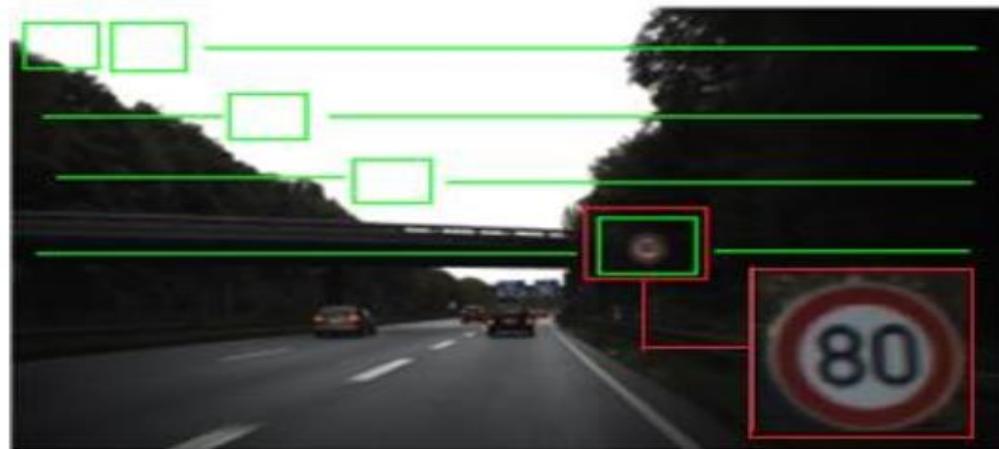


2017 Latin American Robotics Symposium (LARS) and  
2017 Brazilian Symposium on Robotics (SBR)

# Resultados Obtidos

## Algoritmo de *Slide Window*

- Poder do *Deep Learning* X Modelos de detecção 3D



**Figure 5:** Slide window algorithm execution [4]

# Resultados Obtidos

## Resultados para oclusão de imagem

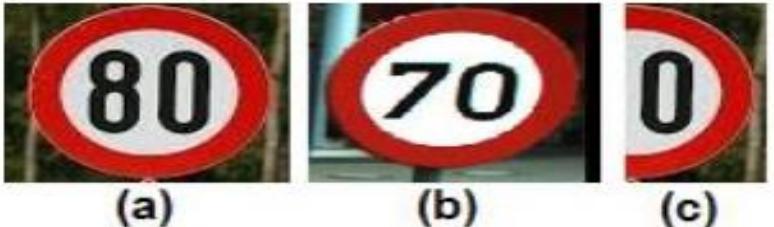


Figure 6: Severe problem of occlusion of traffic signs [6] (a) 80km (b) 70km and (c) problem of occlusion [4]

Traffic Sign	Type of traffic signal	Accuracy in classification (%)
	STOP	99.1
	STOP	99.6
	STOP	98.3
	STOP	96.2
	PREFERENCE	96.2
	PREFERENCE	97.6
	PEDESTRIAN	88.5
	PEDESTRIAN	89.2
	FOLLOW IN FRONT OR RIGHT	94.1
	FOLLOW IN FRONT OR RIGHT	88.2

# Resultados Obtidos

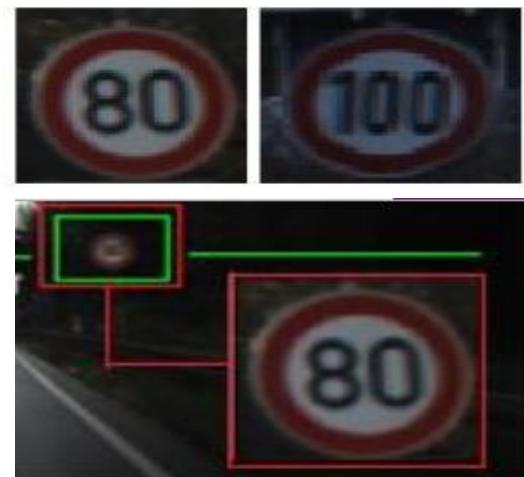
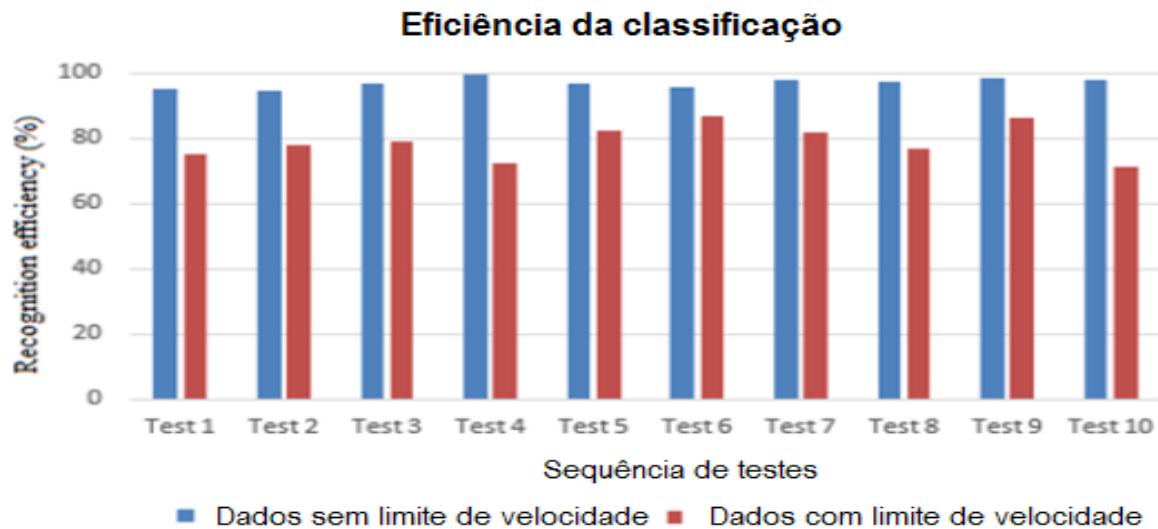
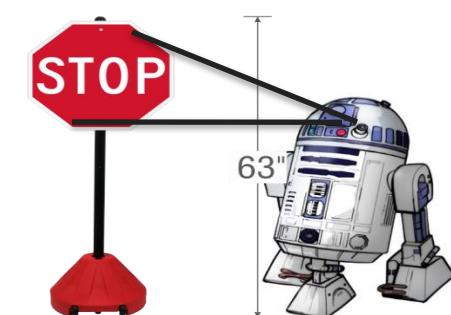


Gráfico 3: Comparaçao dos testes de classificação

# Visão 2D – CNN Segnet

- Detecção em dados (imagens) 2D – Estado da arte em visão 2D

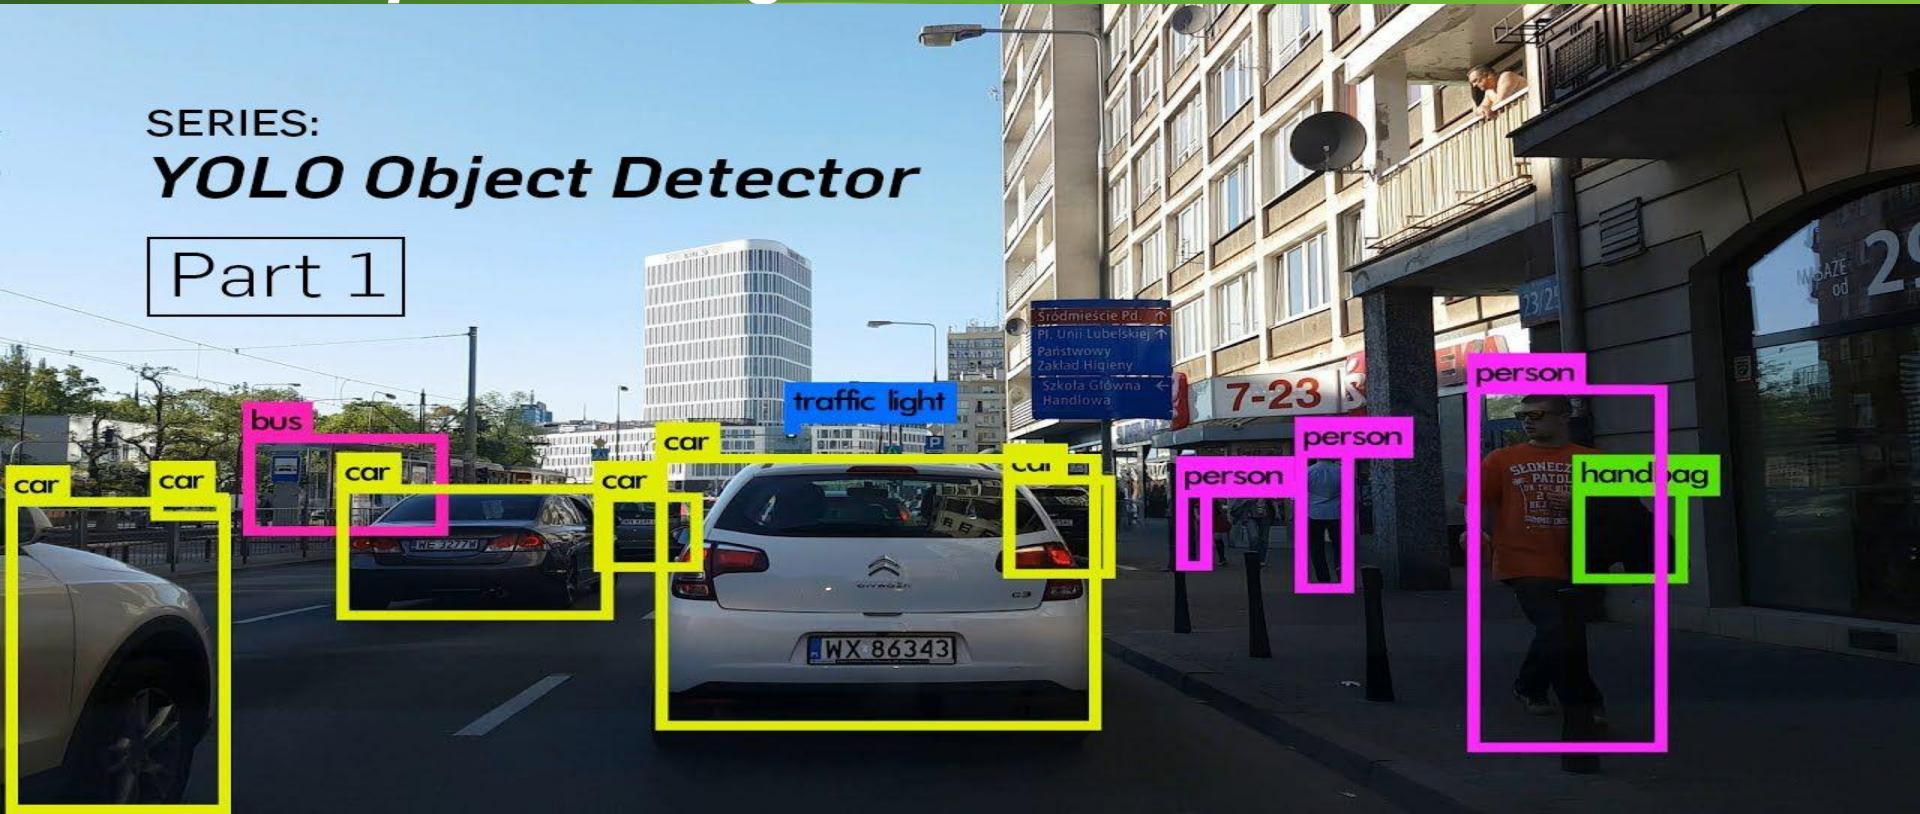


# Deep Learning - YOLO

SERIES:

***YOLO Object Detector***

Part 1

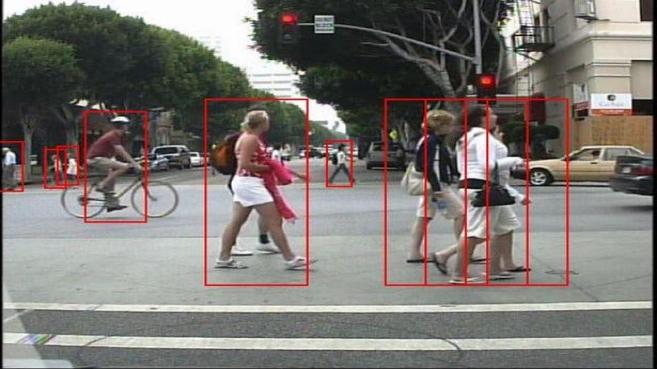


# Intelligent Robotic Applications

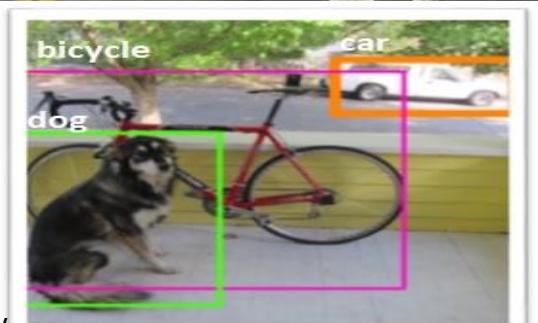
## 2D Computer Vision + ML / DL



<https://www.facebook.com/playgroundenglish/videos/53892067977460/>



[http://jacobsschool.ucsd.edu/news\\_releases/release\\_sfe?i](http://jacobsschool.ucsd.edu/news_releases/release_sfe?i)

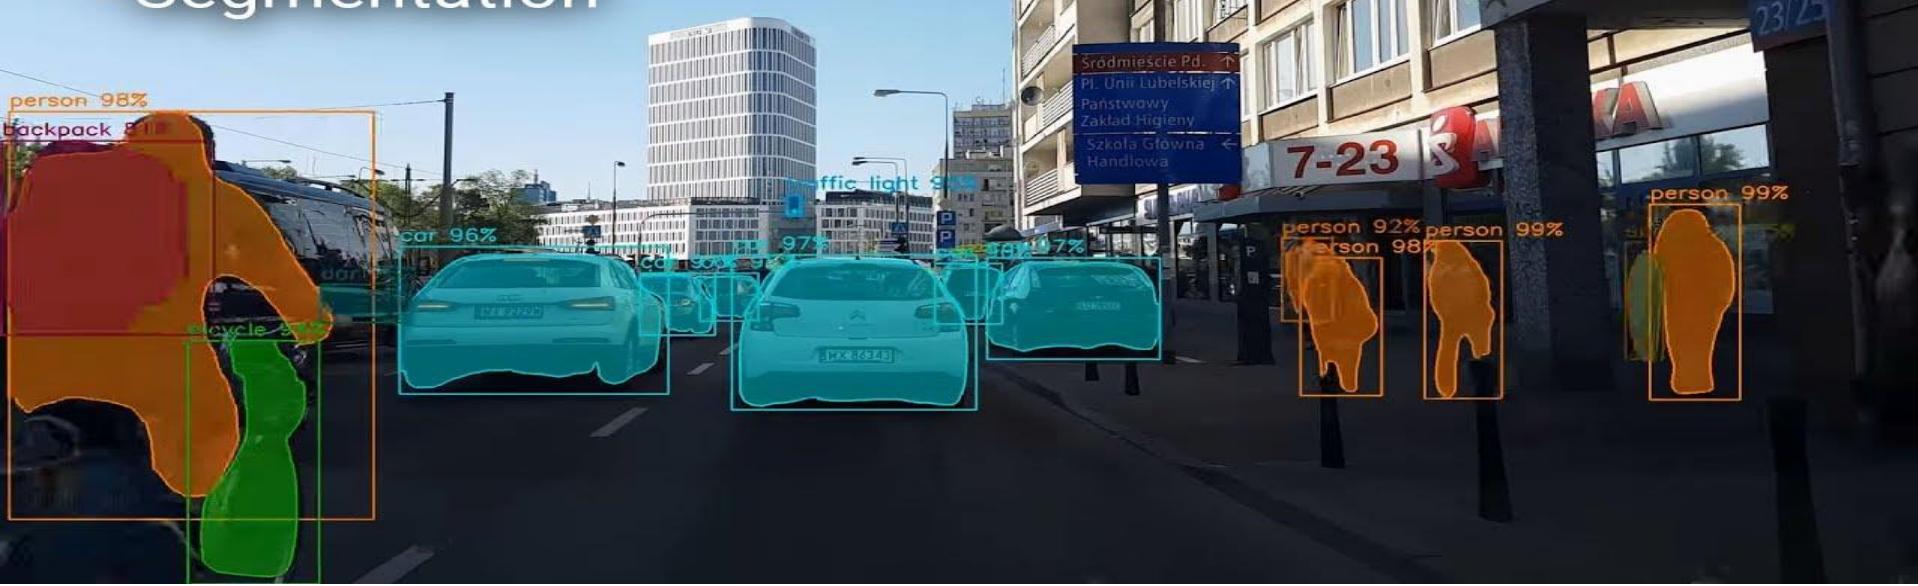


<https://pireddie.com/darknet/volo/>

# *MASK-RCNN Deep Learning*

## Mask R-CNN

- Object Detection
- Segmentation

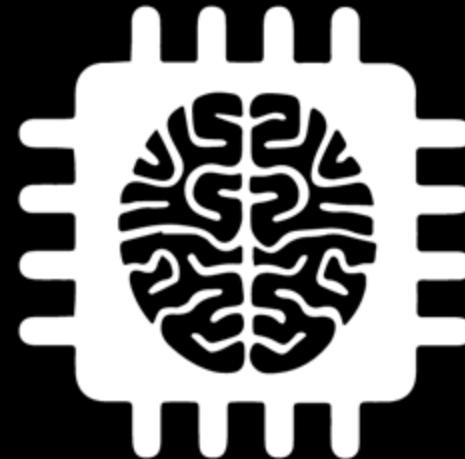


# *DeepLAB - Deep Learning*

## Detecção + Segmentação de objetos



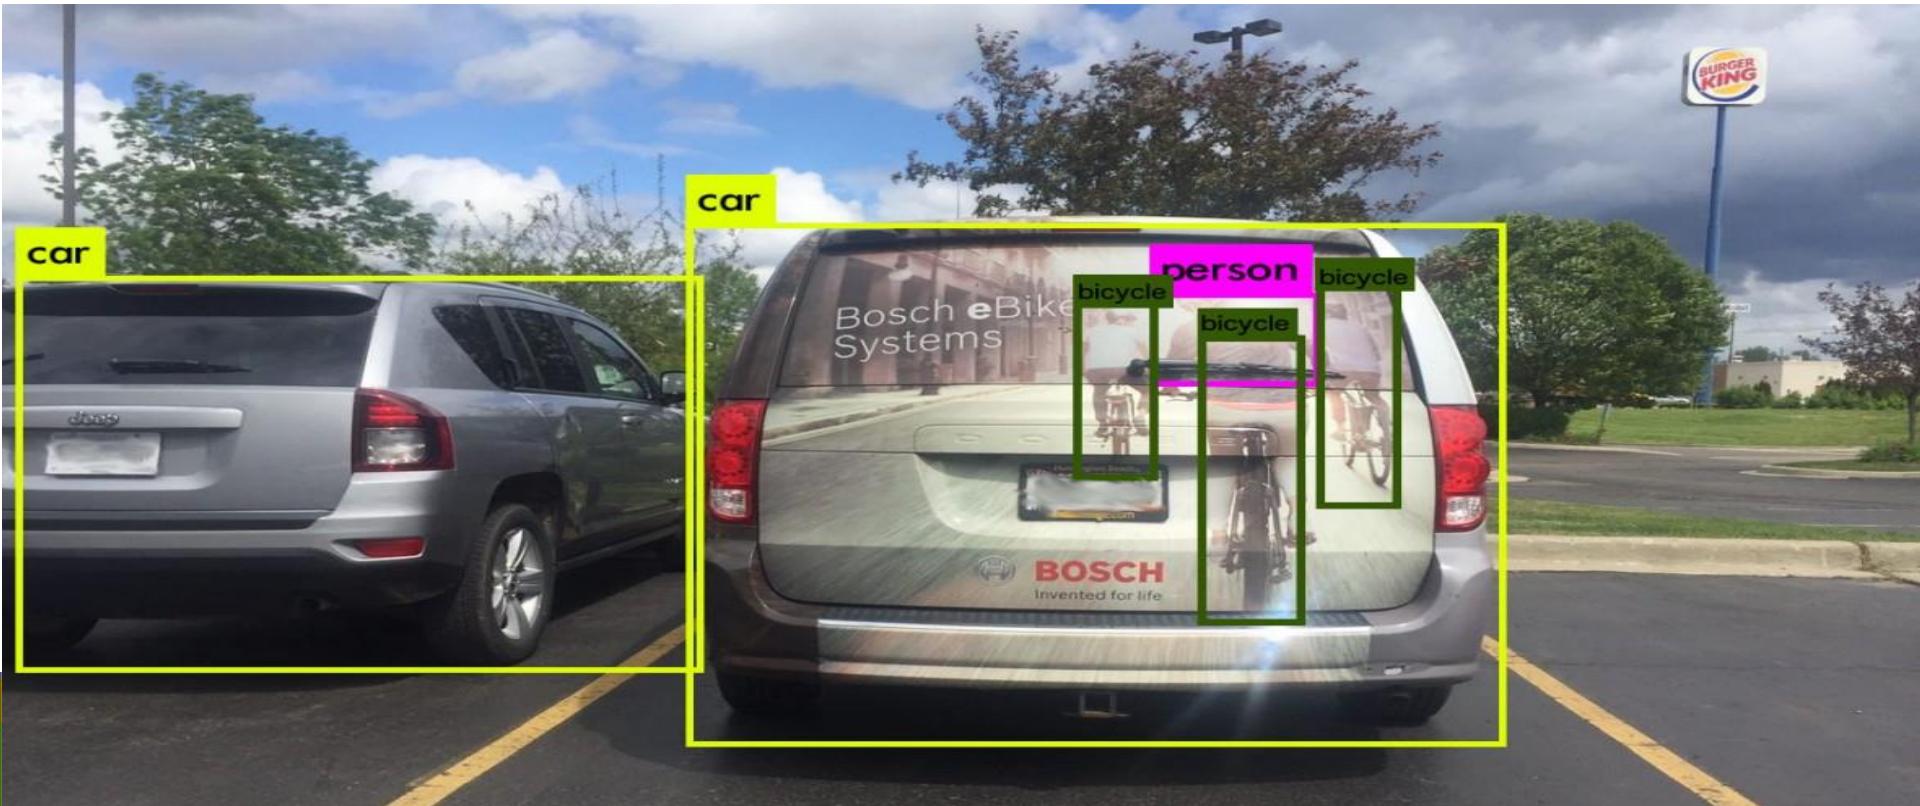
O mundo é visto de  
forma 2D ou 3D?



# Problemas em Visão 2D



Massachusetts  
Institute of  
Technology



<https://www.technologyreview.com/s/608321/this-image-is-why-self-driving-cars-come-loaded-with-many-types-of-sensors/> But also... Researchers hack a self-driving car by putting stickers on street signs  
<https://www.autoblog.com/2017/08/04/self-driving-car-sign-hack-stickers/>



# Problemas em Visão 2D

Veículo Autônomo:  
“Pare” para sempre...



Fotos de pessoas,  
Semáforos, Placas de Trânsito,



# Problemas de visão 2D



# Problemas em Visão 2D

Smartphones  
Face  
Unlock  
*Fail*



<https://www.youtube.com/watch?v=QS8NerjNJSc>  
[https://www.youtube.com/watch?v=IU\\_kbxpjQwW](https://www.youtube.com/watch?v=IU_kbxpjQwW)



**IEEE WORLD CONGRESS ON  
COMPUTATIONAL INTELLIGENCE**  
8-13 July 2018, Rio de Janeiro, Brazil

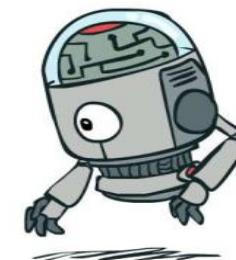
# Analysis and fusion of 2D and 3D images applied for detection and recognition of traffic signs using a new method of features extraction in conjunction with Deep Learning



*Diego Renan Bruno and Fernando Santos Osório*



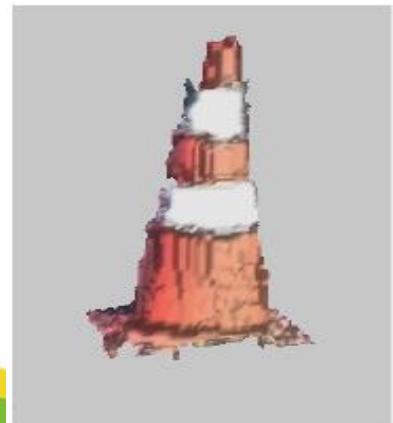
**The International Joint  
Conference on Neural Networks**



# Metodologia

## Visual attention and recognition

- Computer vision system and artificial intelligence



Visual attention



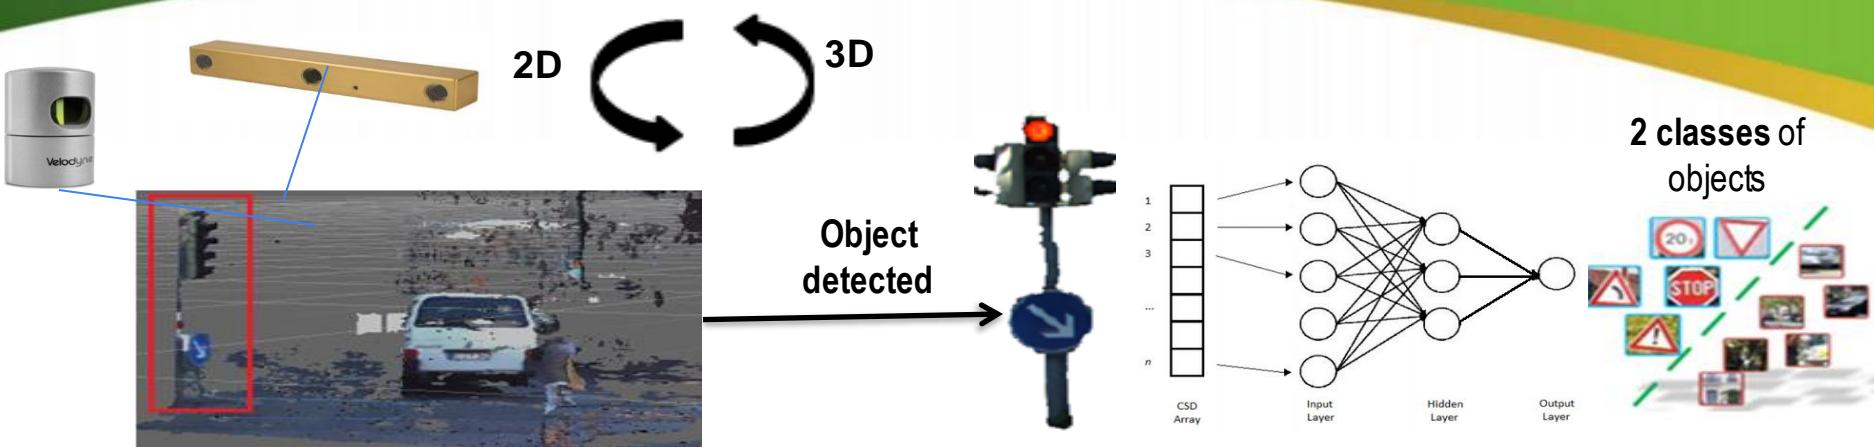
2D recognition – Artificial Intelligence



Our knowledge base is formed by a set of objects



# Metodologia



**2D and 3D data fusion**  
(notion of depth and colors /  
textures)

Extraction of **3D + ANN** features



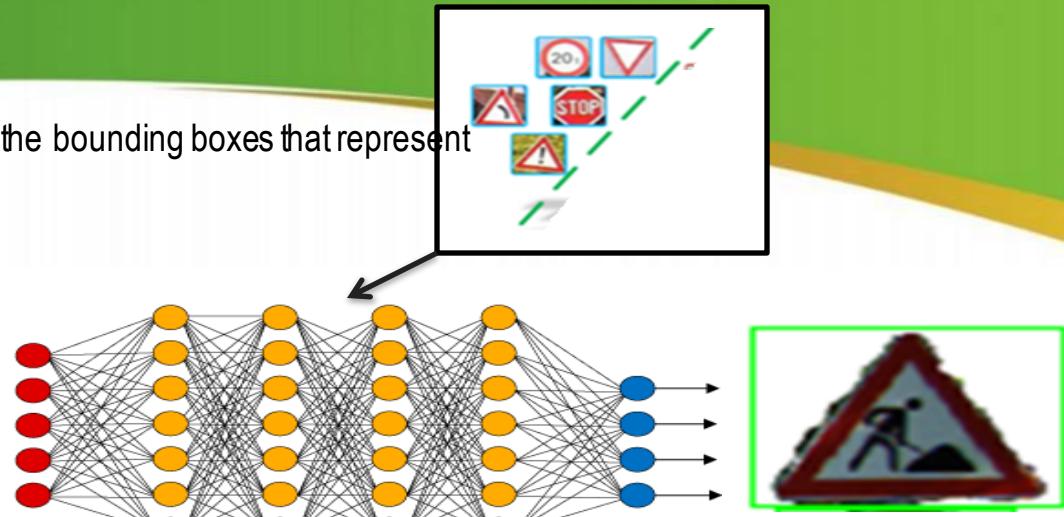
# Metodologia

We apply Deep Learning to classify the bounding boxes that represent the vertical traffic signals



Detection representation in 2D (x, y)

**Imagen 2D**  
(RGB)



**Deep Learning**  
(Inception V3)

Traffic sign detected  
and recognized

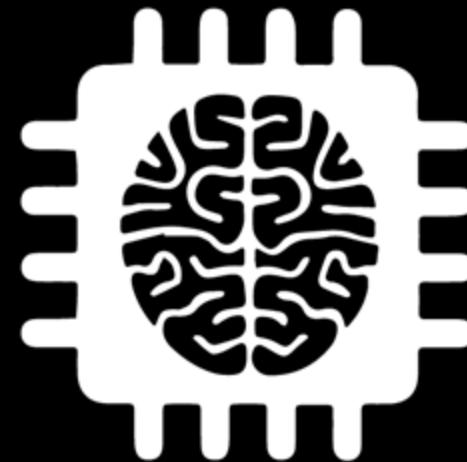


# As leis de trânsito são obedecidas?

dio.



# Ética para Sistemas Inteligentes



**Futurism**

# Laws and Ethics for Autonomous Cars

Sharing the road with robots



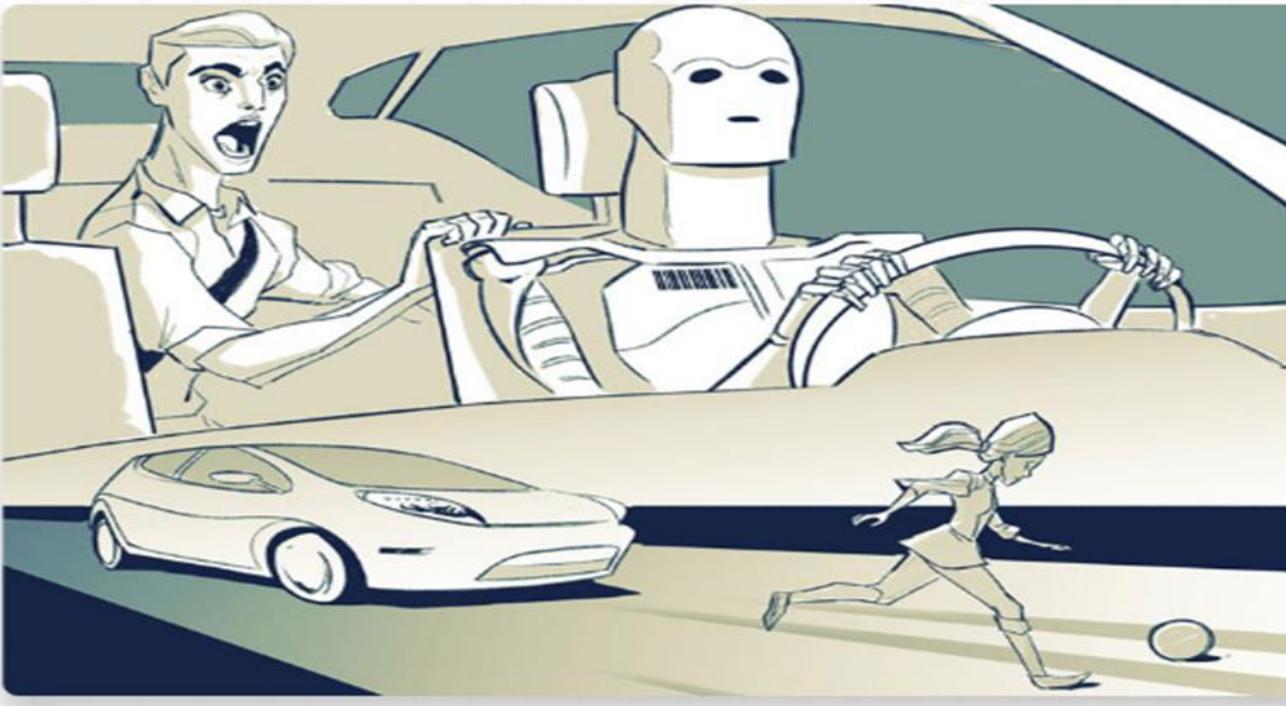
# Eu, robô - Asimov

As três leis de Asimov funcionam?



# Tomada de decisão sem sentimentos

--> Segurança

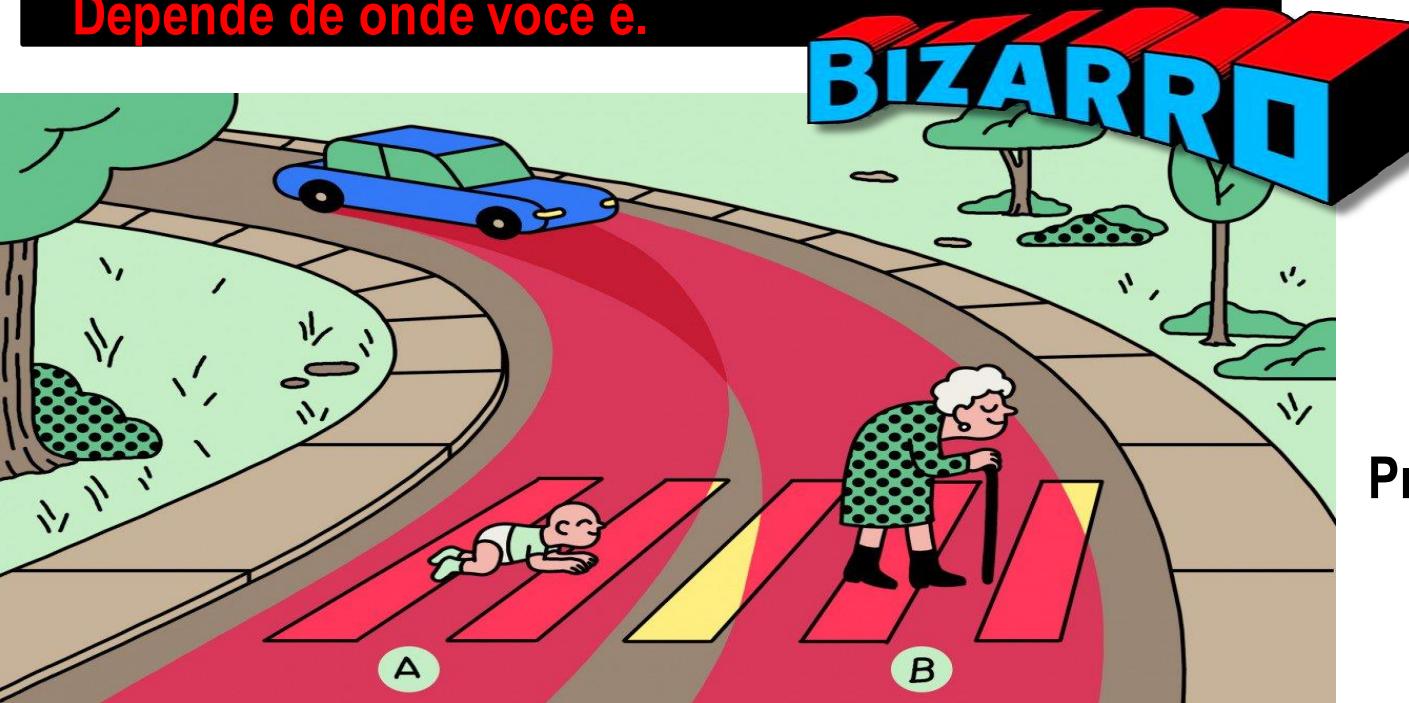


Proteger o seu dono  
ou a criança...?

# Tomada de atitude sem sentimentos

Um carro autônomo deve matar o bebê ou a avó?

Depende de onde você é.



Proteger o idoso ou a  
criança?

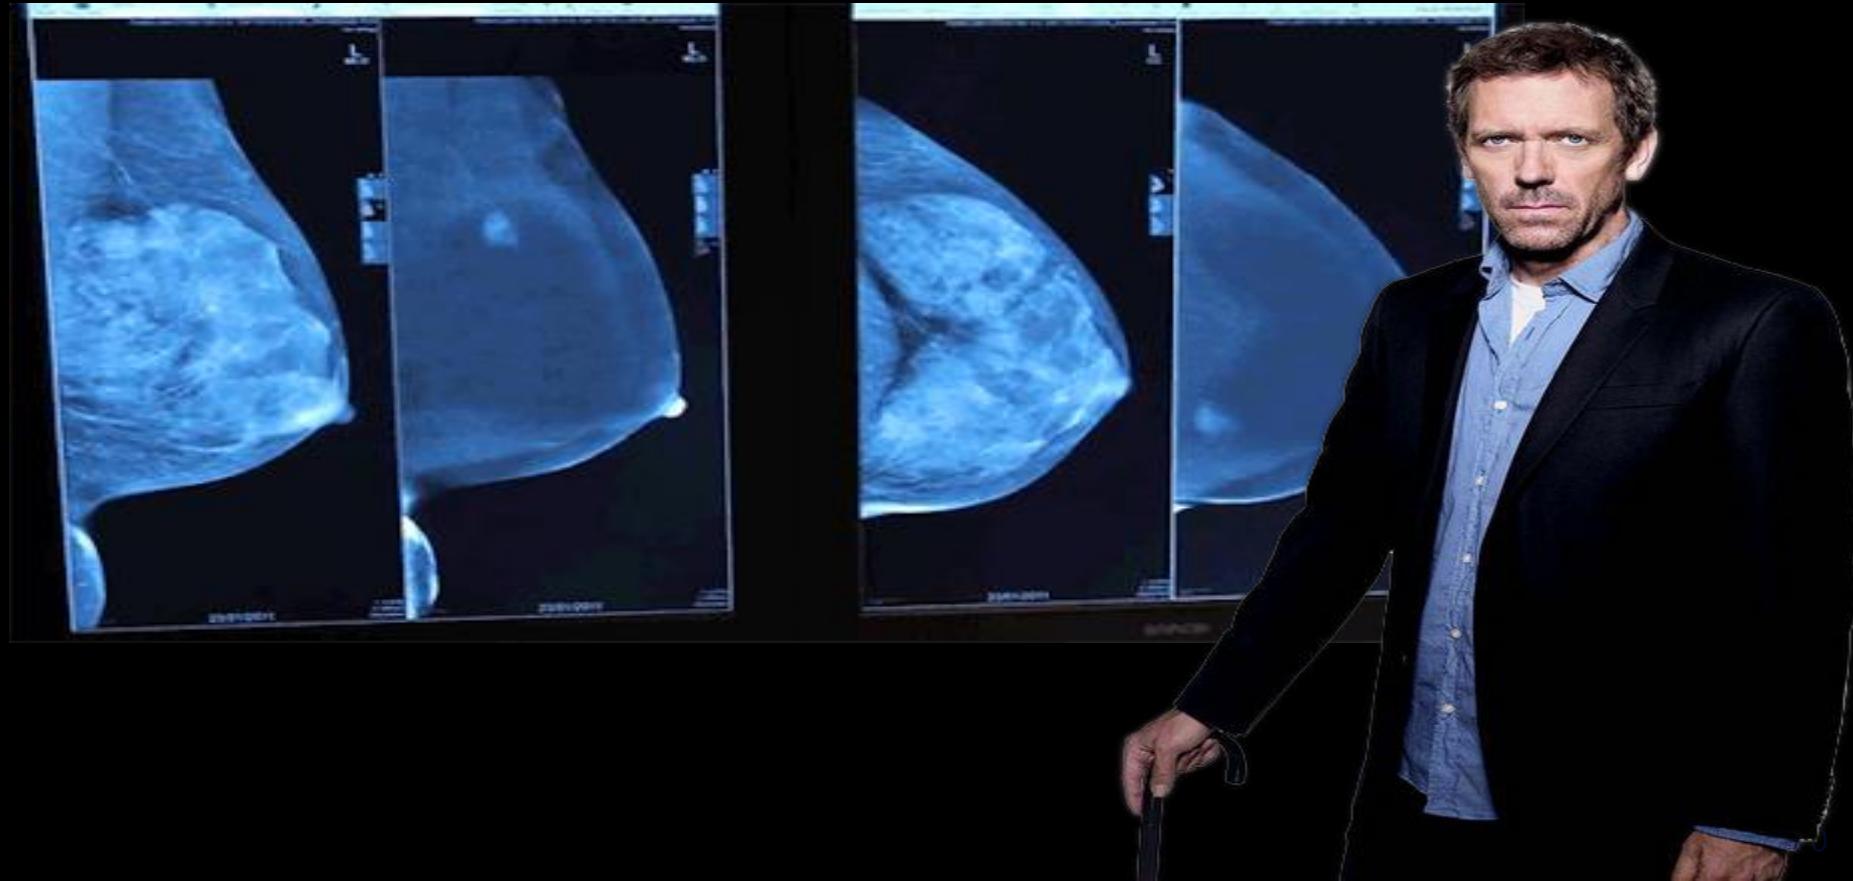
# Aplicações de ML e IA



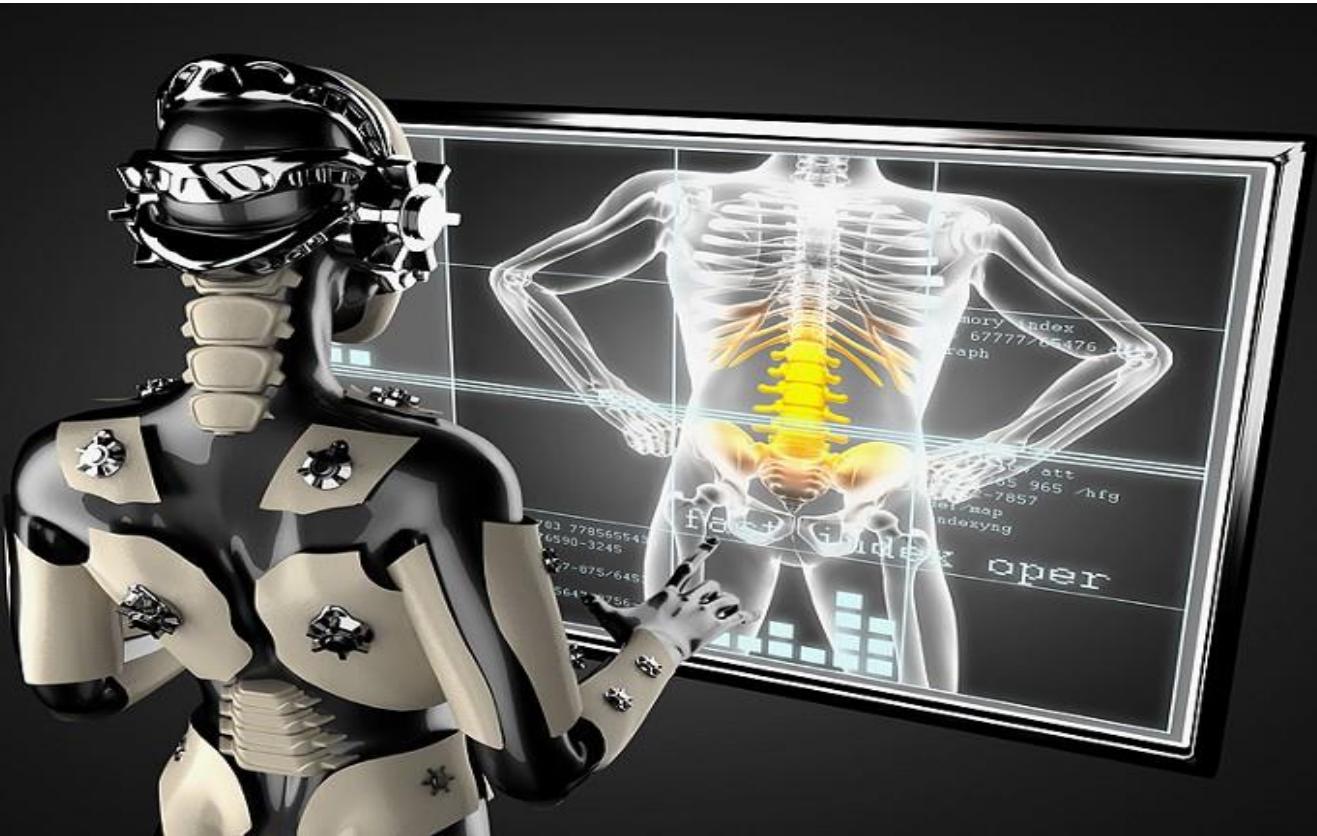
# Suporte para medicina



# Suporte para medicina



# Suporte para medicina



# Revolução Industrial



1 Revolução  
Industrial

1784 Primeiro tear  
mecânico



2 Revolução  
Industrial

1870 Primeira linha de  
produção (abatedouros de  
Cincinnati)



3 Revolução  
Industrial

1969 Primeiro Controlador Lógico  
Programável (PLC), Modicon 084

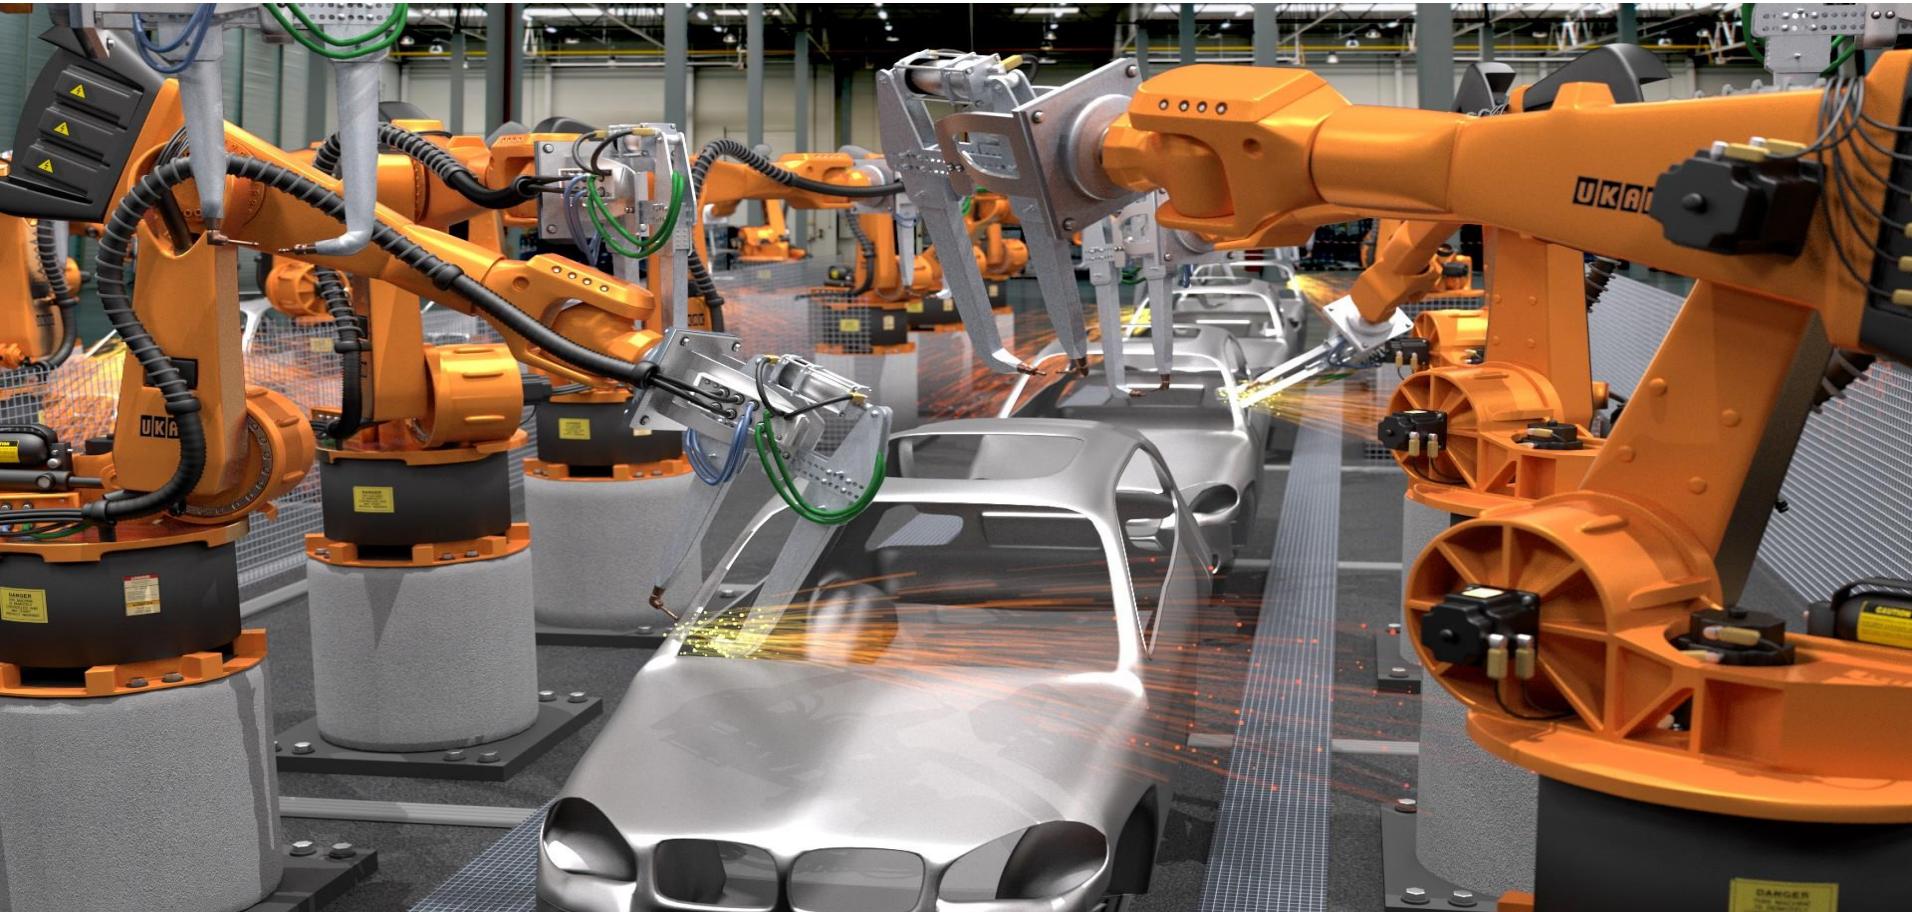


4 Revolução  
Industrial

2012 Sistemas Ciber-  
Físicos

COMPLEXIDADE ↑

# Revolução Industrial



# Revolução Industrial

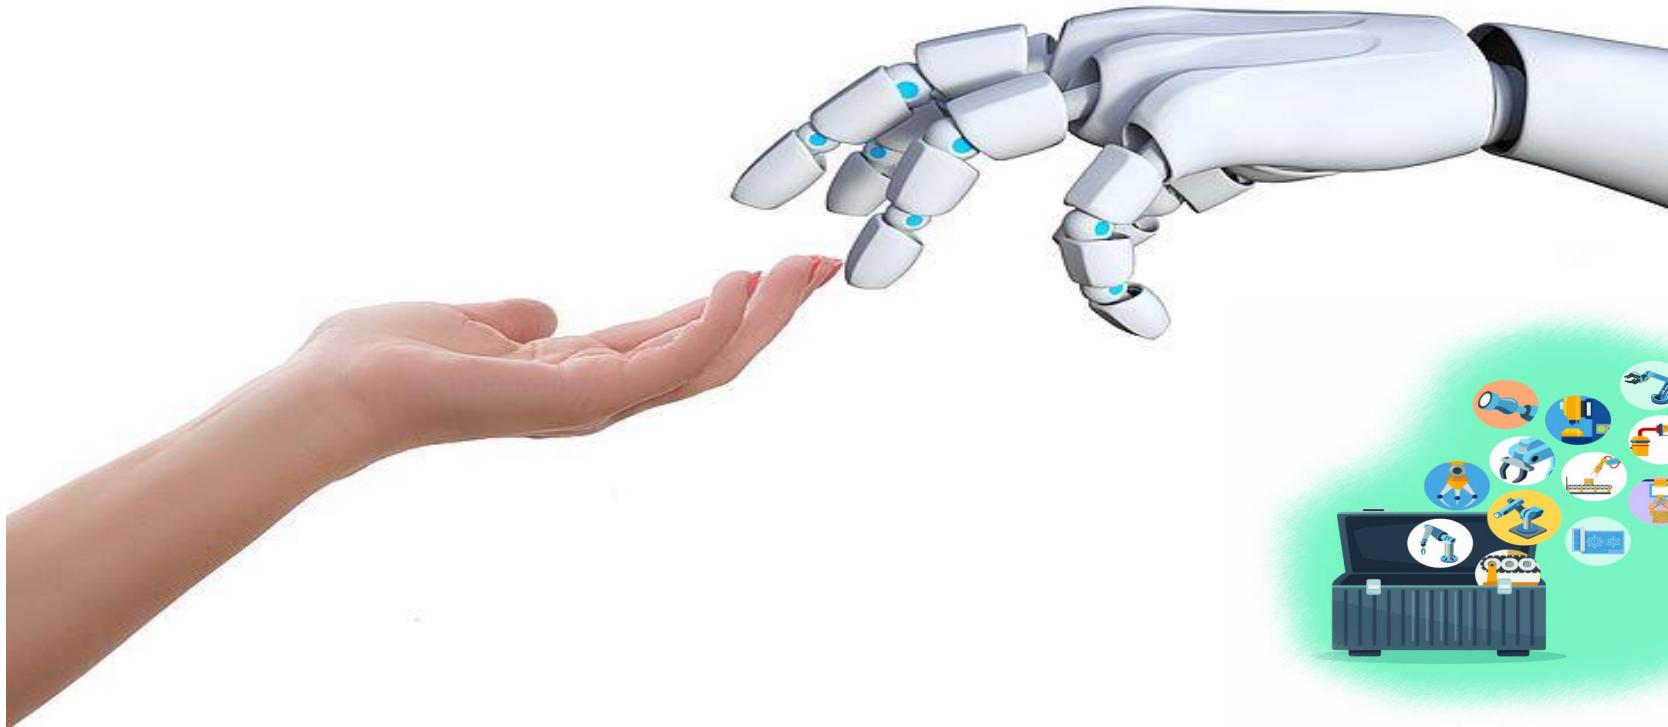
## Robótica Industrial

Robôs de produção

Controle do homem morto



# Robôs colaborativos



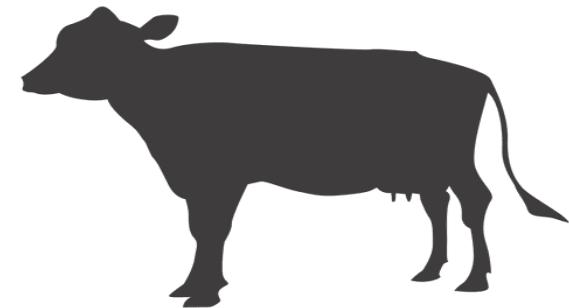
# Robôs colaborativos



# Problemas de IA

Reconhecer o tipo da carne

Grandes valores



# Problemas de IA

Algo parecido já é feito...



# BIG data

Análise de grandes volumes de dados...



Lavoura



Bancos

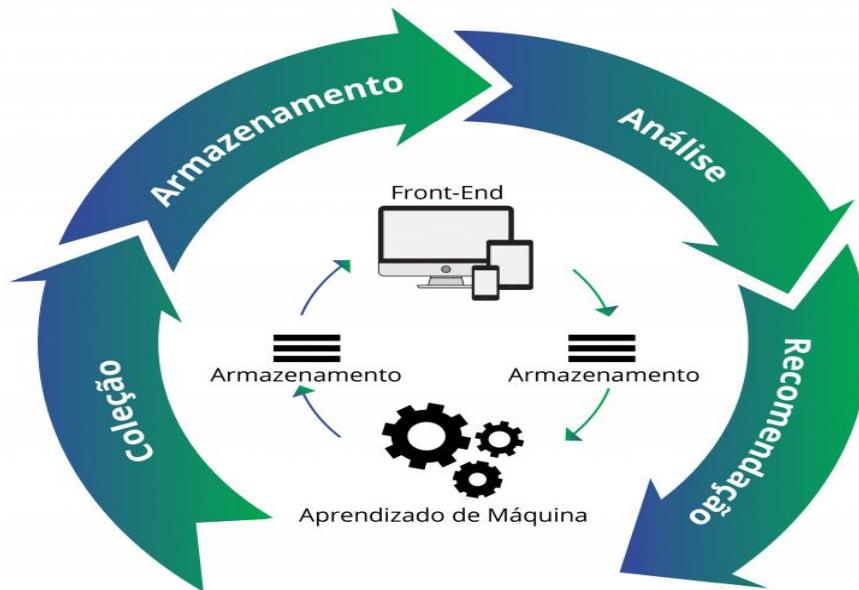
# Sistemas de Recomendação

Como vender produtos relacionados...



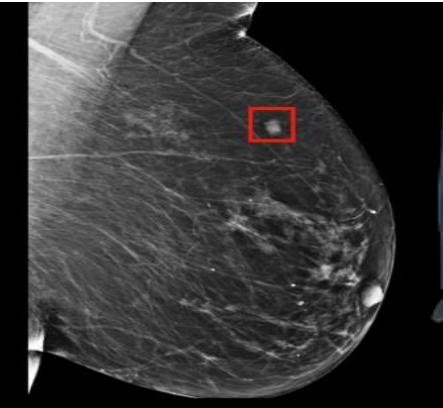
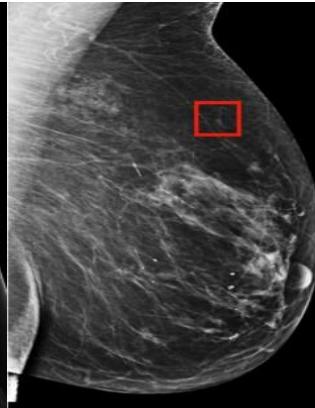
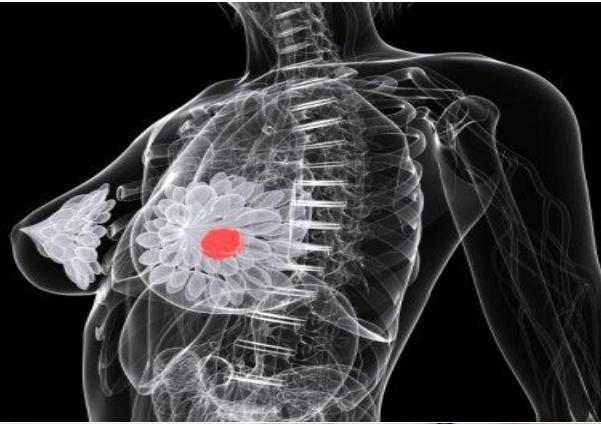
# Sistemas de Recomendação

Como vender produtos relacionados...



# Suporte para a Medicina

Dar suporte para um médico...



## 20 SEGREDOS QUE OS MÉDICOS NÃO CONTAM

BIZARRO

*Cirurgias desnecessárias, remédios que não funcionam, conflitos de interesse: a medicina está doente. Para superar essa crise, é preciso enfrentar algumas verdades inconvenientes.*

# Alguém gostaria de vida eterna?

## 2045 AVATAR PROJECT MILESTONES

STRATEGIC SOCIAL INITIATIVE



### Avatar D 2040 - 2045

Um avatar semelhante a um holograma

BIZARRO

### Avatar C 2030 - 2035

Um avatar com um cérebro artificial no qual uma personalidade humana é transferida no final da vida

### Avatar B 2020 - 2025

Um avatar em que um cérebro humano é transplantado no final da vida

### Avatar A 2015 - 2020

uma cópia robótica de um corpo humano controlada remotamente via BCI



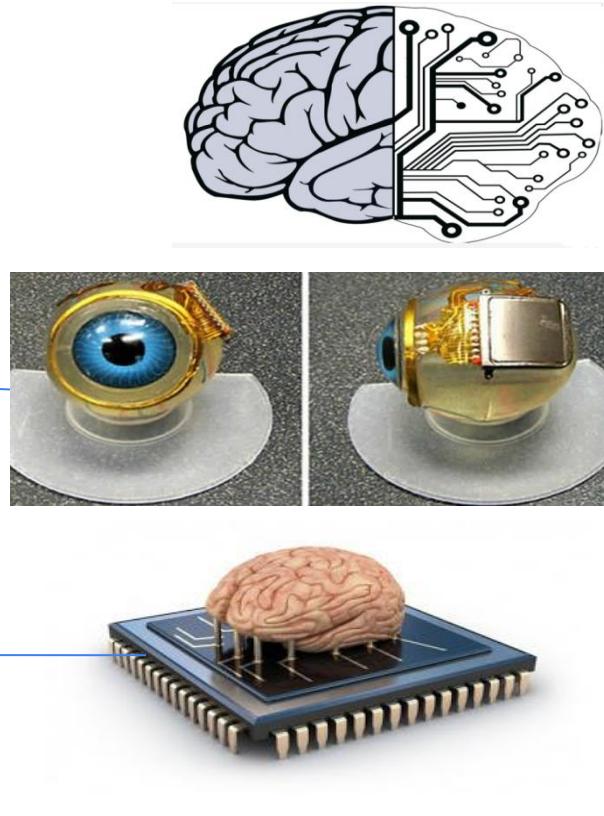
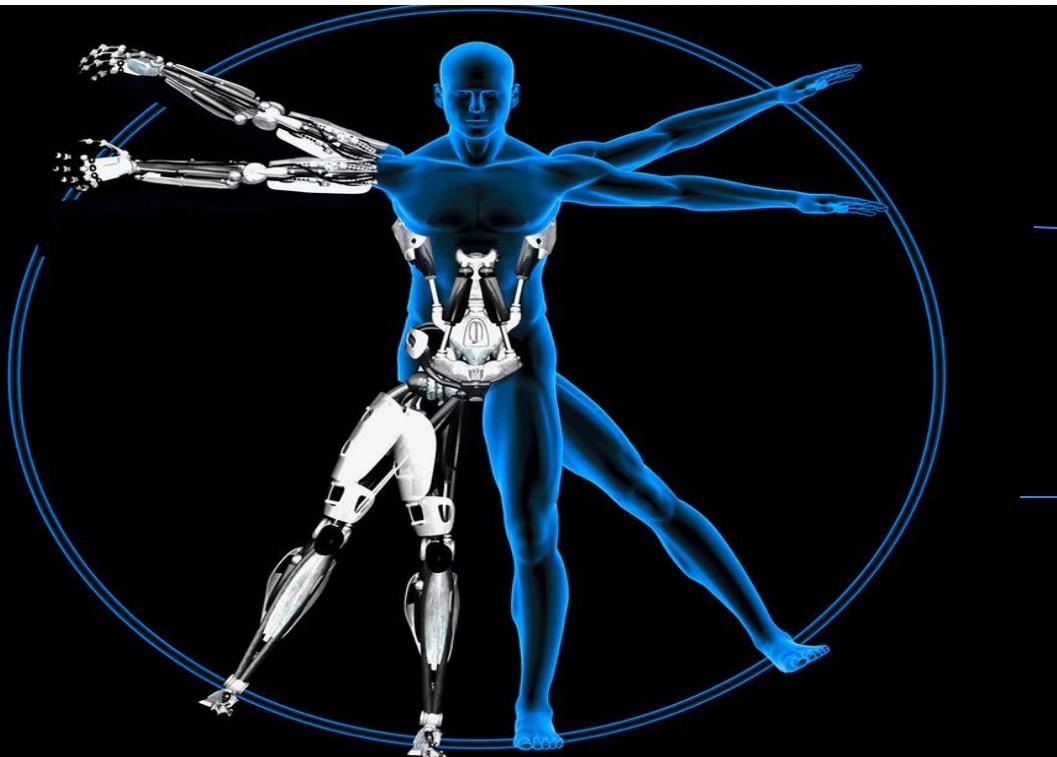
EVOLUTION

2045

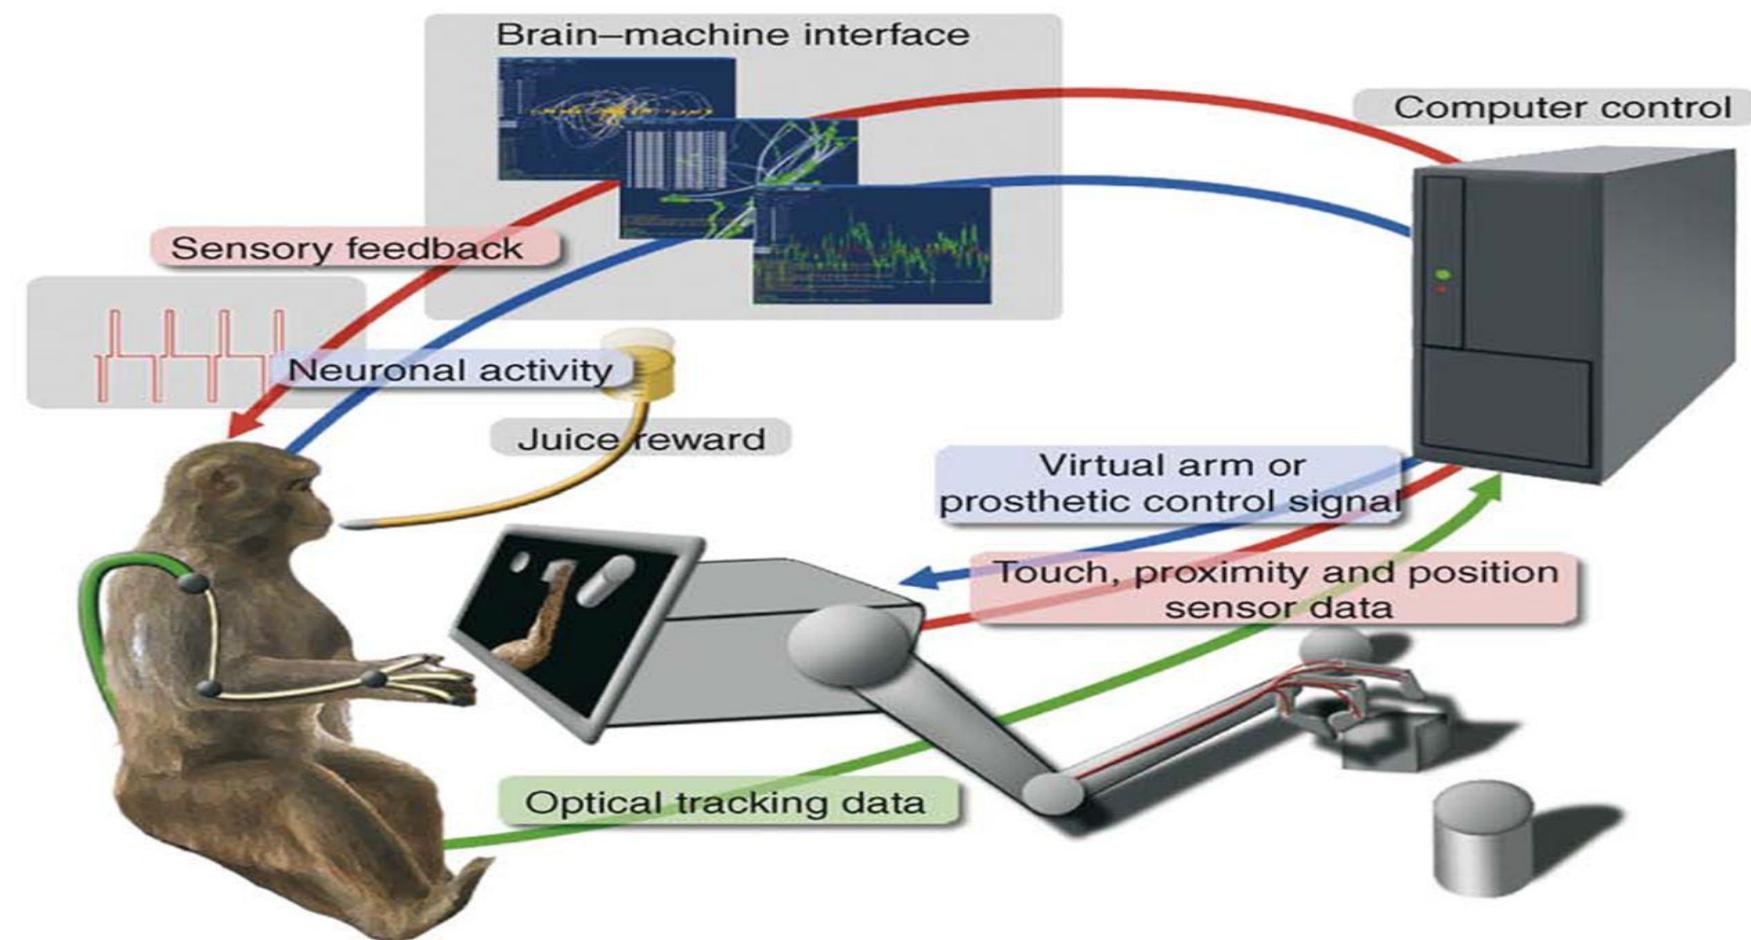
POLITICAL  
PARTY

# Tranhumanismo

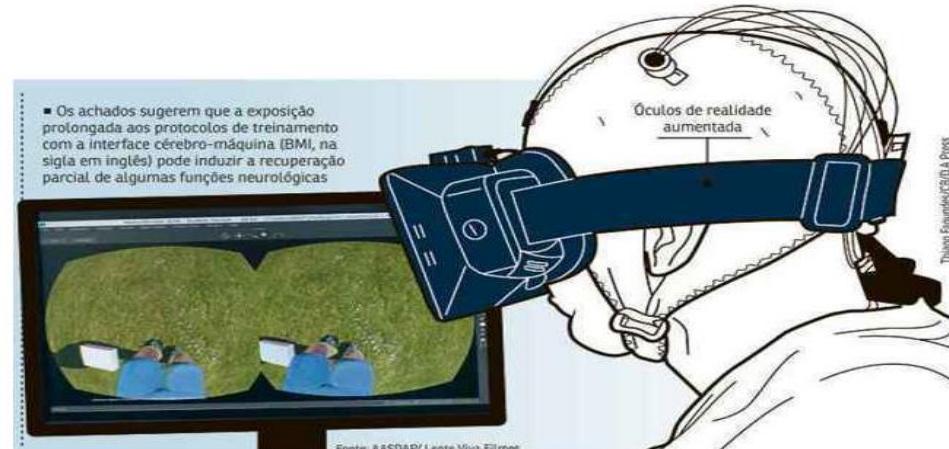
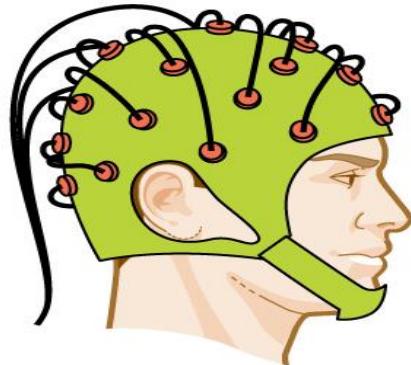
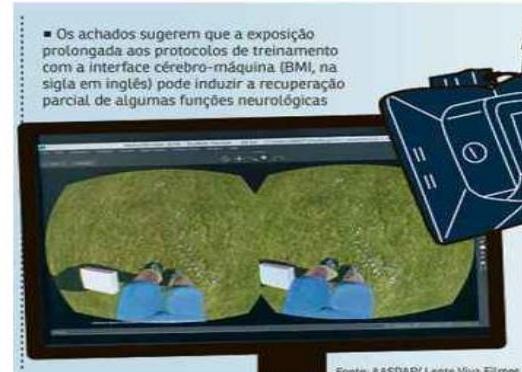
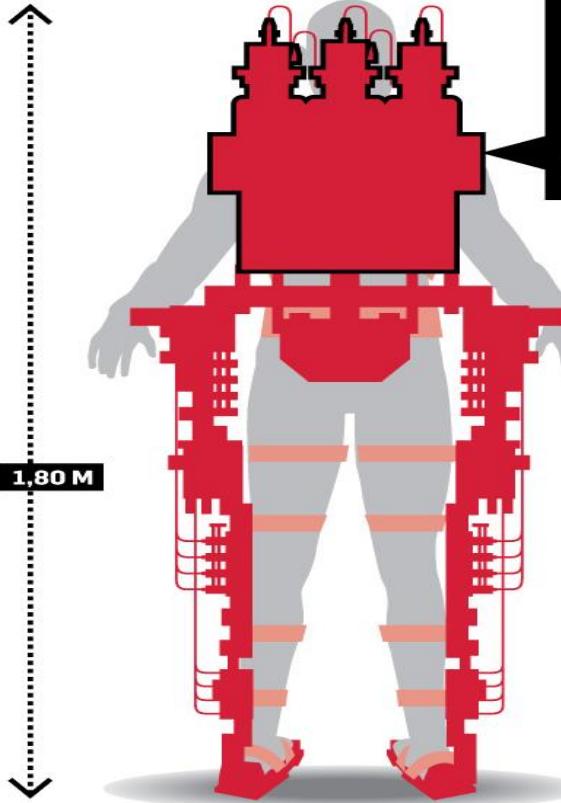
Melhoramento cerebral e corporal



# Máquina que pensam como humanos

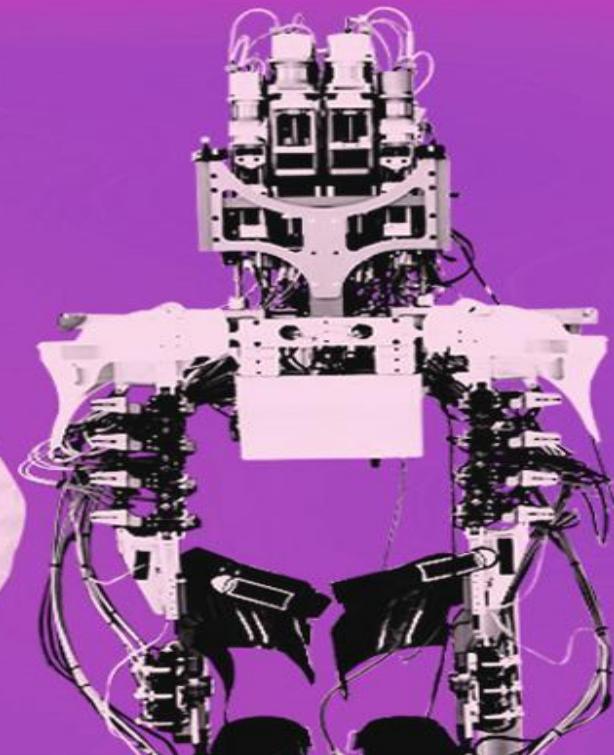
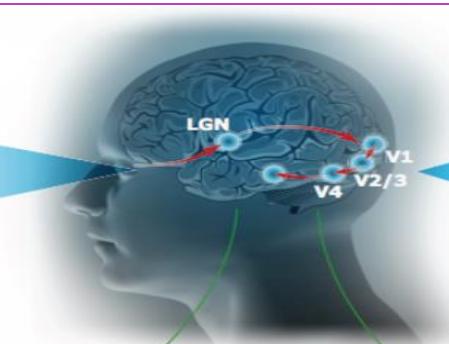


# Máquina que pensam...



# Máquinas que pensam...

Neurocientista brasileiro Miguel Nicolelis



# Máquinas que pensam como seres humanos

dio.

Aplicações de reabilitação humana – sistemas cognitivos

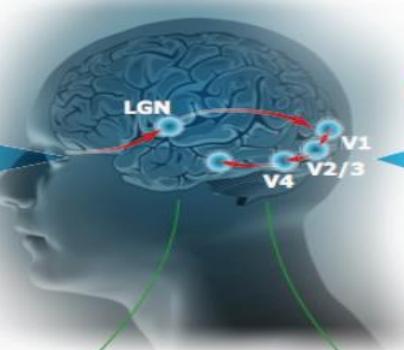
a.



encoding

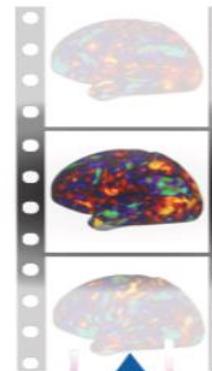
decoding

b.



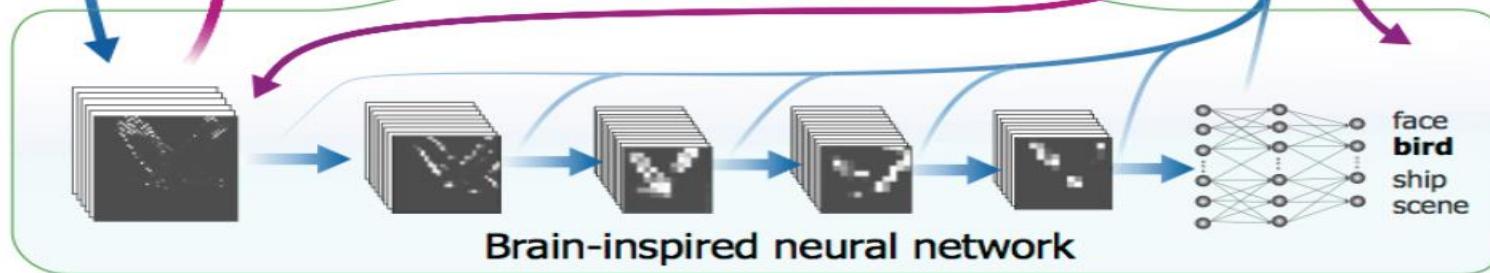
Imaging

c.



categorization

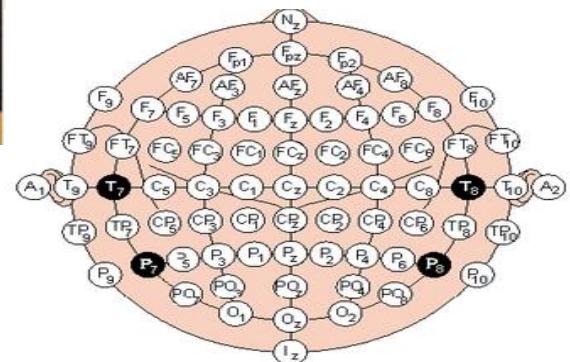
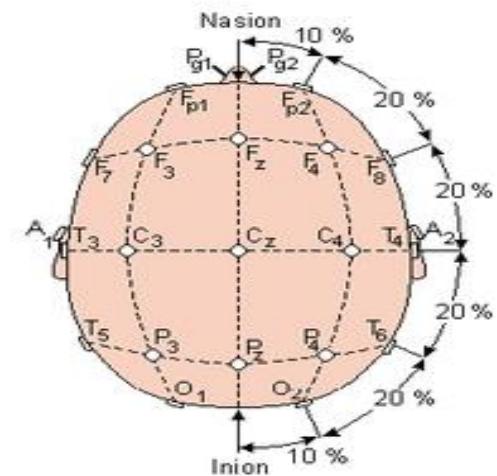
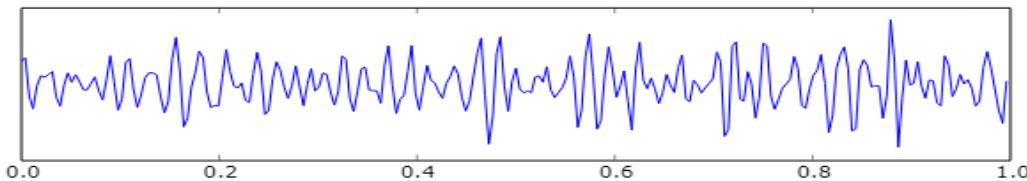
d.



brainn.org.br

# Máquinas que pensam...

ndia



# Obrigado!

*Machine Learning*

Prof. Dr. Diego Bruno



# Métodos de *Machine Learning* Bioinspirados

**Prof. Dr. Diego Bruno**

Education Tech Lead na DIO

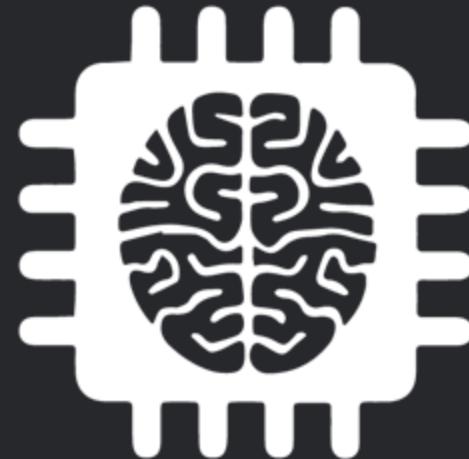
Doutor em Robótica e *Machine Learning* pelo ICMC-USP



# *Algoritmos Bioinspirados*

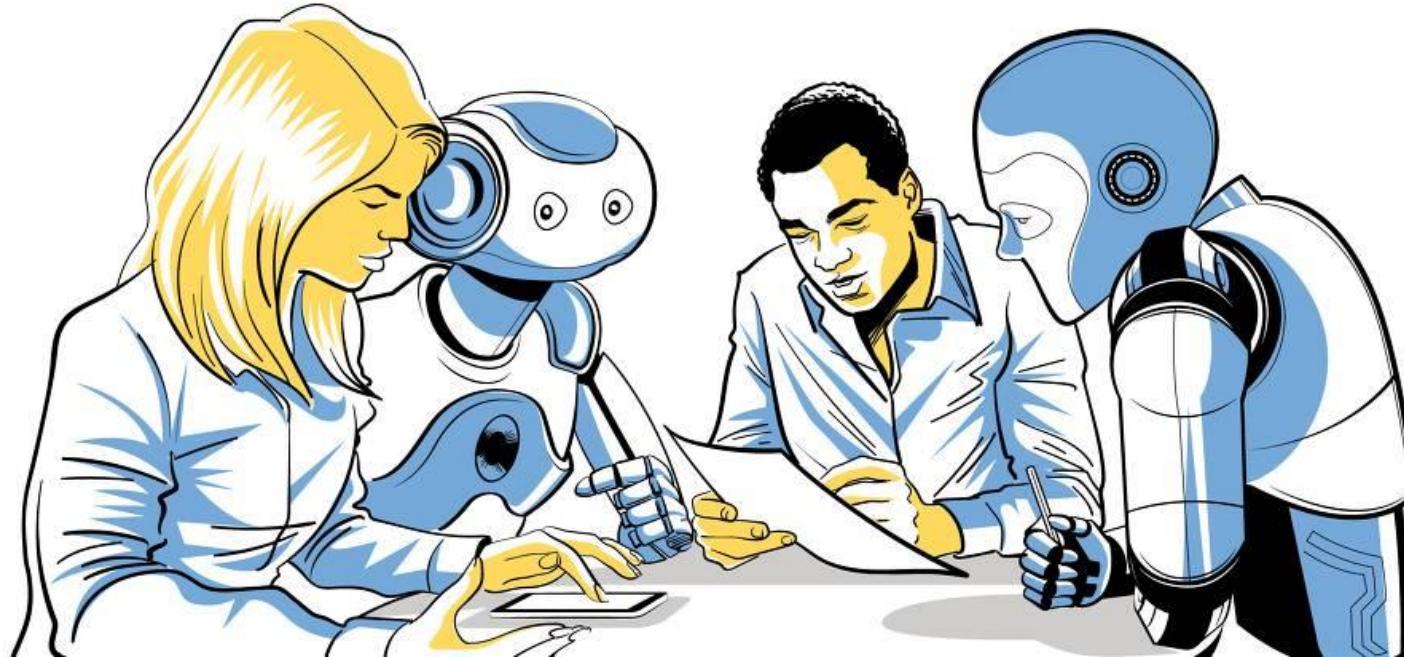
*Machine Learning*

Prof. Dr. Diego Bruno



# De onde veio a idéia de ensinar uma máquina? (*Machine Learning*)

*Machine Learning*



# Buscando inspiração na Natureza

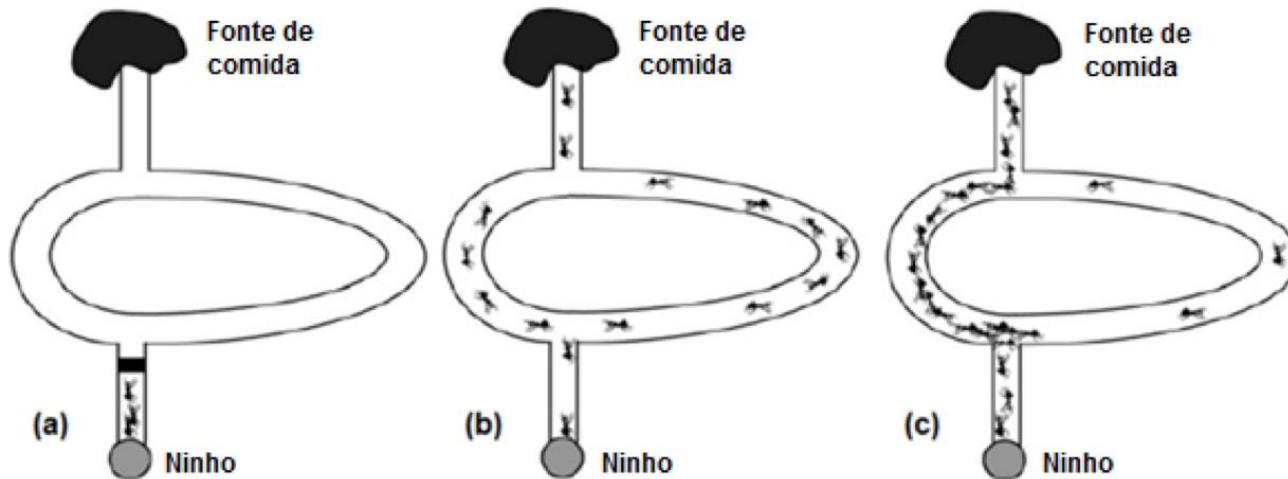


# O que são Algoritmos Bioinspirados?

- Inspirados no Comportamento de Seres vivos em convivência social;
- Conhecimento Colaborativo/compartilhado;
- Métodos Heurísticos (não determinísticos);
- Buscam a melhor solução global;

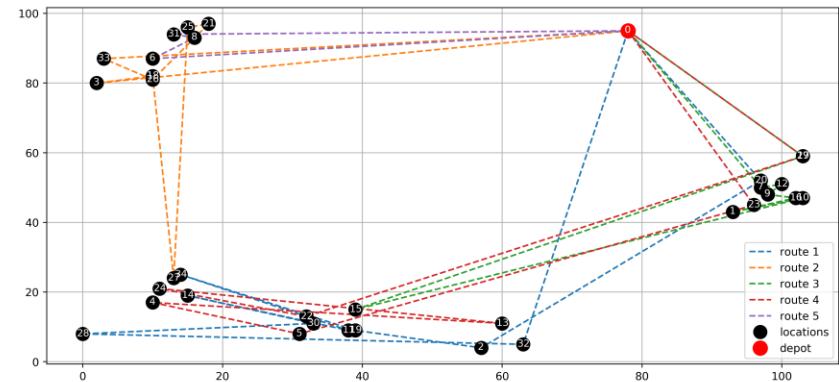
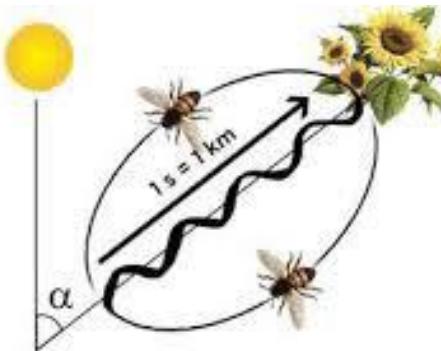
# O que são Algoritmos Bioinspirados?

## Colônia de Formigas



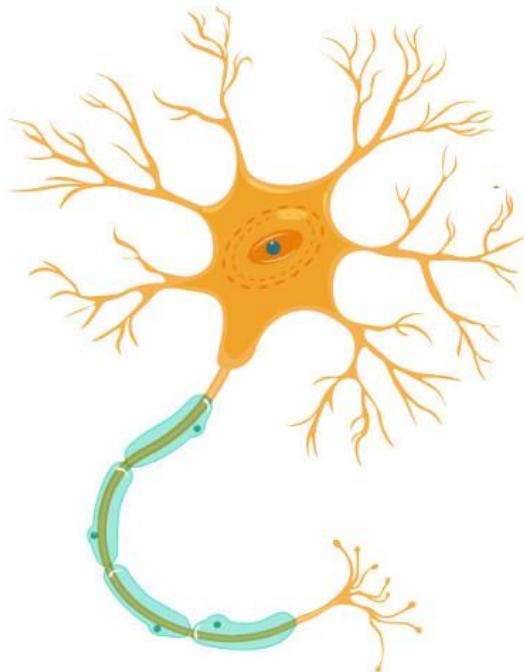
# O que são Algoritmos Bioinspirados?

## Colônia de Abelhas



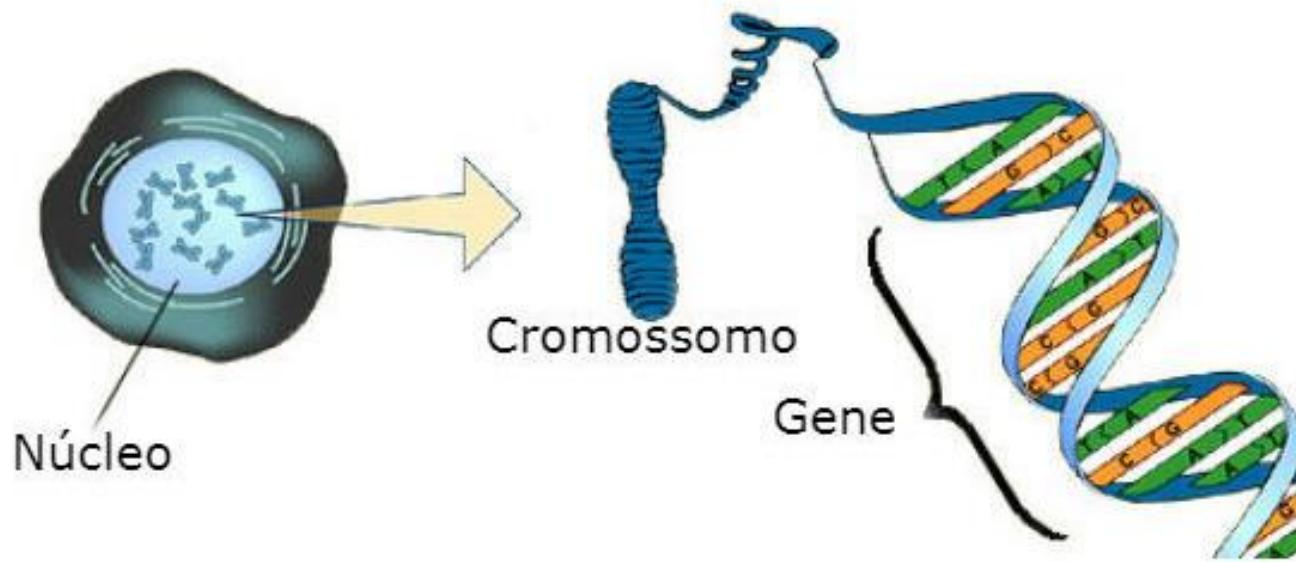
# O que são Algoritmos Bioinspirados?

Redes Neurais



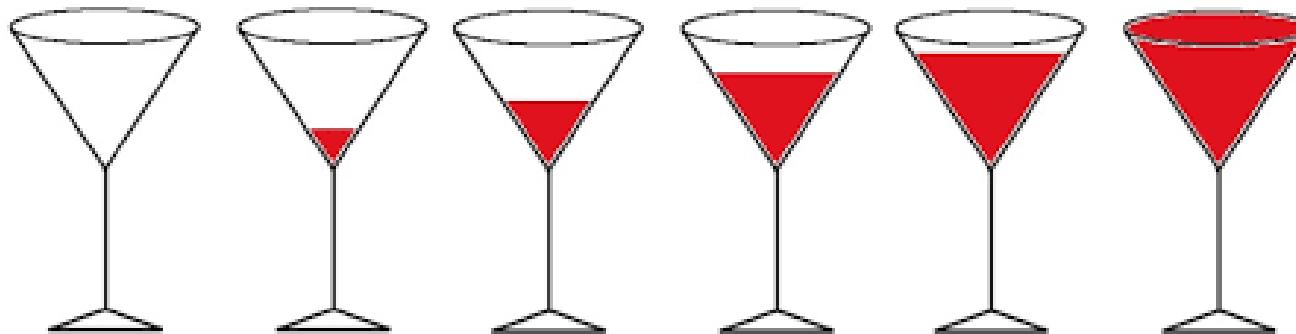
# O que são Algoritmos Bioinspirados?

Genética



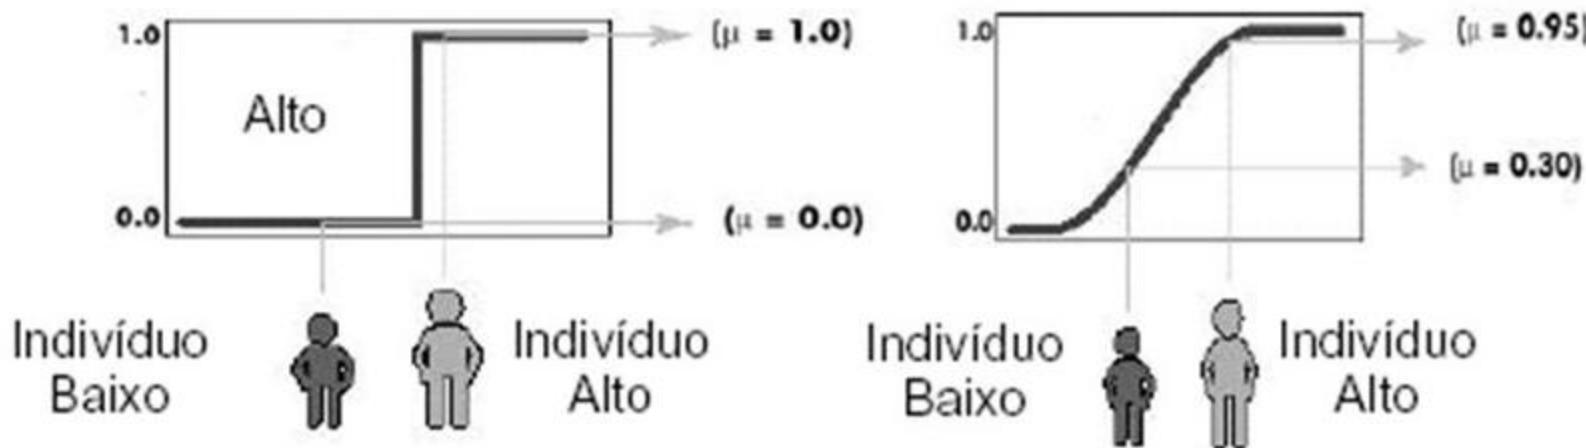
# O que são Algoritmos Bioinspirados?

**Fuzzy:** Qual taça tem bastante vinho?



# O que são Algoritmos Bioinspirados?

Fuzzy: Qual o tamanho de uma pessoa alta?

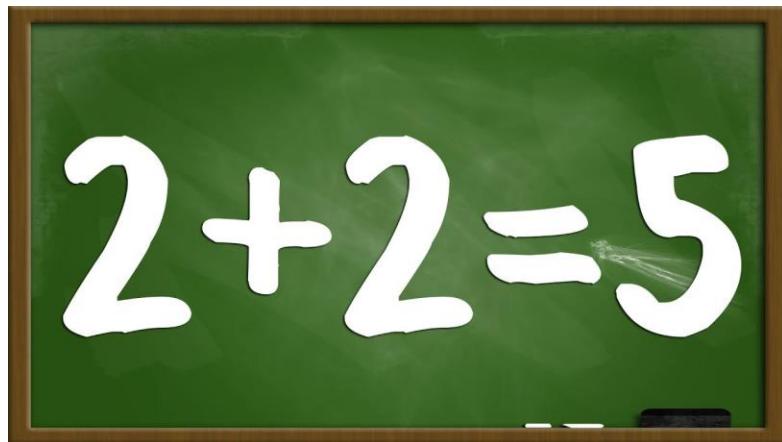


# Algoritmos heurísticos x Determinísticos



# Qual a Diferença entre valores Determinísticos e Heurísticos?

Determinístico



Qual o valor?

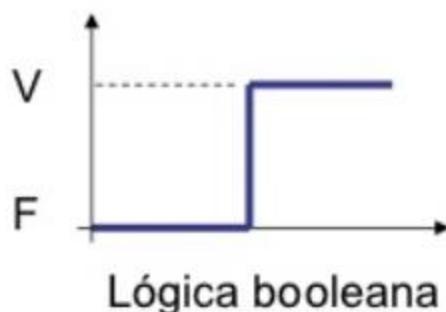
Heurístico



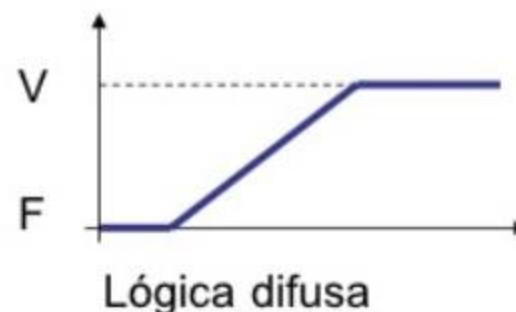
O mais bonito?

# Qual a Diferença entre valores Determinísticos e Heurísticos?

Determinístico

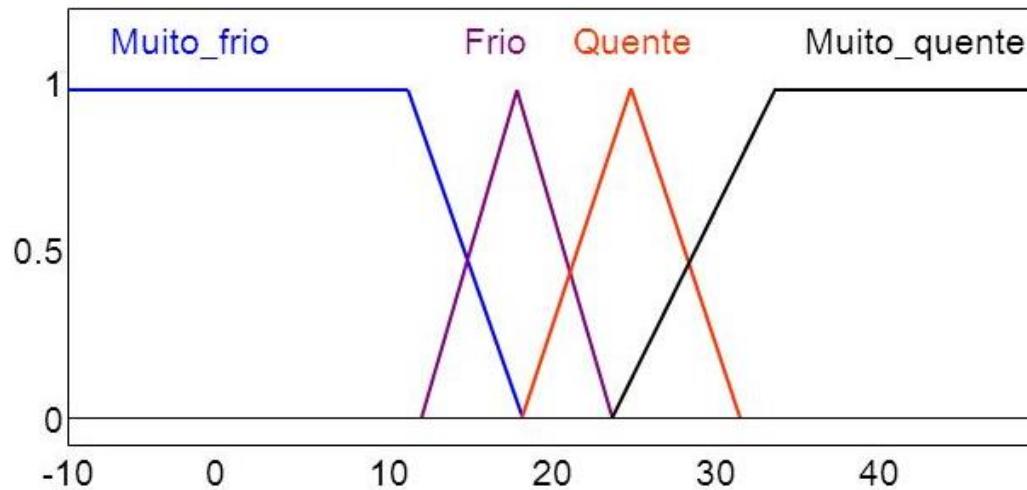


Heurístico



# Qual a Diferença entre valores Determinísticos e Heurísticos?

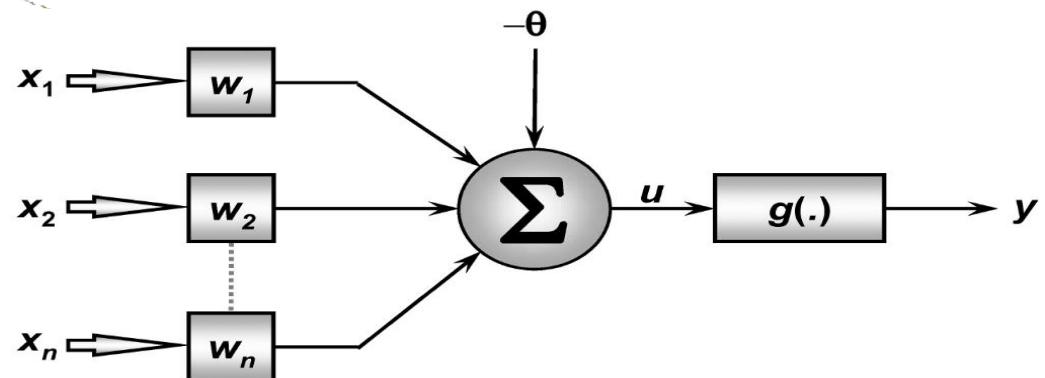
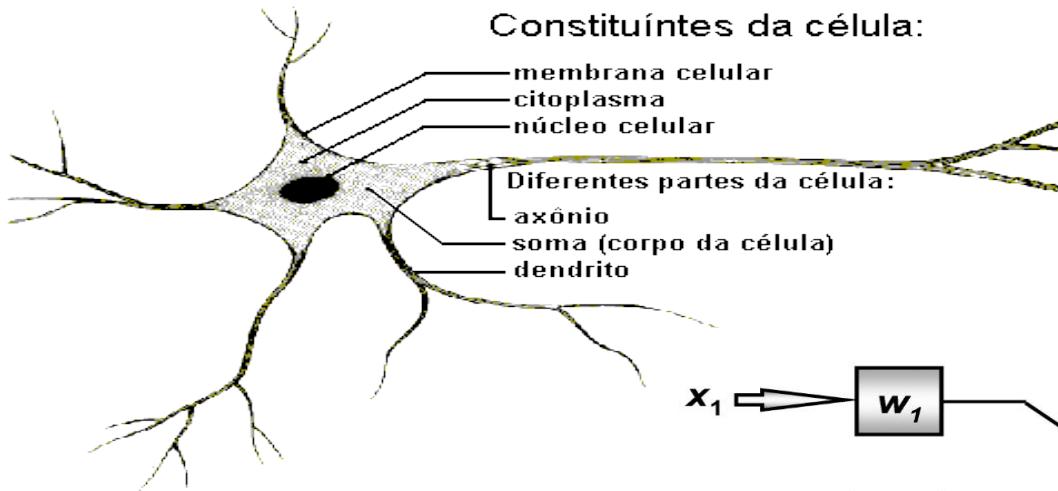
Valores *Fuzzy*:



# Redes Neurais Artificiais



# O que mais usamos: RNA

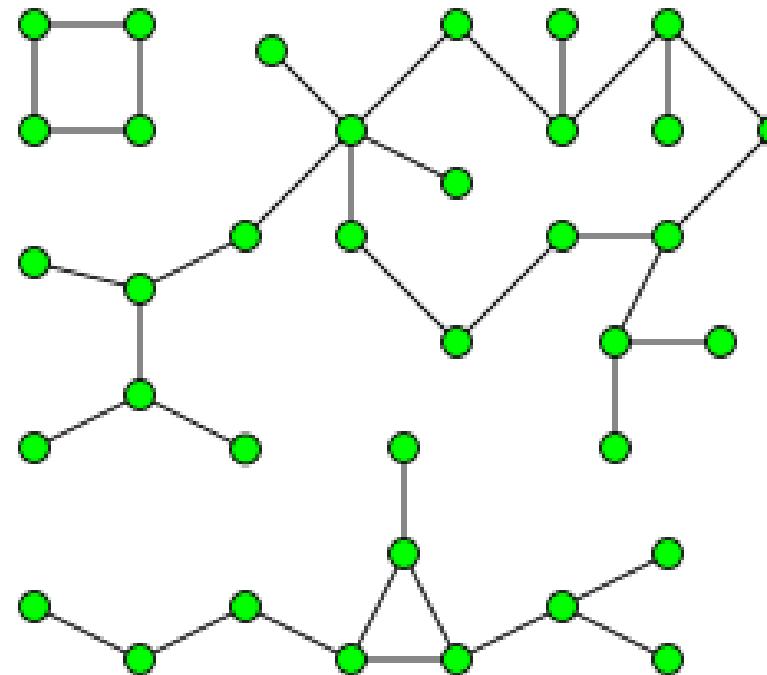


# Aplicações em Sistemas



# Algoritmos de roteamento

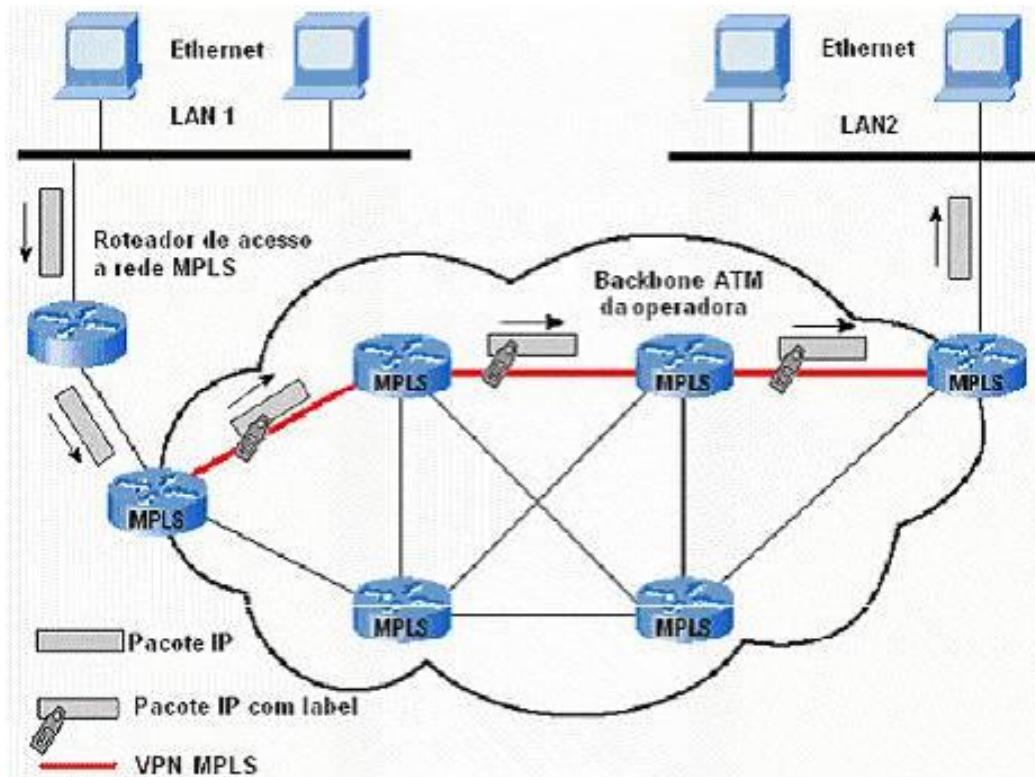
## Robótica



Destino

# Algoritmos de roteamento

## Redes



# Obrigado!

*Machine Learning*

Prof. Dr. Diego Bruno



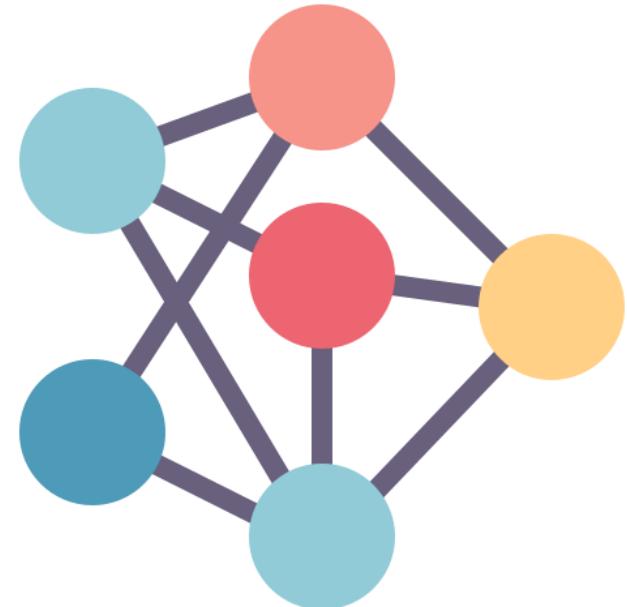
# Redes Neurais Artificiais

## Teoria e Prática

**Prof. Dr. Diego Bruno**

Education Tech Lead na DIO

Doutor em Robótica e *Machine Learning* pelo ICMC-USP



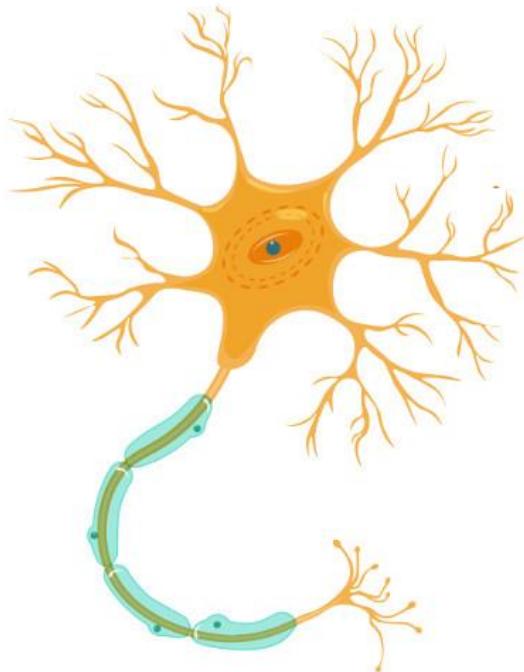
# Redes Neurais

Prof. Dr. Diego Bruno

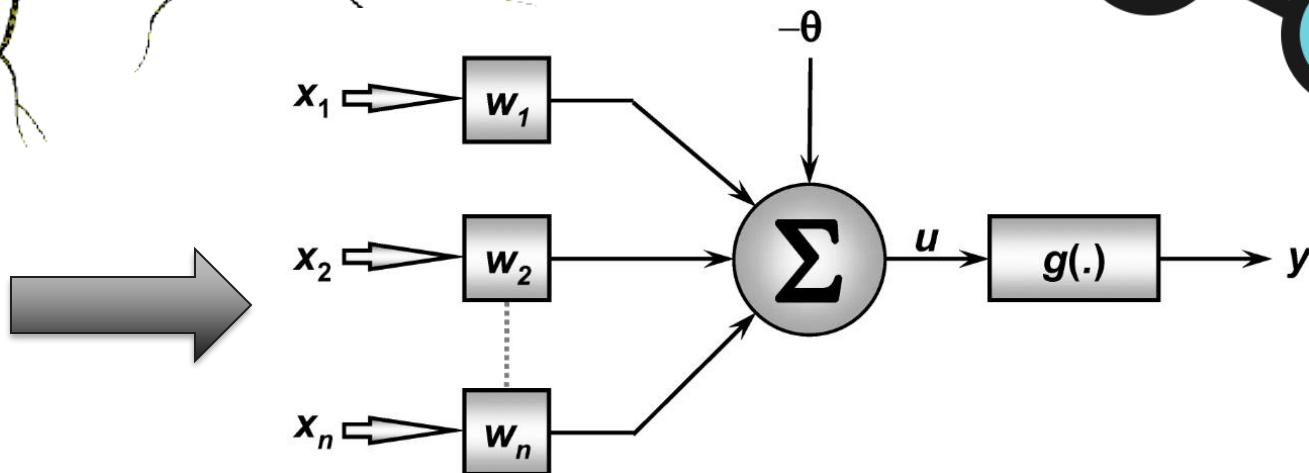
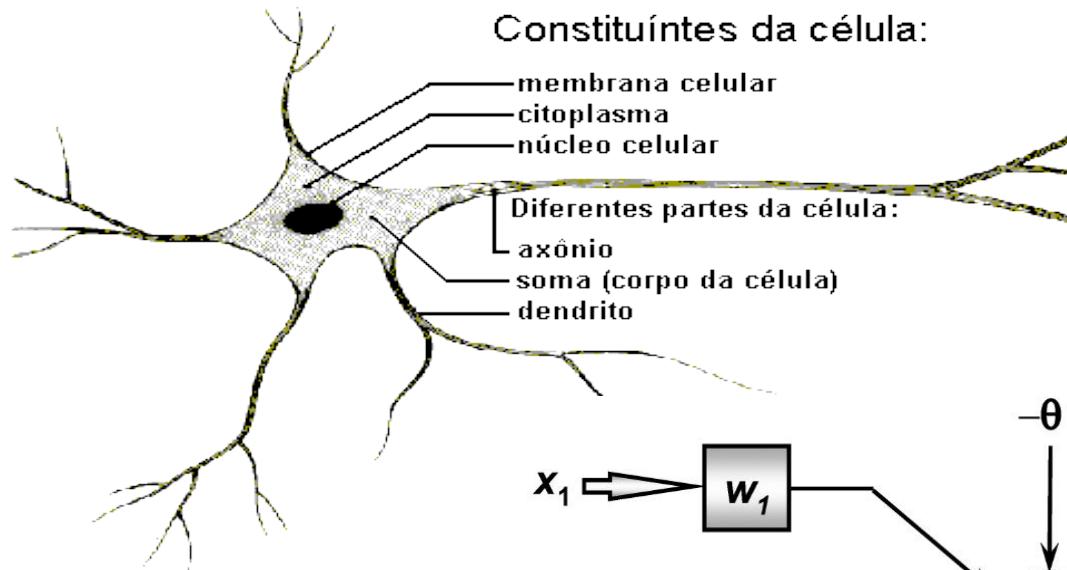


# O que são Redes Neurais?

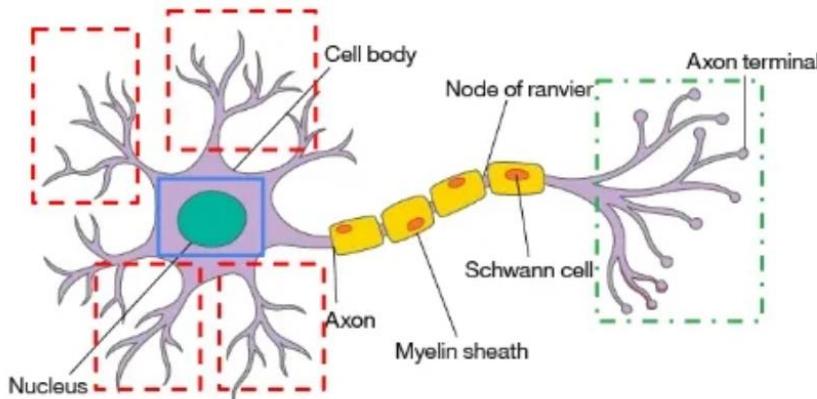
## Redes Neurais



# Qual a estrutura de uma RNA?



# Redes Biológicas x Artificiais



neurônio



dendritos / pesos



núcleo / unidade

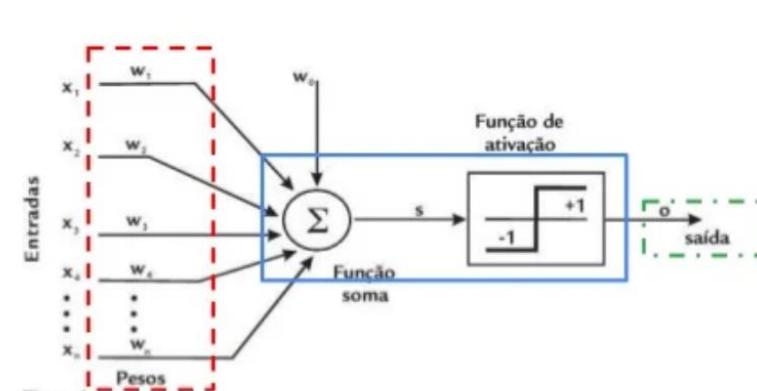


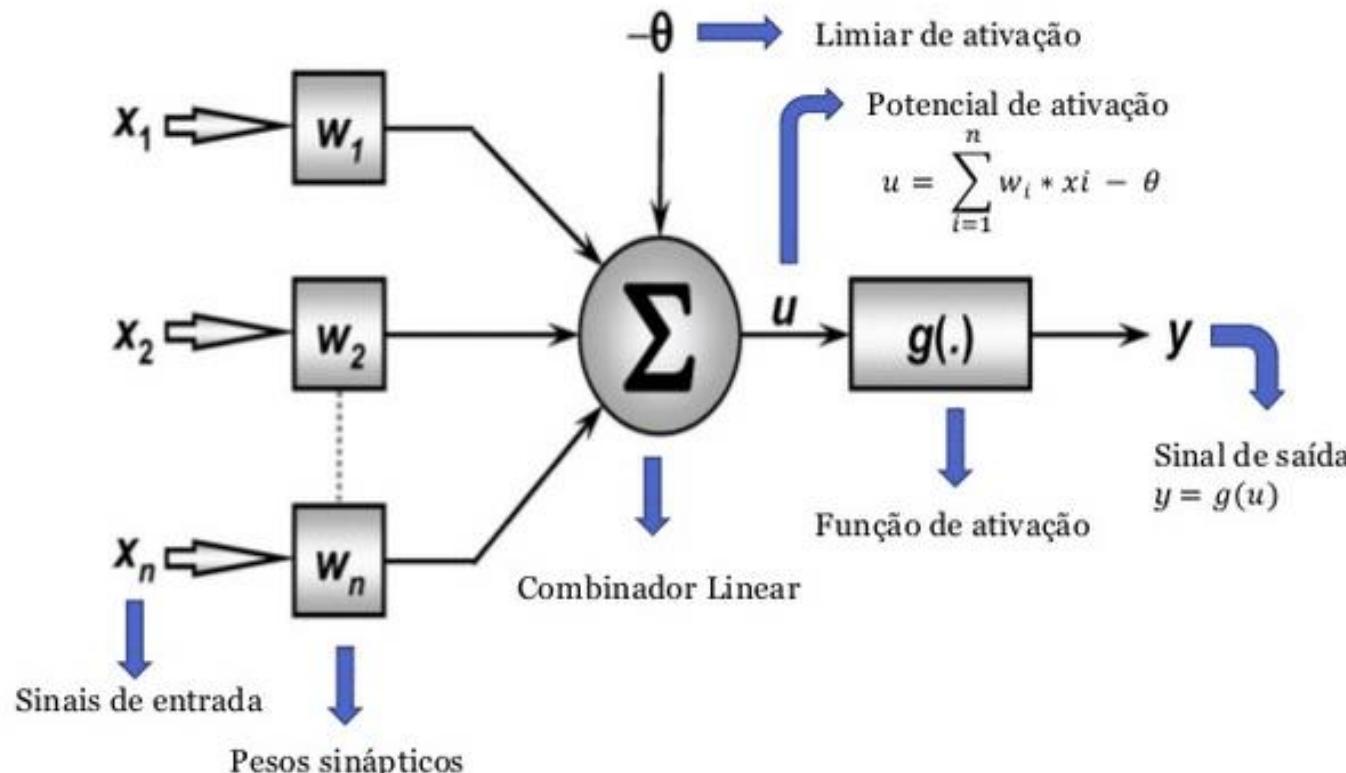
Figura 1  
Modelo de um neurônio perceptron de Rosenblatt. Fonte: Adaptado de Medeiros (2006, p. 3).

neurônio artificial

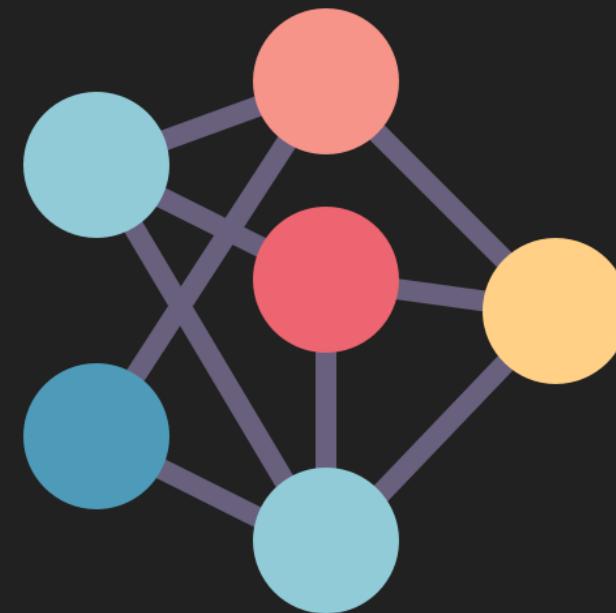


axônio+sinapse / saída

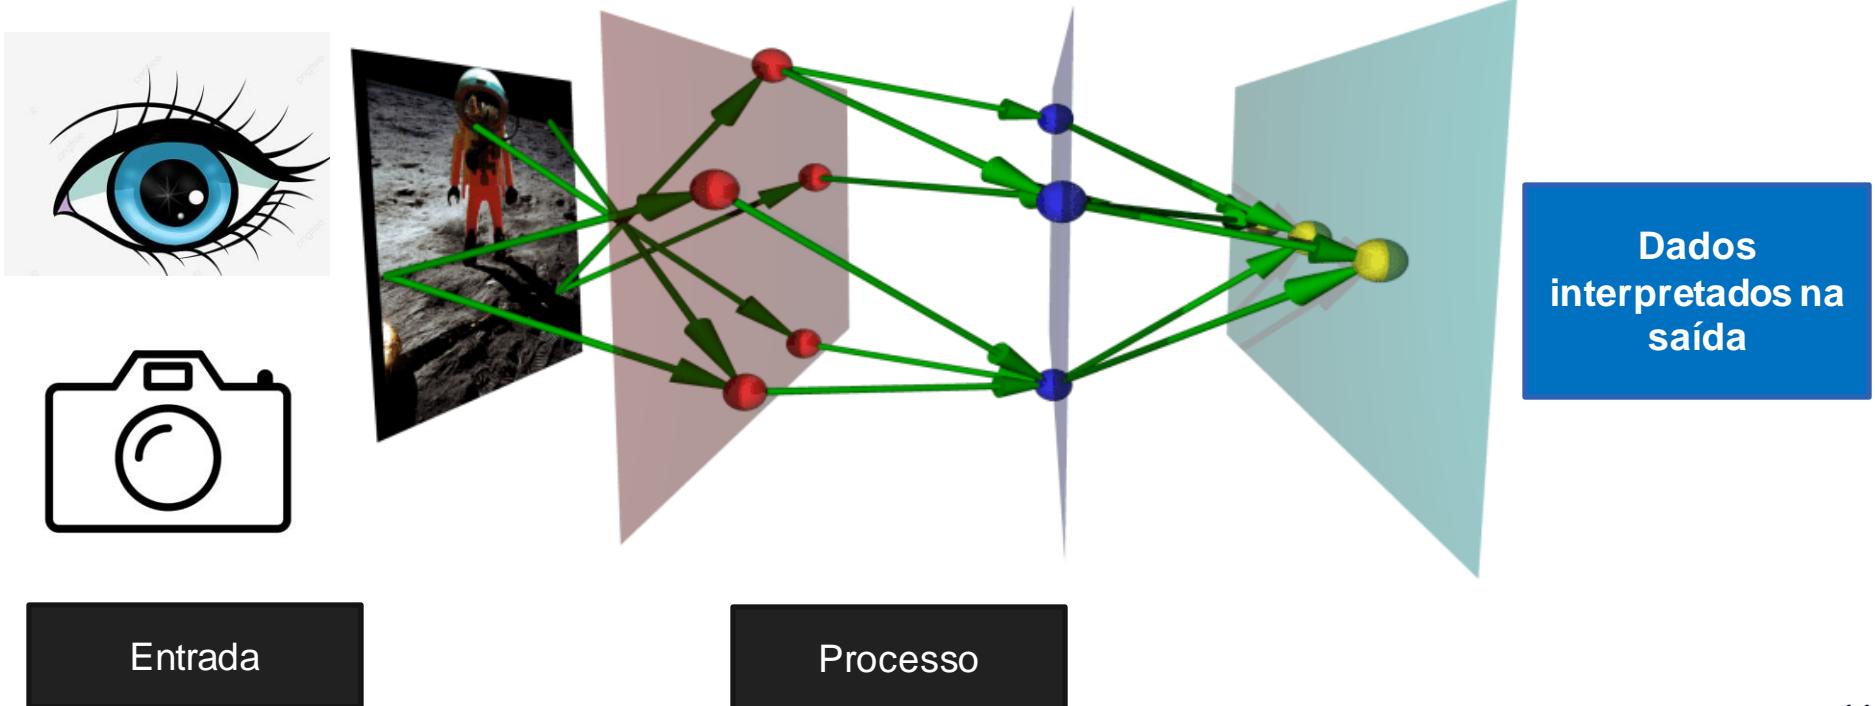
# Neurônio Artificial



# Dados de entrada e saída



# Redes Neurais Biológicas x Artificiais



# Relação de entrada e saída



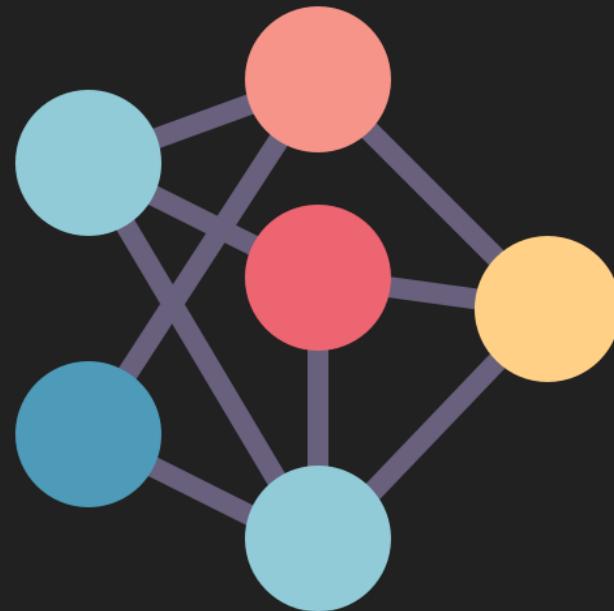
09	02	22	97	38	15	00	40	00	75	04	05	07	78	52	12	50	77	81	00
49	49	99	40	17	81	18	57	60	87	17	40	58	43	69	45	59	56	62	00
81	49	31	73	55	79	14	29	93	71	40	67	53	65	30	03	49	13	36	65
52	70	95	23	04	60	11	42	65	68	56	01	32	56	71	37	02	36	91	00
22	31	16	71	51	67	03	89	41	92	36	54	22	40	40	28	66	33	13	80
24	47	11	60	99	03	45	02	44	75	33	53	78	36	84	20	35	17	12	50
32	98	81	28	64	23	67	10	26	38	40	67	59	54	70	66	18	38	64	70
67	26	20	68	02	62	12	20	95	63	94	39	63	08	40	91	66	49	94	21
24	55	58	05	66	73	99	26	97	17	78	78	96	83	14	88	34	69	63	72
21	36	23	09	75	00	76	44	20	45	35	14	00	61	33	97	34	31	33	95
78	17	53	28	22	75	31	67	15	94	03	80	04	62	16	14	09	53	56	92
16	39	05	42	96	35	31	47	55	58	88	24	00	17	54	24	36	29	85	57
86	56	00	48	35	71	89	07	05	44	44	37	44	60	21	58	51	54	17	58
19	80	81	68	05	94	47	69	28	73	92	13	86	52	17	77	04	69	55	40
04	52	08	83	97	35	99	16	07	97	57	32	16	26	26	79	33	27	98	66
03	46	68	87	57	62	20	72	03	46	33	67	46	55	12	32	63	93	53	69
04	42	16	73	35	35	39	11	24	94	72	18	08	46	29	32	40	62	76	36
20	69	36	41	72	30	23	88	34	68	09	69	82	67	59	85	74	04	36	16
20	73	35	29	78	31	90	01	74	31	49	73	49	05	01	16	23	57	05	54
01	70	54	71	83	51	54	69	16	92	33	48	61	43	52	01	89	21	67	45

Dados gerados

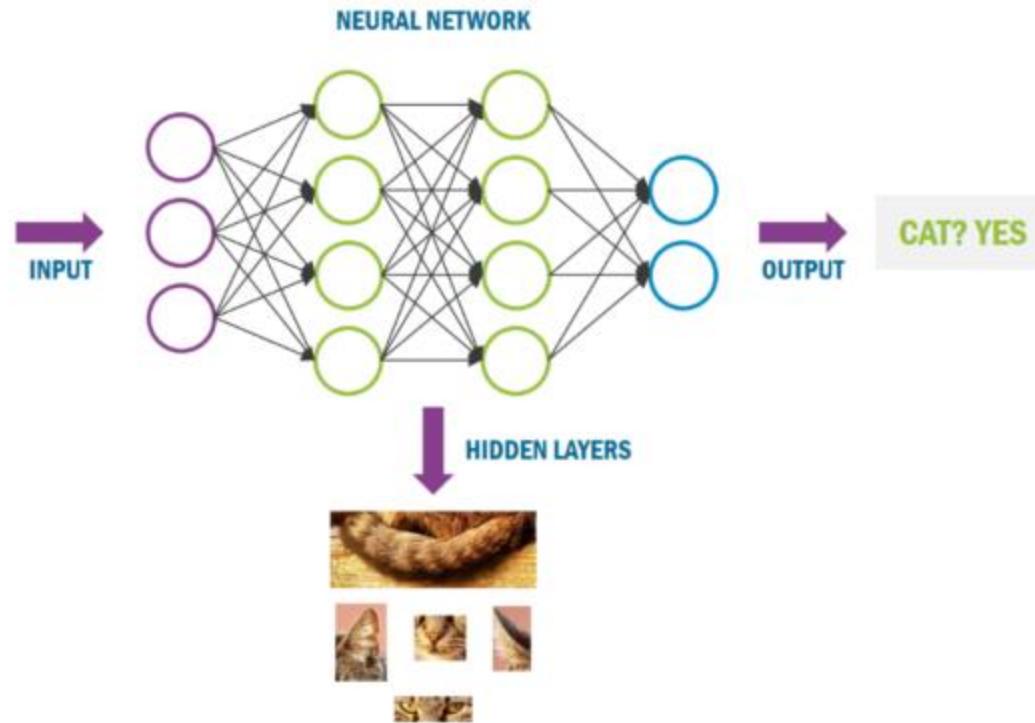


Imagen de Entrada

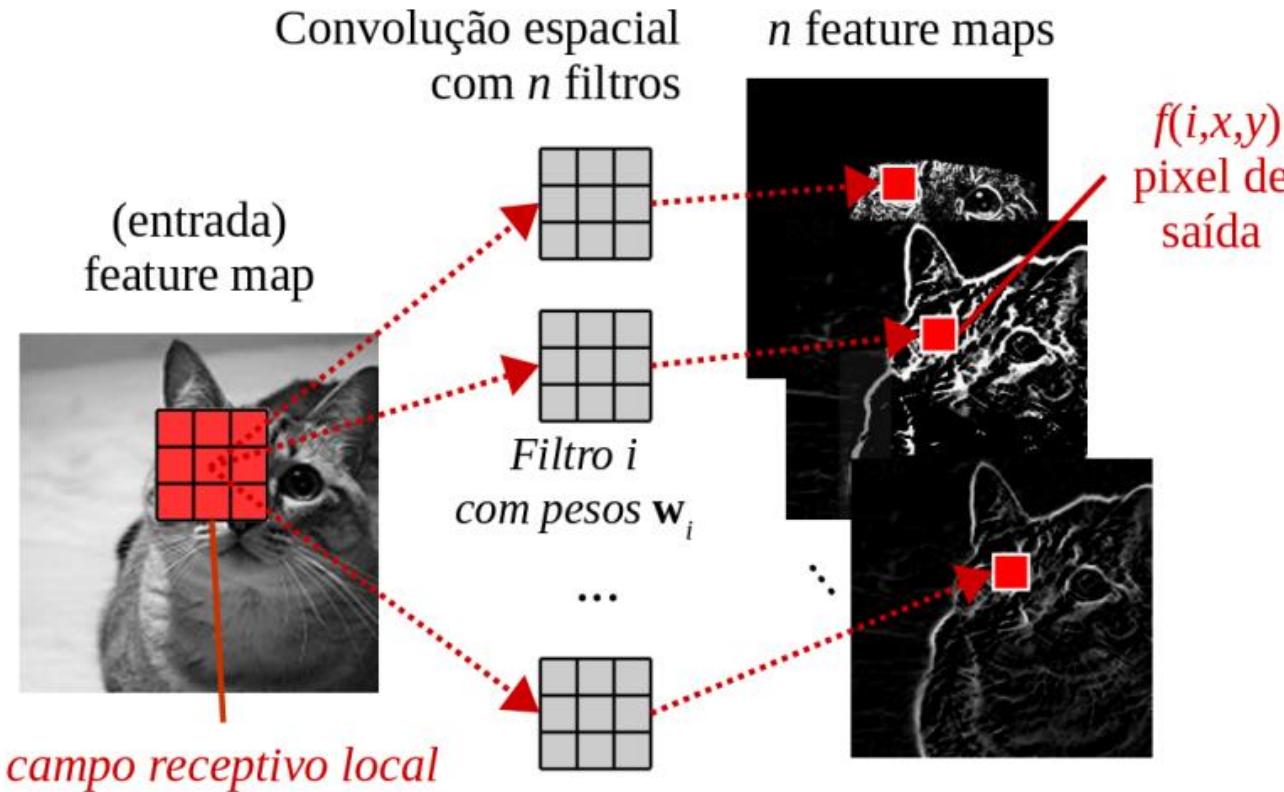
# Análise de Características (*Features*)



# Redes Neurais Artificiais

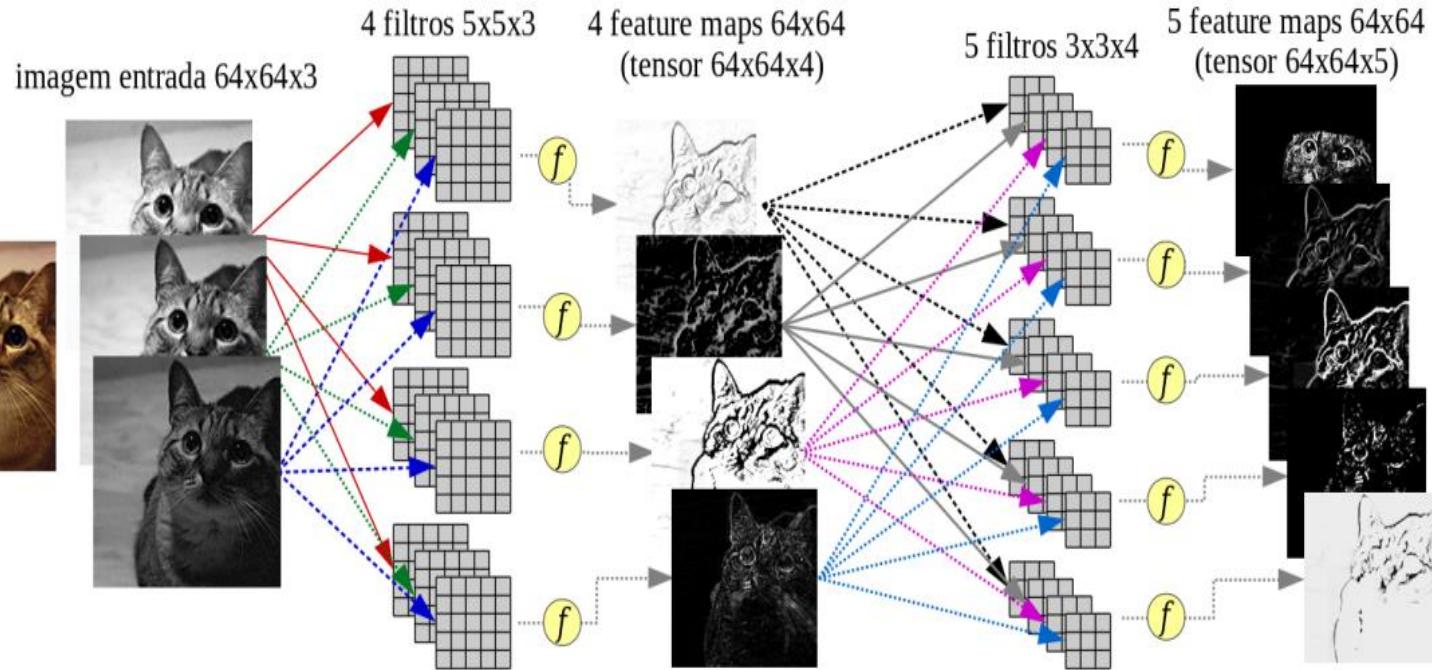


# Dados a serem interpretados

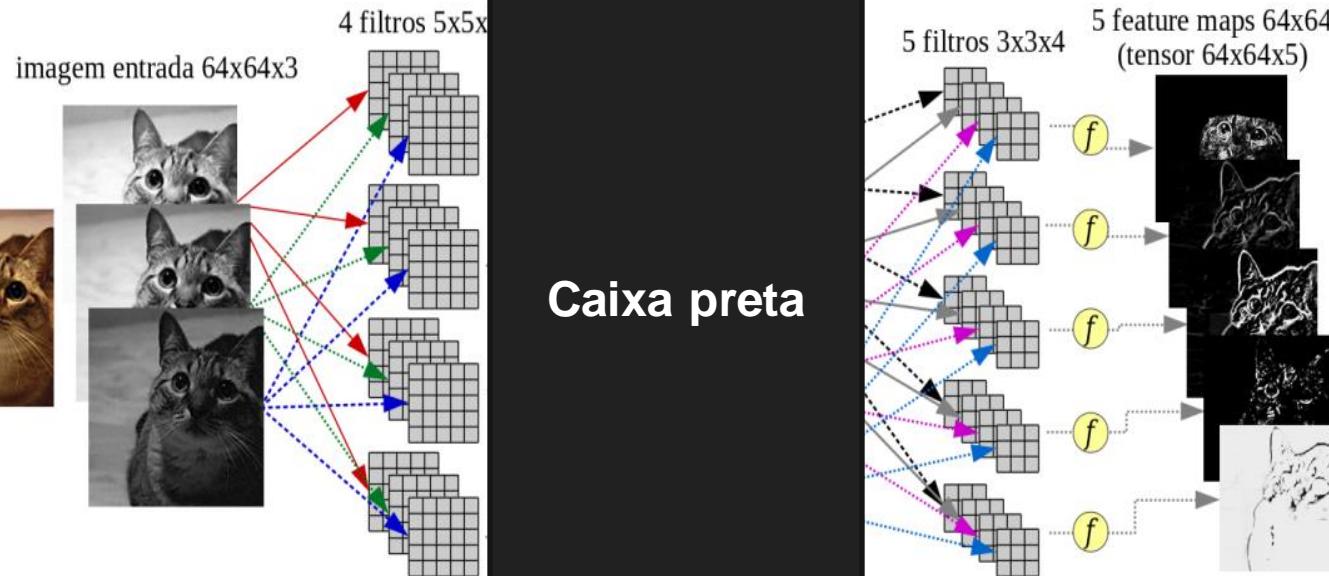


# Análise de características (features)

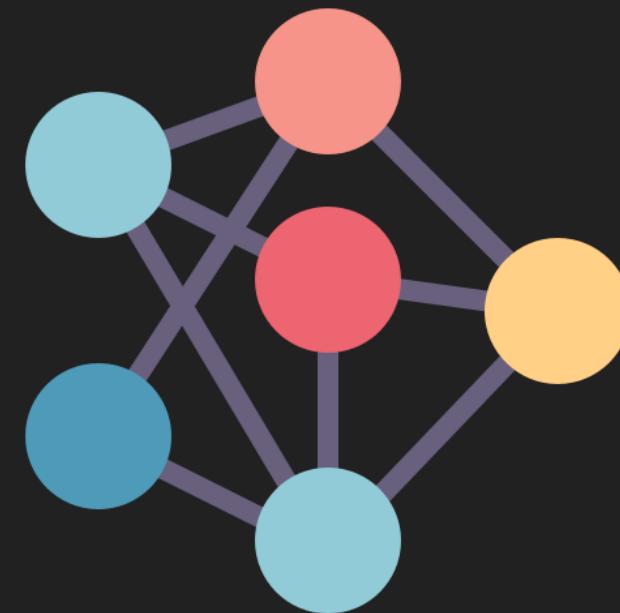
bio.-



# Caixa preta gerada no treino



# Mas como são as *Features*?

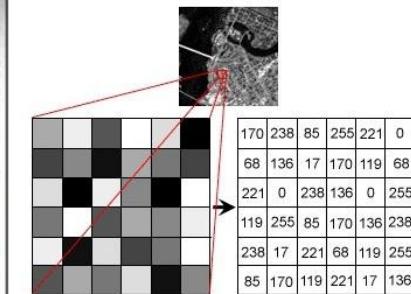
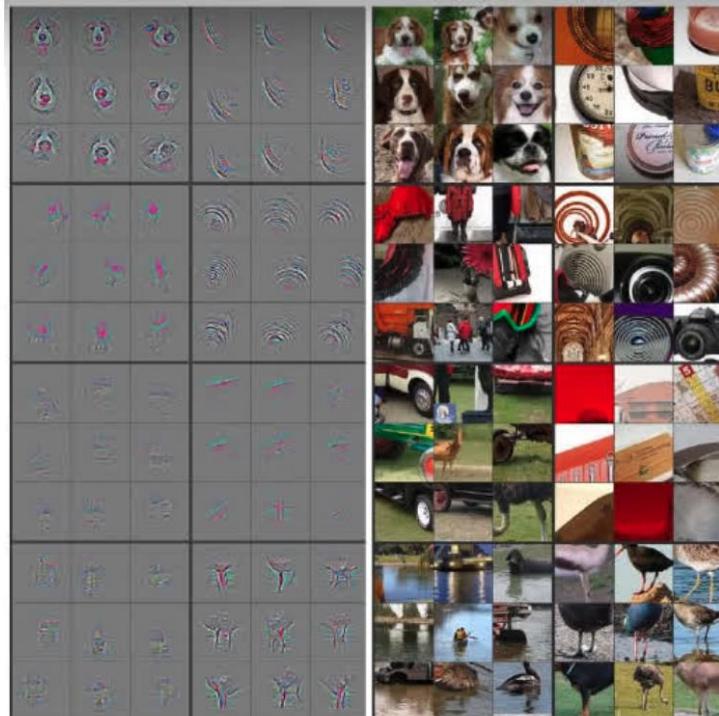


# Como são as features?

faces

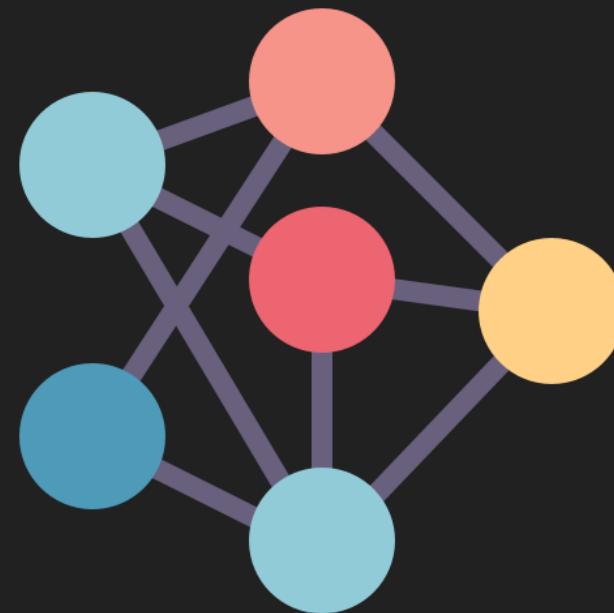


Outros Objetos

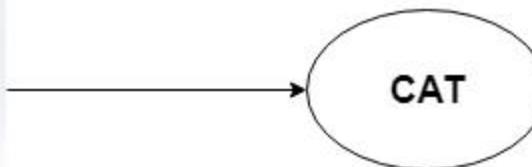


$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

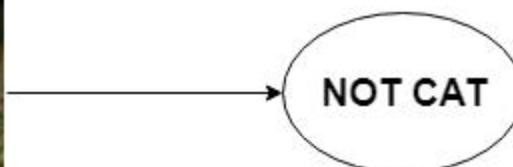
# Classificação



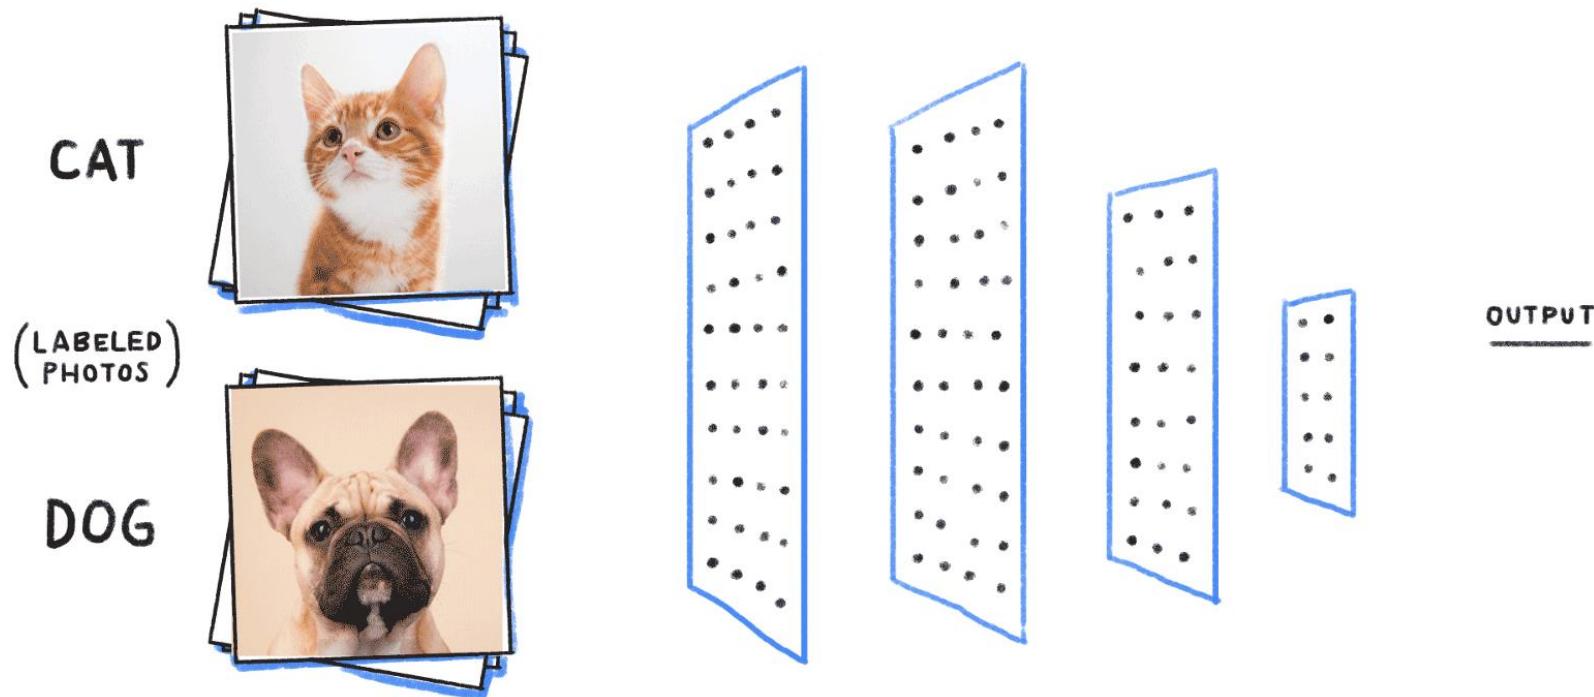
# Classificação de objetos



Aqui temos duas classes



# Dados a serem interpretados



# Dados a serem interpretados

Entrada



Rótulo

CAT

Classificação



NOT CAT



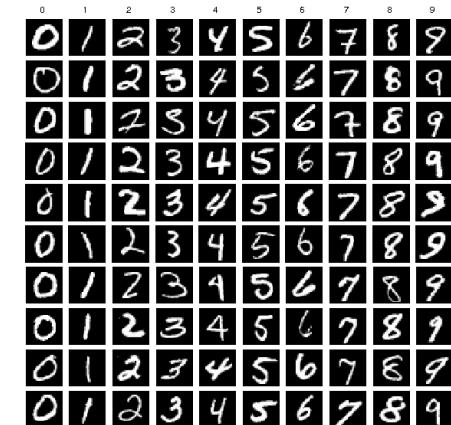
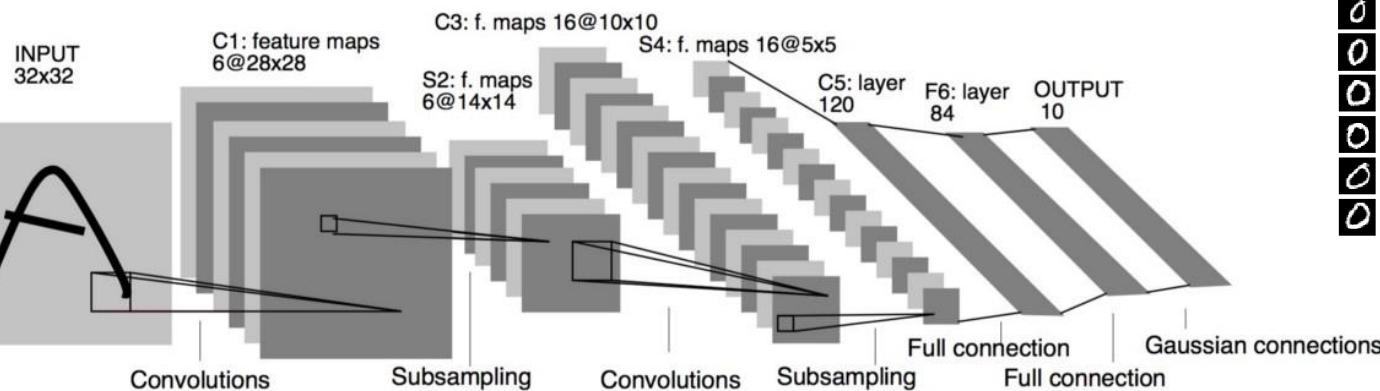
?



CAT

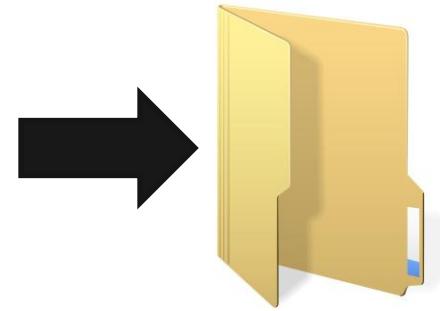
# Classificação de objetos

## Mnist Dataset



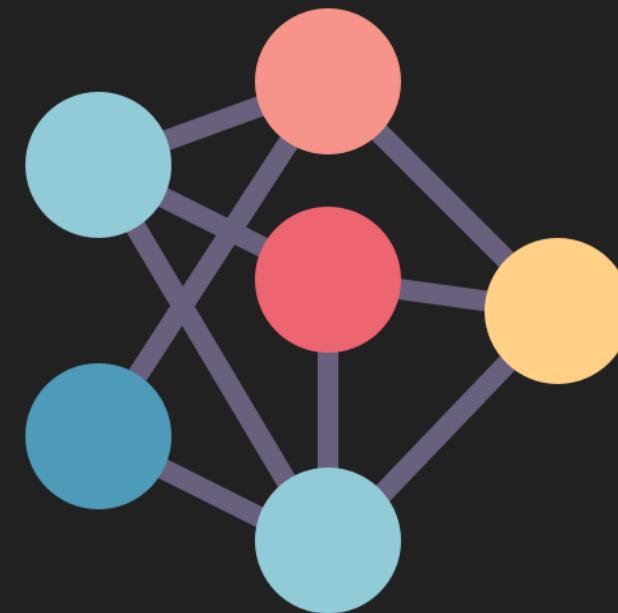
Aqui temos 9 classes

# DATASET – Base de treino



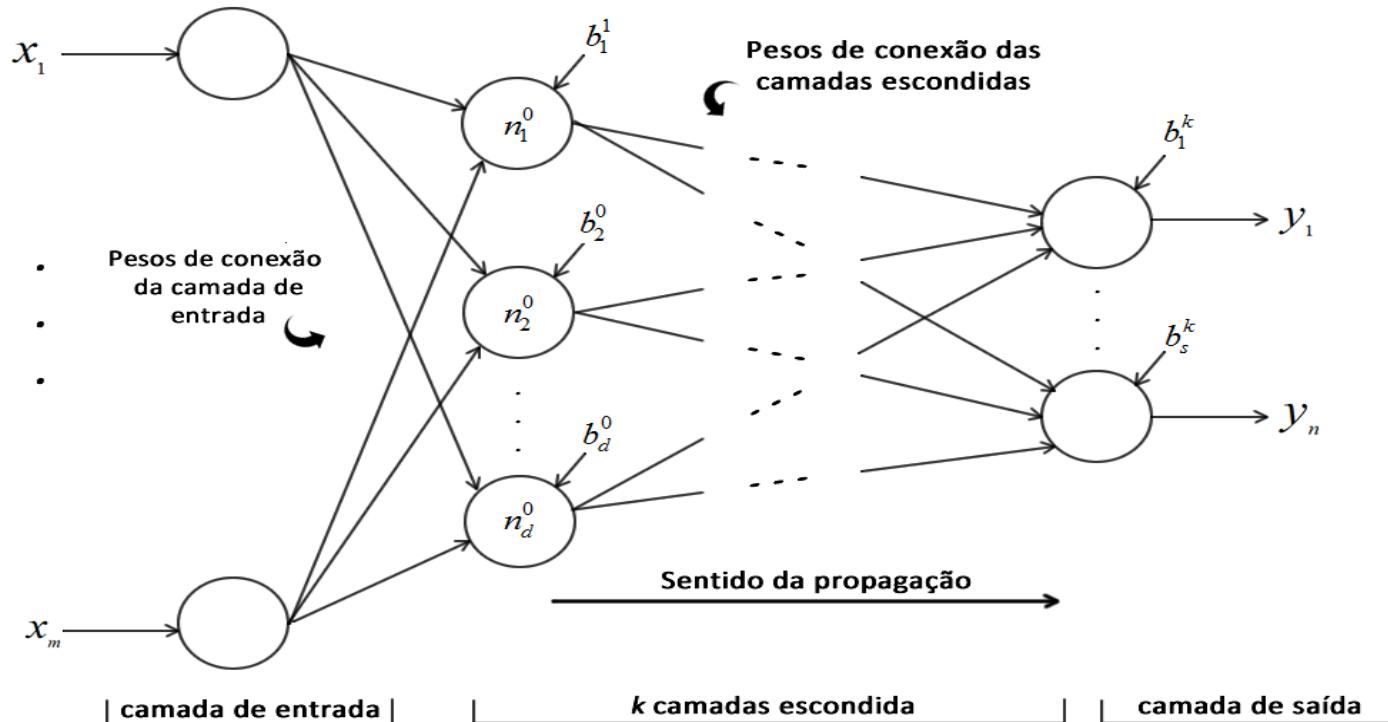
Classe “gatos”

# Mas o que gera um Treinamento?



# Dados de aprendizado

## Pesos gerados no treinamento



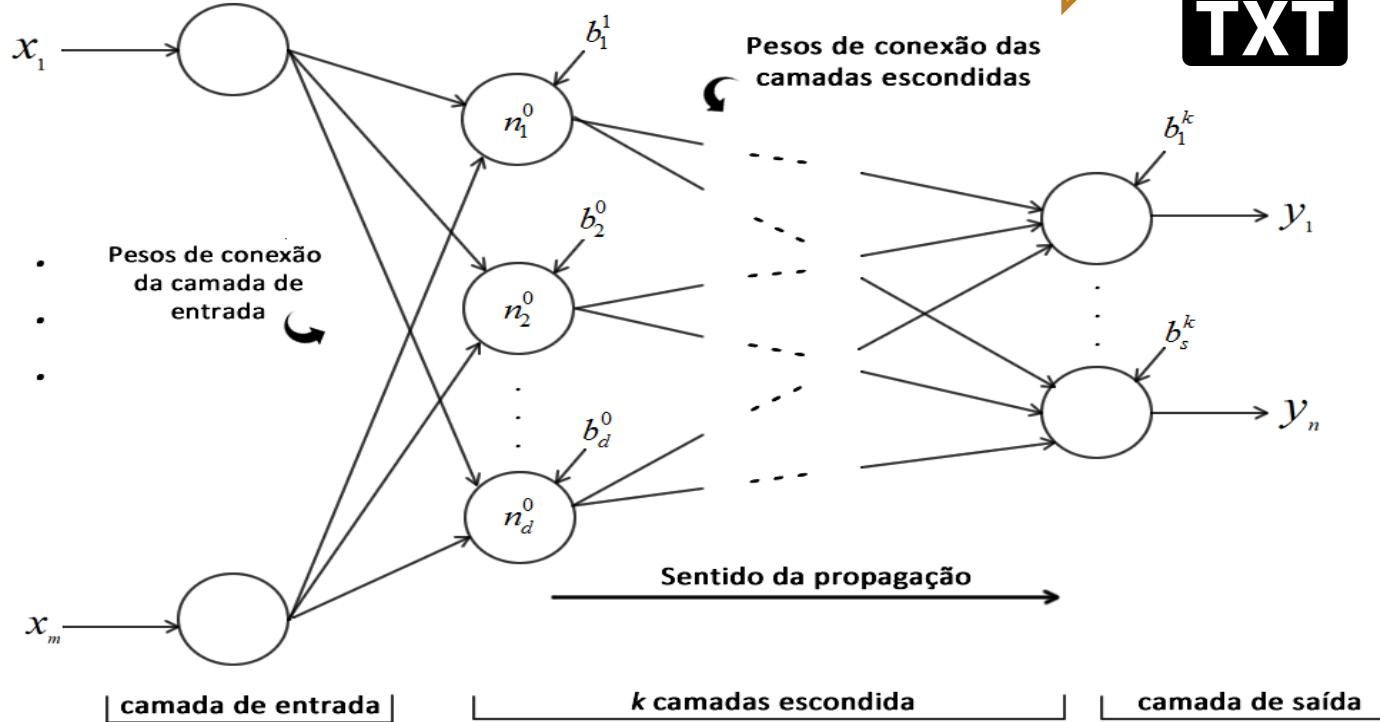
# Dados de aprendizado

## Arquivos de pesos



# Modelo de treinamento

## Arquivos de pesos



# Modelo de treinamento

Pesos gerados em uma rede



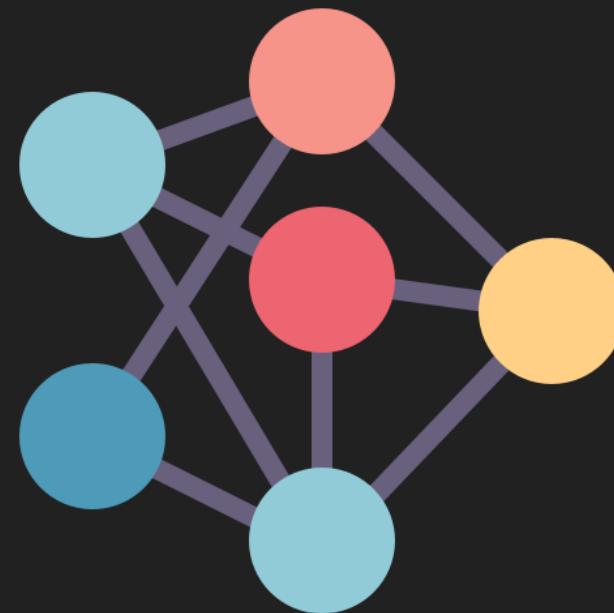
pesos - Bloco de notas

```
-163.8
-135.394
-55.5981
138.008
-2.99415
0.00479873
8.2035
38.409
-86.1918
0.207466
143.202
-130.191
-73.5929
-21.1949
```

saída - Bloco de notas

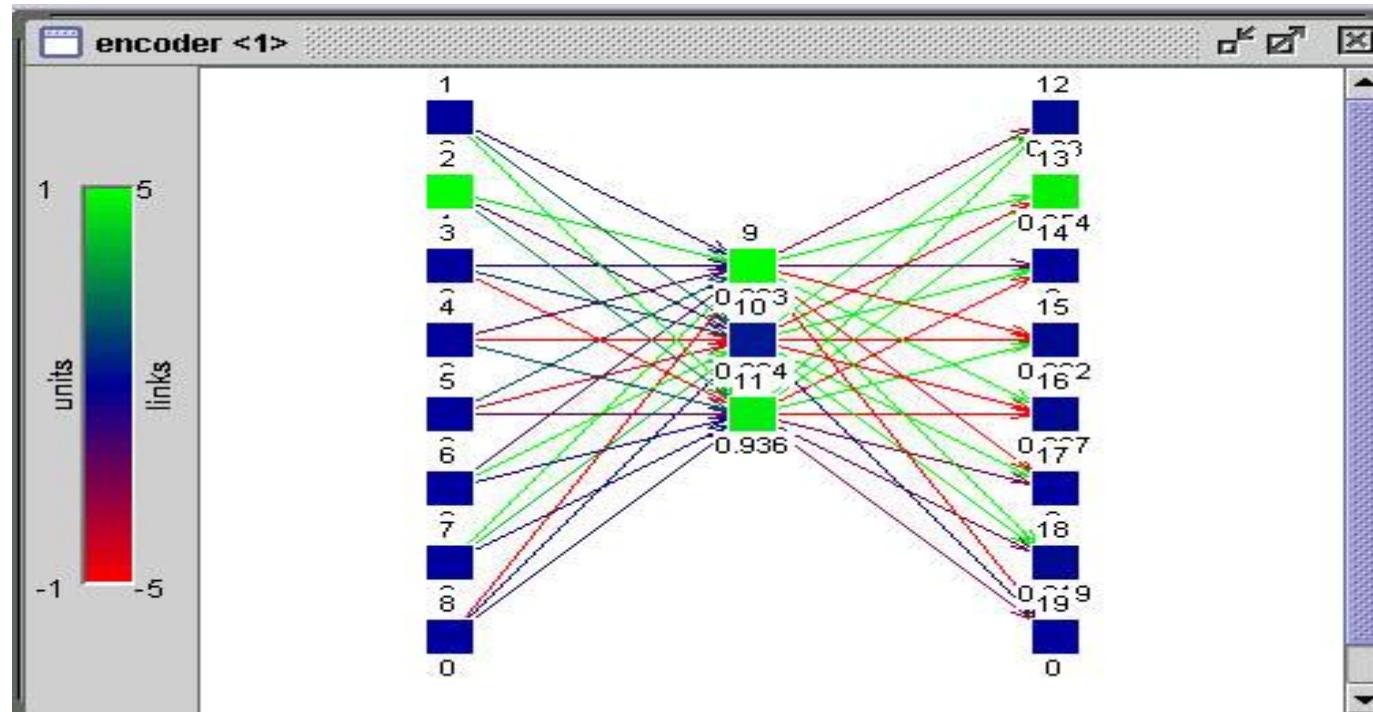
```
-1
-1
1
-1
```

# Algoritmo



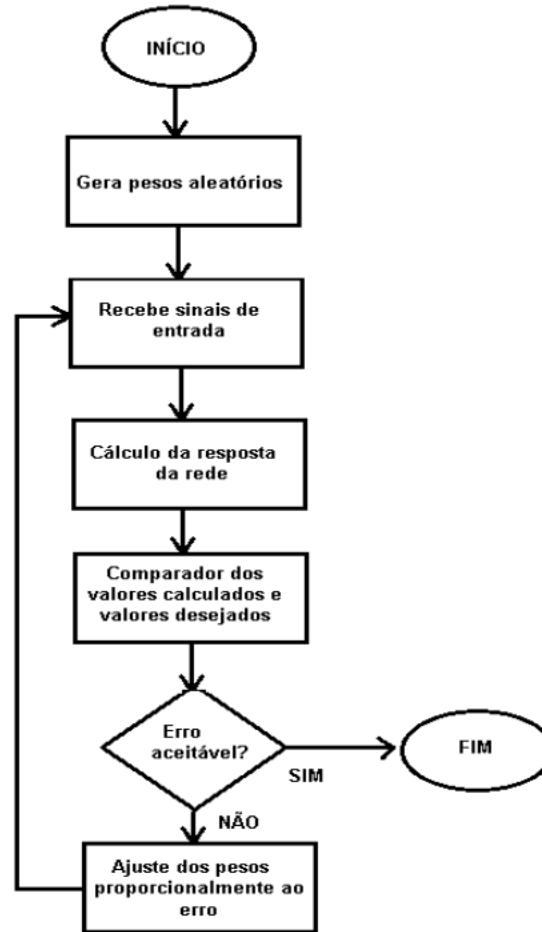
# Modelo de treinamento

Relação dos pesos



# Algoritmo

```
31     def __init__(self, path=None, debug=False):
32         self.file = None
33         self.fingerprints = set()
34         self.logdups = True
35         self.debug = debug
36         self.logger = logging.getLogger(__name__)
37         if path:
38             self.file = open(os.path.join(path, 'fingerprints'), 'r')
39             self.file.seek(0)
40             self.fingerprints.update(self.file.read().split())
41
42     @classmethod
43     def from_settings(cls, settings):
44         debug = settings.getbool('DEBUG', False)
45         return cls(job_dir(settings), debug)
46
47     def request_seen(self, request):
48         fp = self.request_fingerprint(request)
49         if fp in self.fingerprints:
50             return True
51         self.fingerprints.add(fp)
52         if self.file:
53             self.file.write(fp + os.linesep)
54
55     def request_fingerprint(self, request):
56         return request_fingerprint(request)
```



# Importando Modelos de RNA

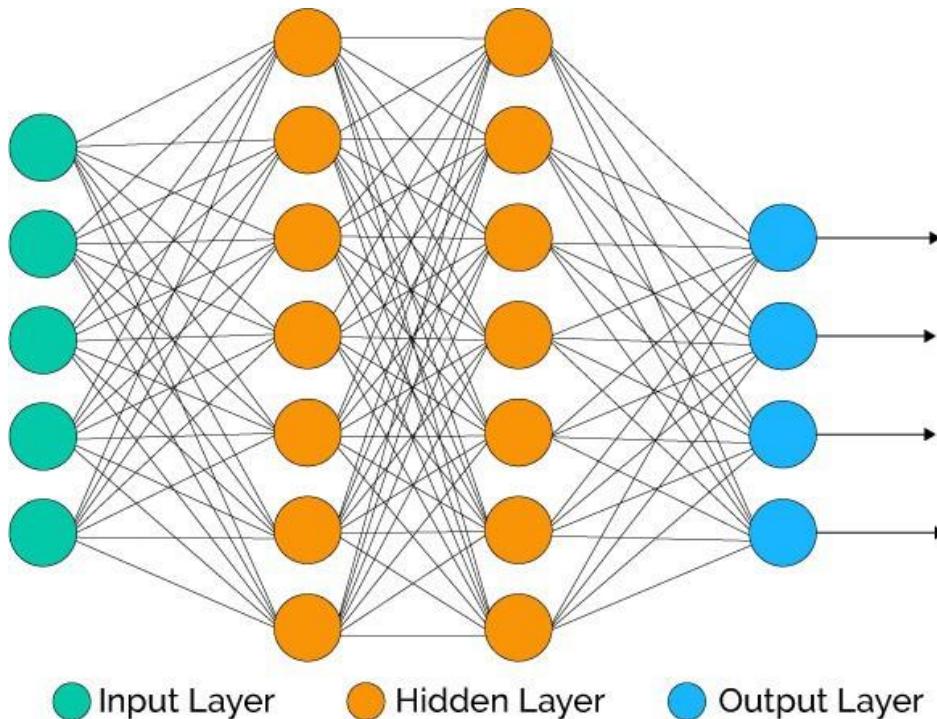
Classify ImageNet classes with ResNet50

```
from tensorflow.keras.applications.resnet50 import ResNet50
from tensorflow.keras.preprocessing import image
from tensorflow.keras.applications.resnet50 import preprocess_input, decode_predictions
import numpy as np

model = ResNet50(weights='imagenet')

img_path = 'elephant.jpg'
img = image.load_img(img_path, target_size=(224, 224))
x = image.img_to_array(img)
x = np.expand_dims(x, axis=0)
x = preprocess_input(x)
```

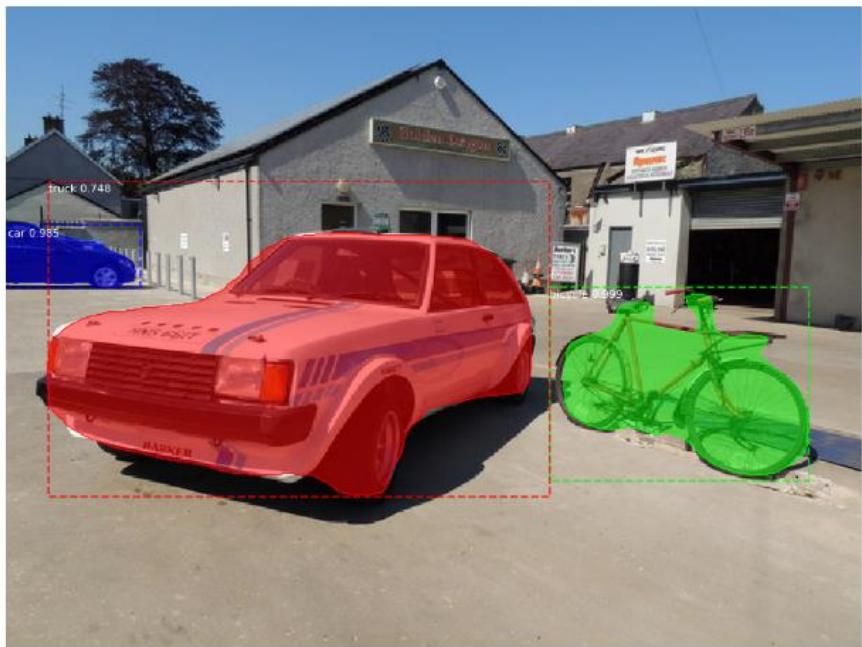
# Exemplo de RNA no COLAB



[https://colab.research.google.com/github/storopoli/ciencia-de-dados/blob/master/notebooks/Aula\\_18\\_a\\_Redes\\_Neurais\\_com\\_TensorFlow.ipynb#scrollTo=6zmMUxg8pfqE](https://colab.research.google.com/github/storopoli/ciencia-de-dados/blob/master/notebooks/Aula_18_a_Redes_Neurais_com_TensorFlow.ipynb#scrollTo=6zmMUxg8pfqE)

# Exemplo de RNA no COLAB

```
Processing 1 images
image          shape: (480, 640, 3)      min:  0.00000  max: 255.00000  uint8
molded_images   shape: (1, 1024, 1024, 3)  min: -123.78000  max: 151.10000  float64
image_metas     shape: (1, 93)           min:  0.00000  max: 1024.00000  float64
anchors         shape: (1, 261888, 4)      min: -0.35390  max:  1.29134  float32
```



[https://colab.research.google.com/github/tensorflow/tpu/blob/master/models/official/mask\\_rcnn/mask\\_rcnn\\_demo.ipynb#scrollTo=X8rPd4MyrDsn](https://colab.research.google.com/github/tensorflow/tpu/blob/master/models/official/mask_rcnn/mask_rcnn_demo.ipynb#scrollTo=X8rPd4MyrDsn)

# Obrigado!

Prof. Dr. Diego Bruno



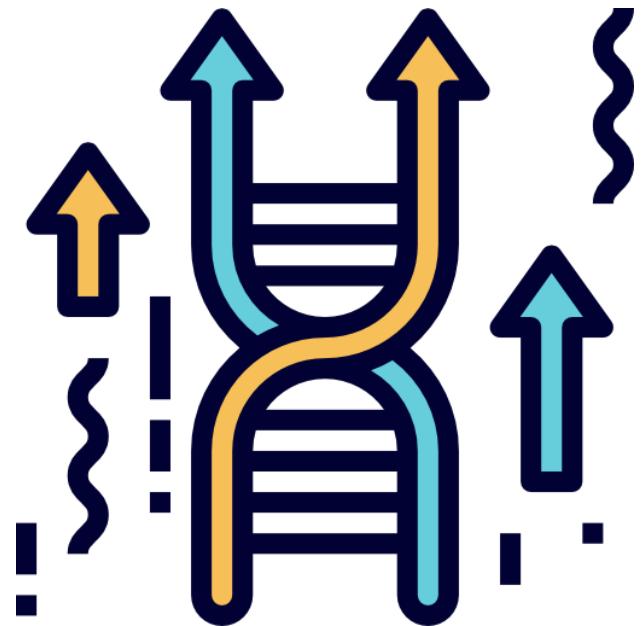
# Algoritmos Genéticos

## Teoria e Prática

**Prof. Dr. Diego Bruno**

Education Tech Lead na DIO

Doutor em Robótica e *Machine Learning* pelo ICMC-USP



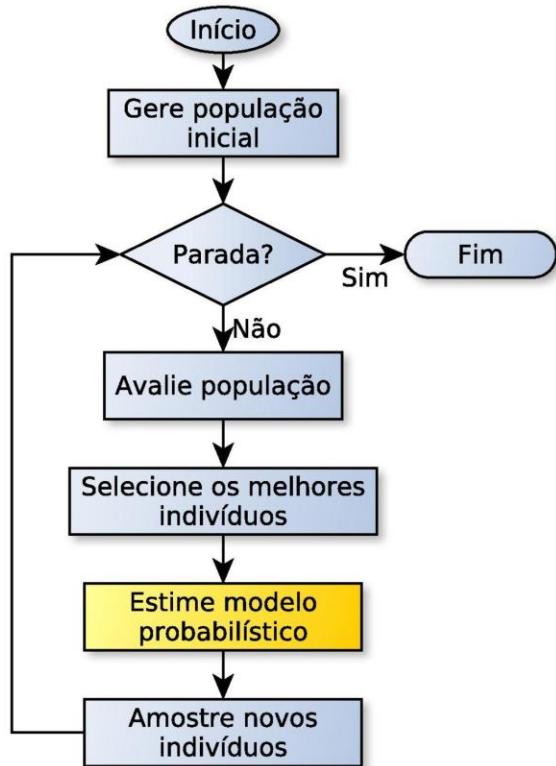
# Algoritmos Genéticos

Prof. Dr. Diego Bruno

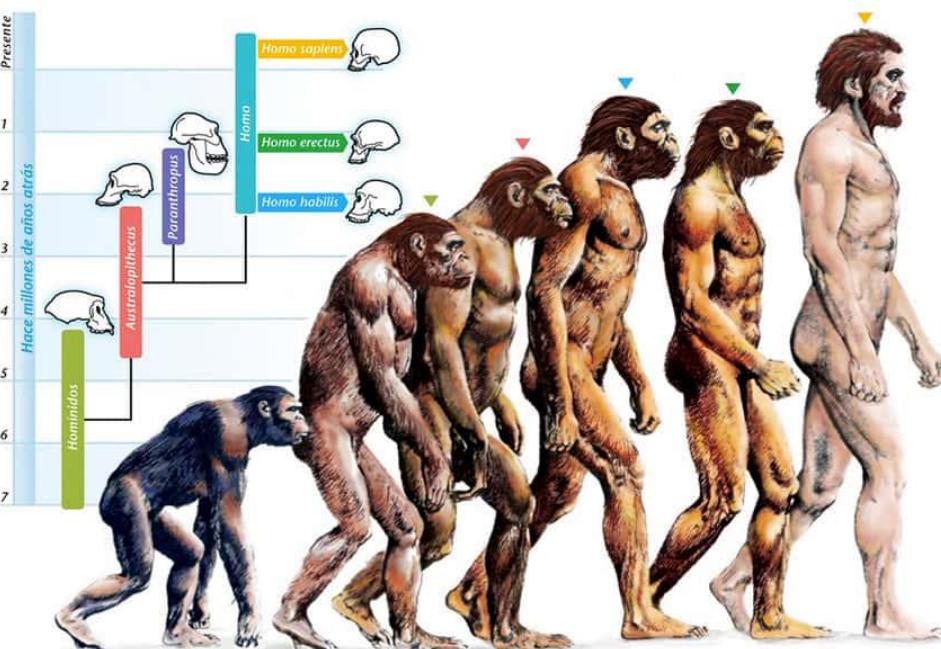


# O que são Algoritmos Genéticos?

## Algoritmo genético (AG)

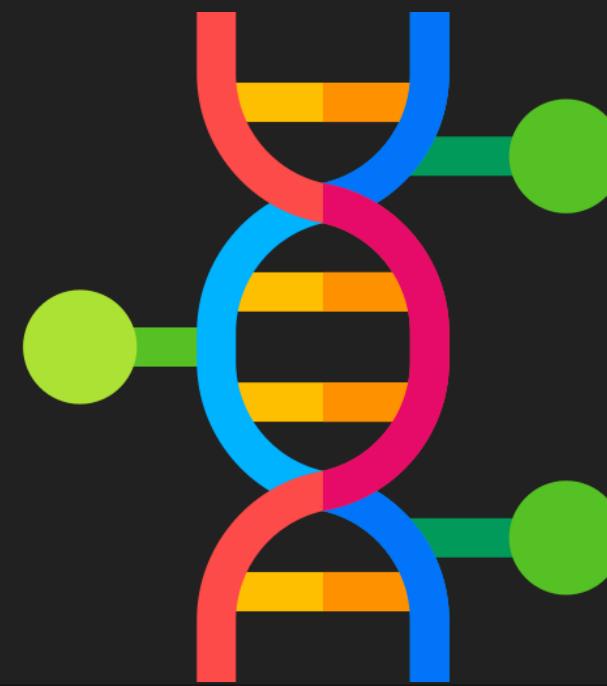


A base do AG é dada pela evolução de amostras



# Etapas do AG

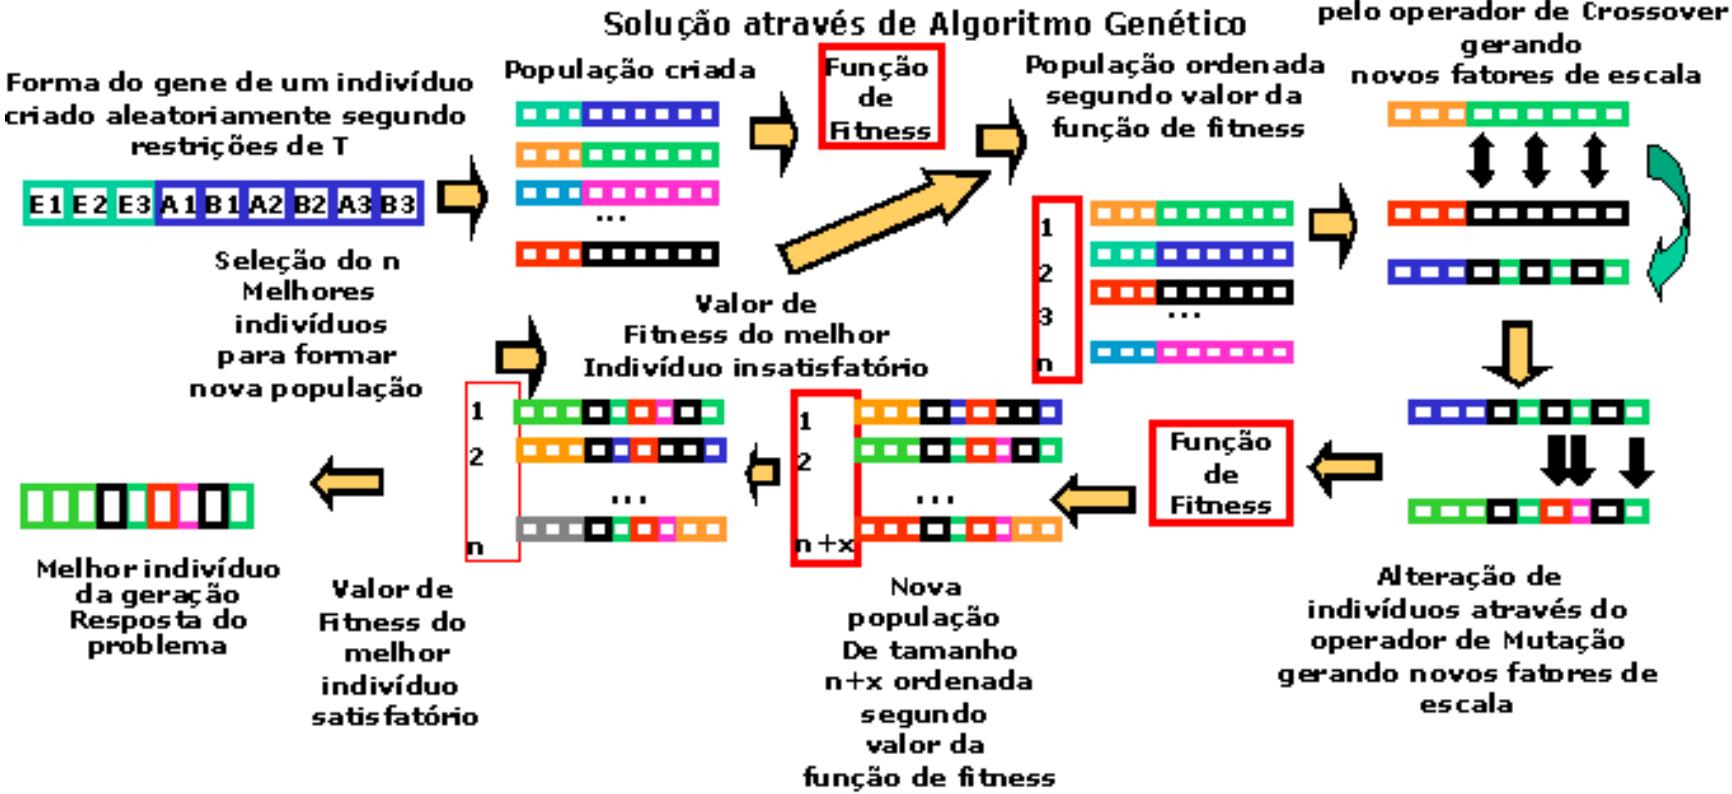
Prof. Dr. Diego Bruno



# O que são Algoritmos Genéticos?

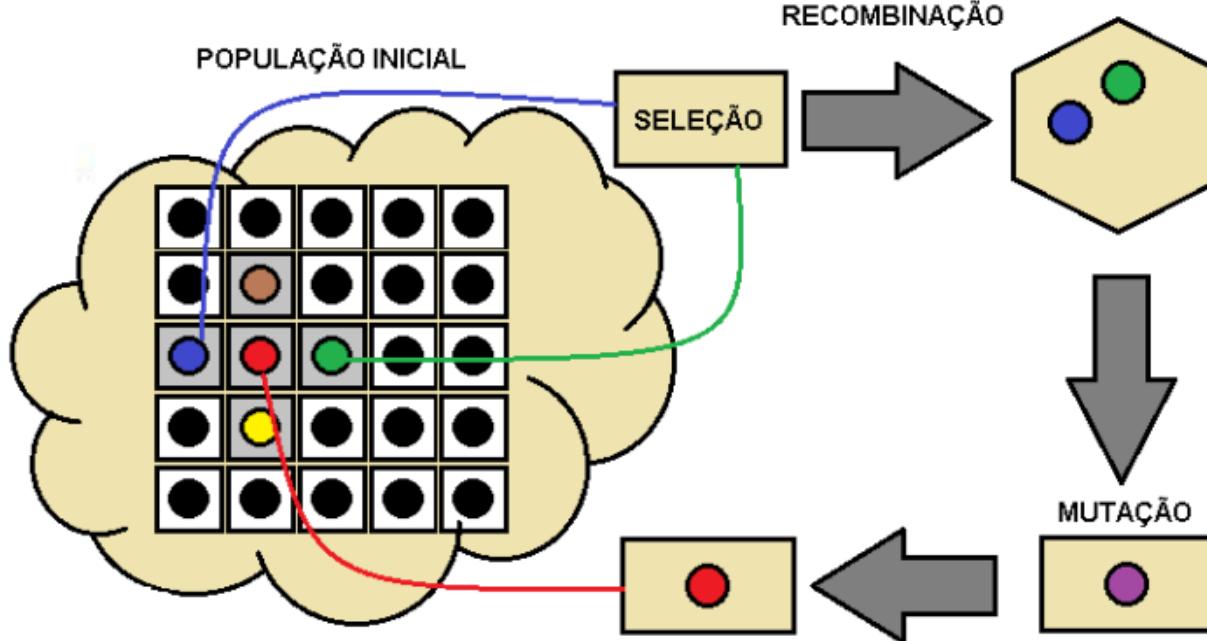
dio.

## Algoritmos baseados na genética biológica



# O que são Algoritmos Genéticos?

Algoritmos baseados na genética biológica

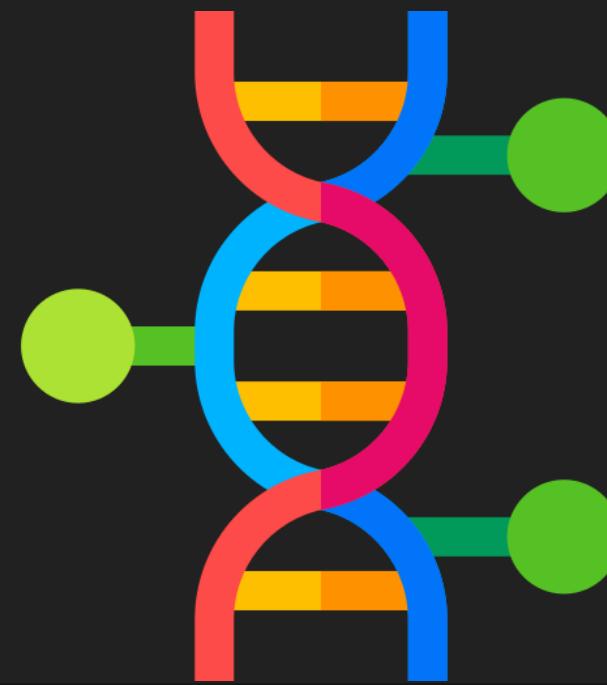


Soluções  
Heurísticas e não  
determinísticas

Gerar o melhor valor  
possível: ótimo  
global

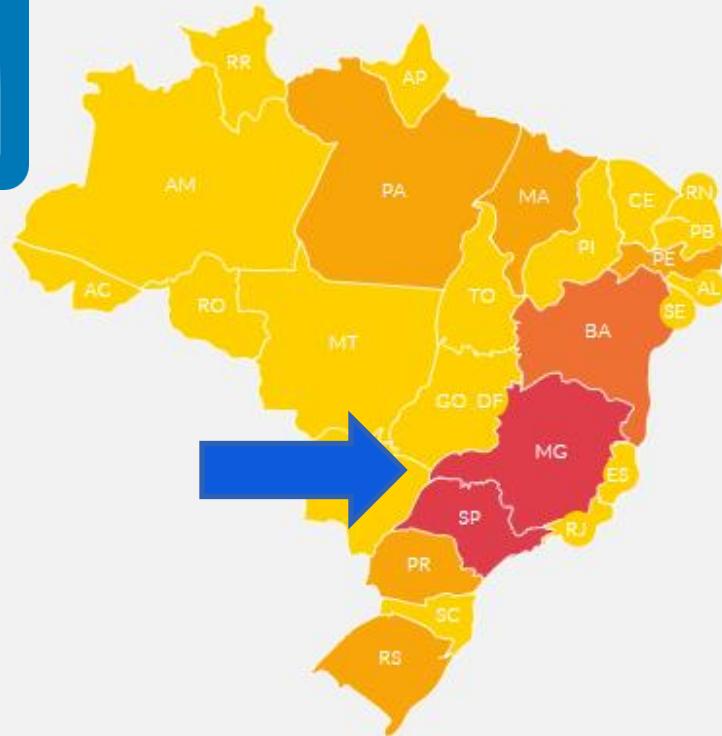
# AG são heurísticos

Prof. Dr. Diego Bruno



# Aplicações de AG

Onde aplicamos AG? Exemplo: encontrar um funcionário

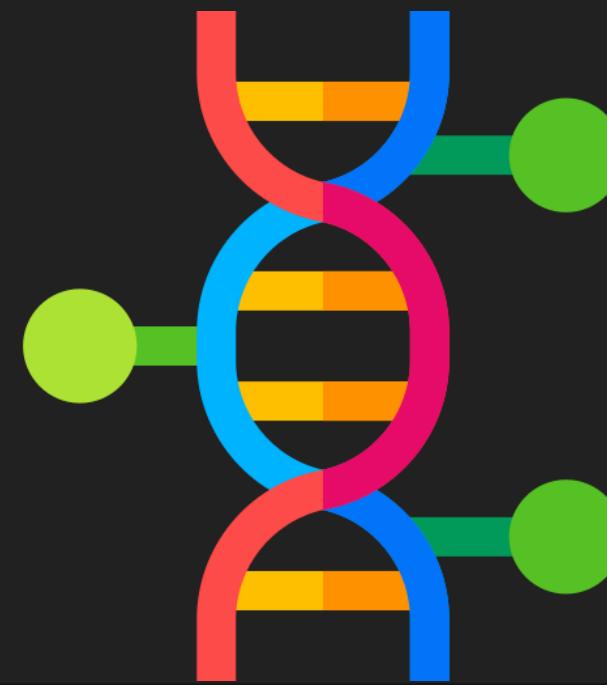


Trabalhamos com regiões de busca

Soluções Heurísticas e não determinísticas

# Definição para AG

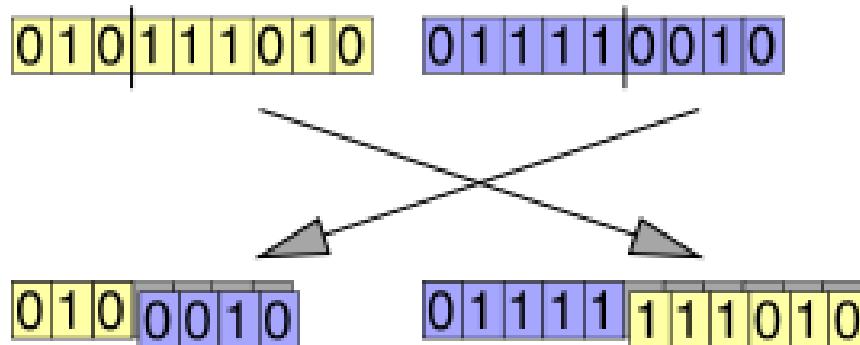
Prof. Dr. Diego Bruno



# Definições

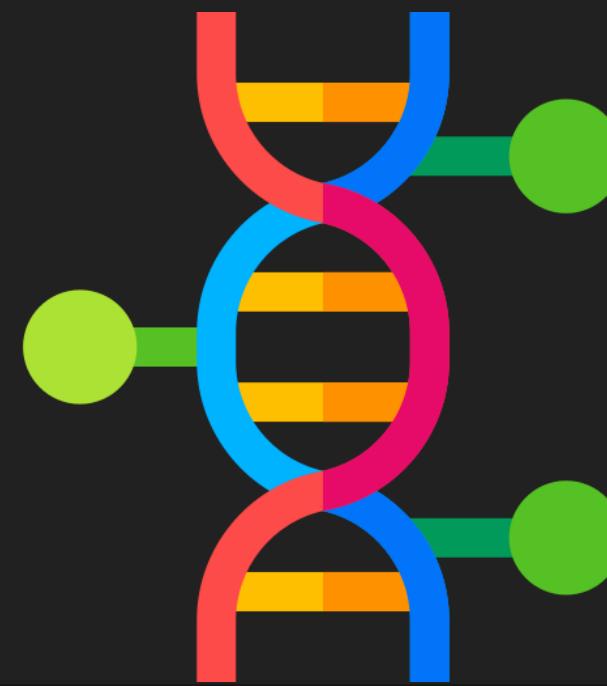
## Onde aplicamos AG?

Um **Algoritmo Genético (AG)** é uma técnica de busca utilizada na ciência da computação para achar soluções aproximadas em problemas de otimização e busca.



# Aplicações de AG

Prof. Dr. Diego Bruno



# Aplicações de AG

## Onde aplicamos AG?

- Navegação robótica
- Inteligência Artificial
- Geração de novos dados
- Jogos digitais



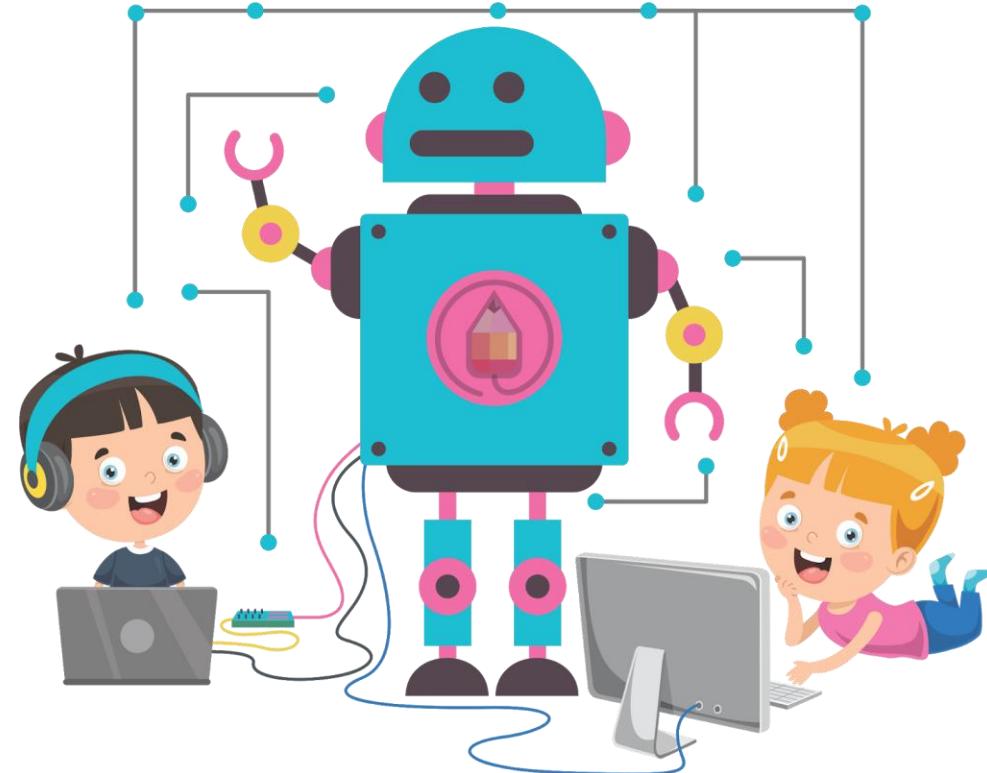
# Aplicações de AG

**Exemplo:** Aplicações em ensino e chatbots

Gerar combinações de respostas para o usuário

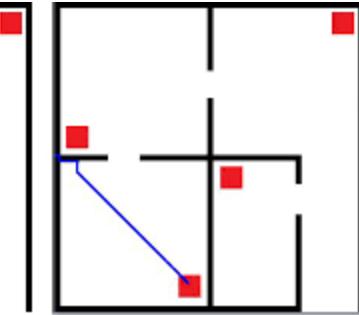
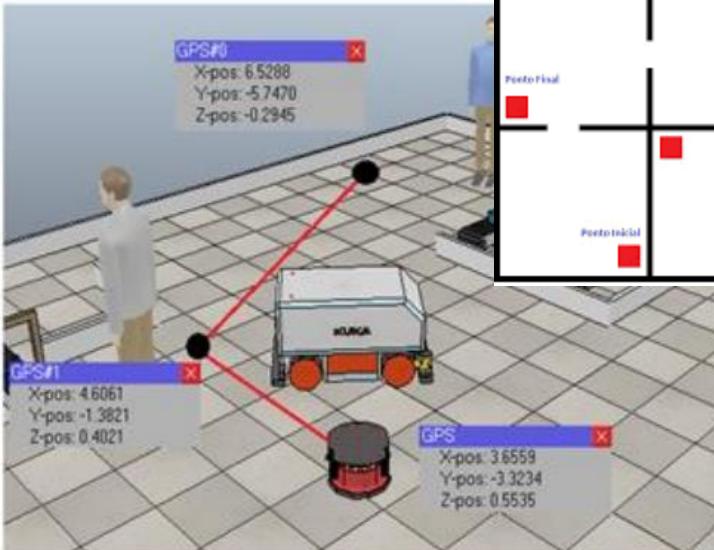
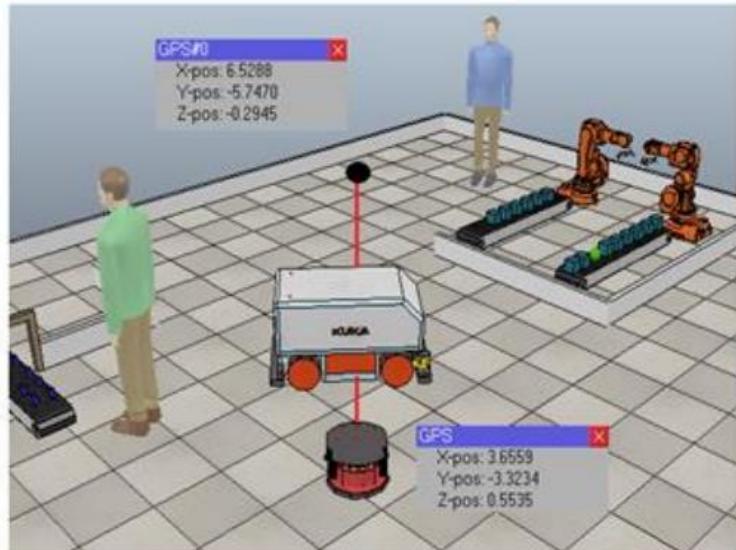
Gerar combinações de perguntas

Deixar o sistema mais próximo de uma **interação humana**



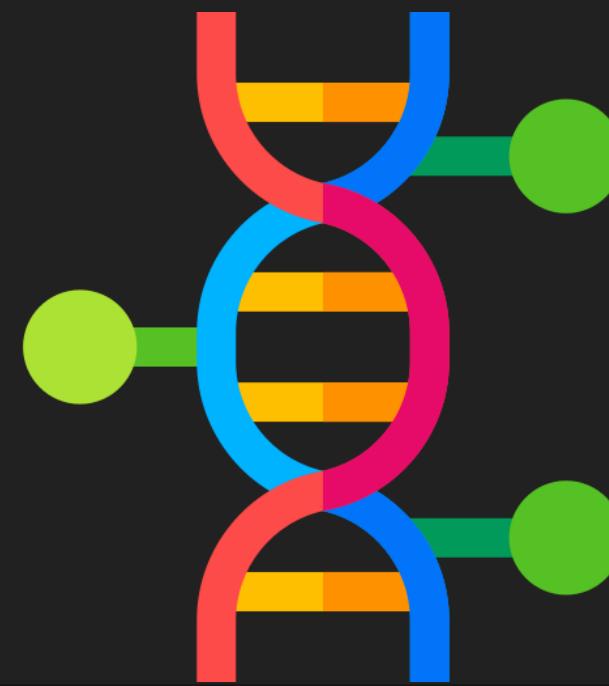
# Aplicações de AG

**Exemplo:** Planejamento de rotas em robôs móveis



# Métodos para AG

Prof. Dr. Diego Bruno



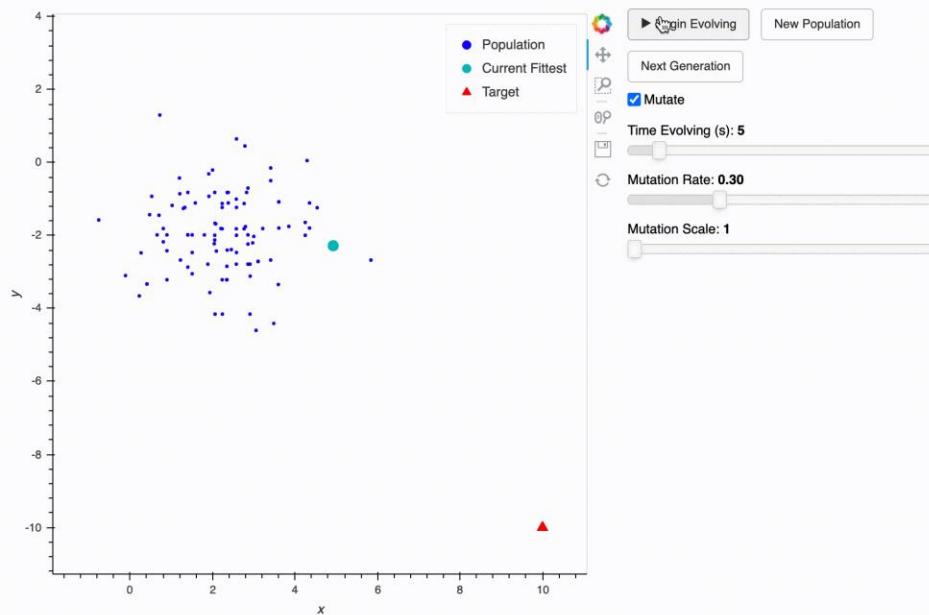
# Como implementar um AG?

## Passo 0: Gera população inicial

### Genetic Algorithm Dashboard

#### Instructions:

1. Click on the plot to place the target.
2. Click '► Begin Evolution' button to begin evolving for the time on the Time Evolving slider.
3. Experiment with the Mutation Rate (the probability of an individual in the next generation mutating)
4. Experiment with the Mutation Scale (the size of the mutation, tip: zoom out using the Wheel Zoom on the right of the plot).

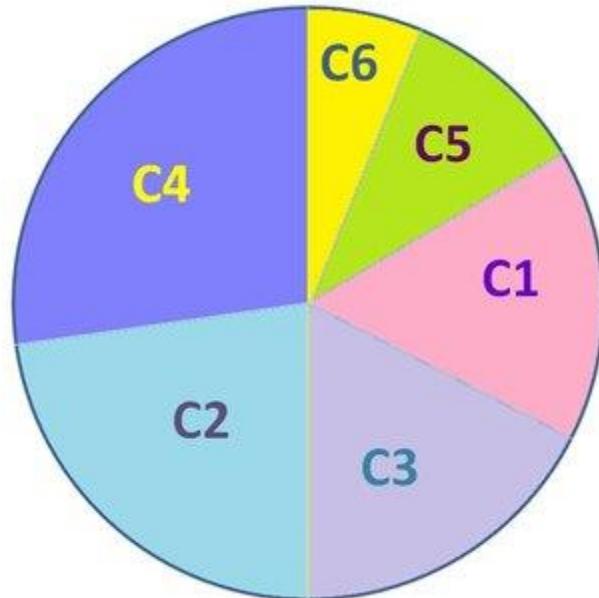


Gera população de forma aleatória

Define a população dentro de uma região de busca

# Como implementar um AG?

**Passo 1:** Seleção dos melhores indivíduos iniciais



Método de seleção por  
roleta

Seleciona os melhores  
indivíduos dada sua  
**probabilidade**

# Como implementar um AG?

## Passo 2: Recombinação de indivíduos

1 1 0 1 0 1

1 0 0 1 0 0

(a)

A recombinação vai  
recombinar os **dois**  
**melhores** indivíduos

A meta é gerar um indivíduo  
**melhor** do que seus pais

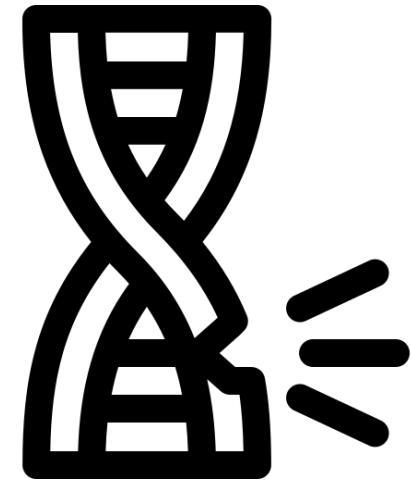
# Como implementar um AG?

## Passo 3: Seleção dos melhores indivíduos iniciais

Antes da Mutação: 1 1 1 0 0

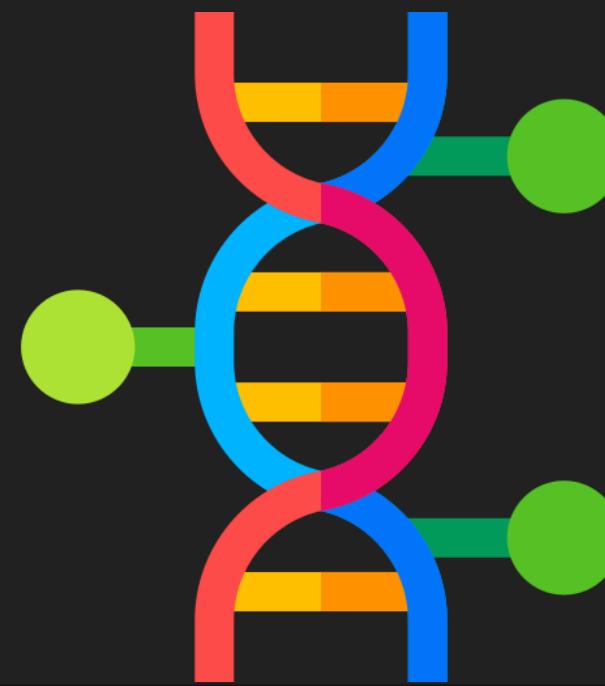
Selecionar um ponto do cromossomo e gerar mutação

Evita a convergência prematura do AG



# Funcionamento

Prof. Dr. Diego Bruno



# Funcionamento na prática...

Gerar soluções para o comportamento dos personagens em um game

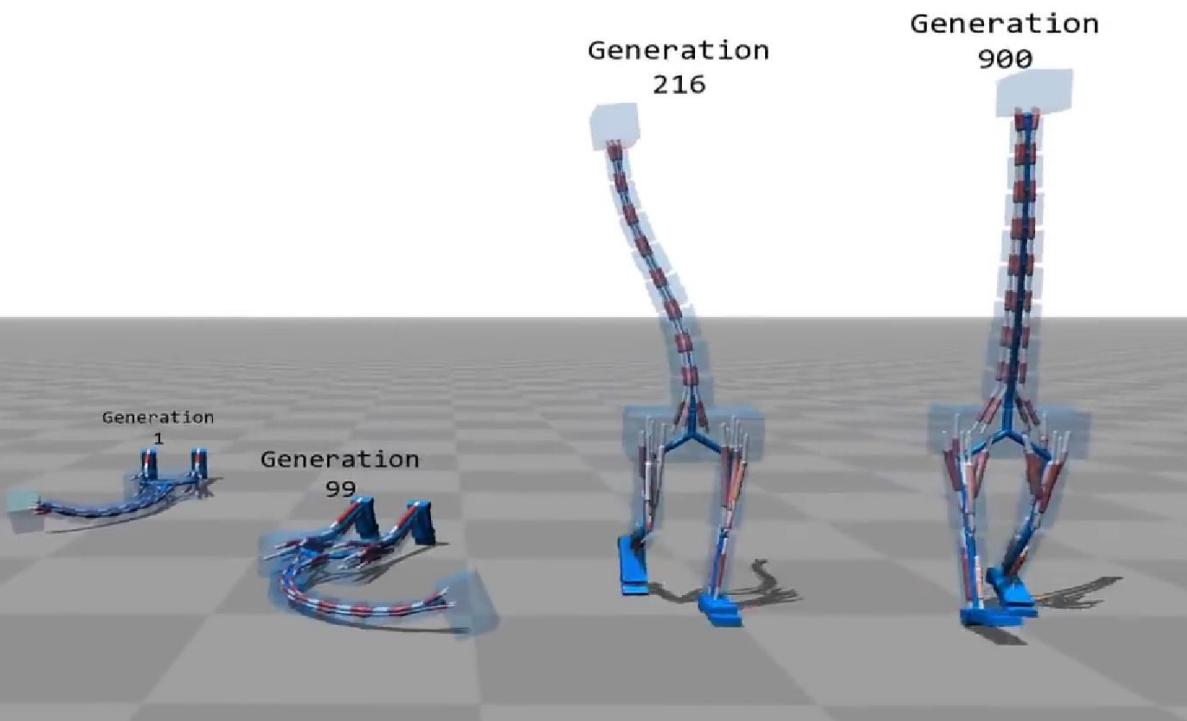


Evitar comportamentos repetidos entre os agentes do game

Gerar comportamentos novos para cada agente

# Funcionamento na prática...

Ensinar um agente em seu funcionamento desde o ponto “zero”.

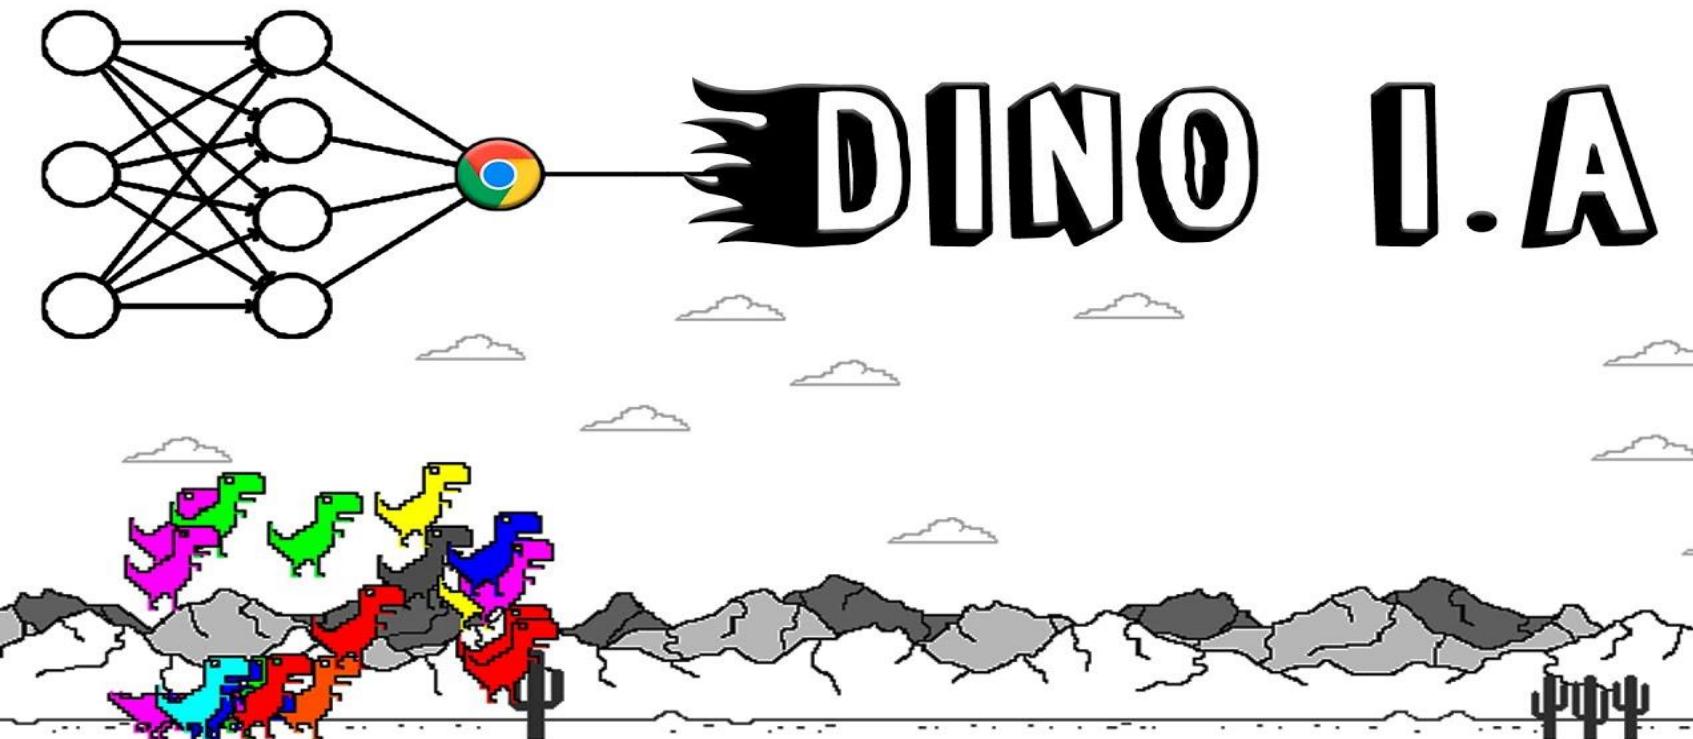


**Ensinar o comportamento do agente do “zero”**

**Aprendizado por tentativa e erro**

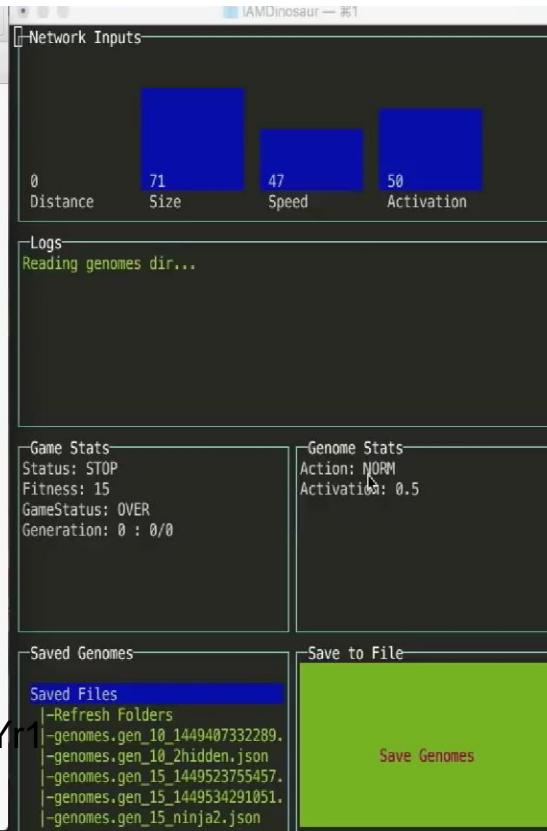
# Funcionamento na prática...

Vamos ver algo mais simples...



# Funcionamento na prática...

Vamos ver algo mais simples...



Ensinar o comportamento do agente do “zero”

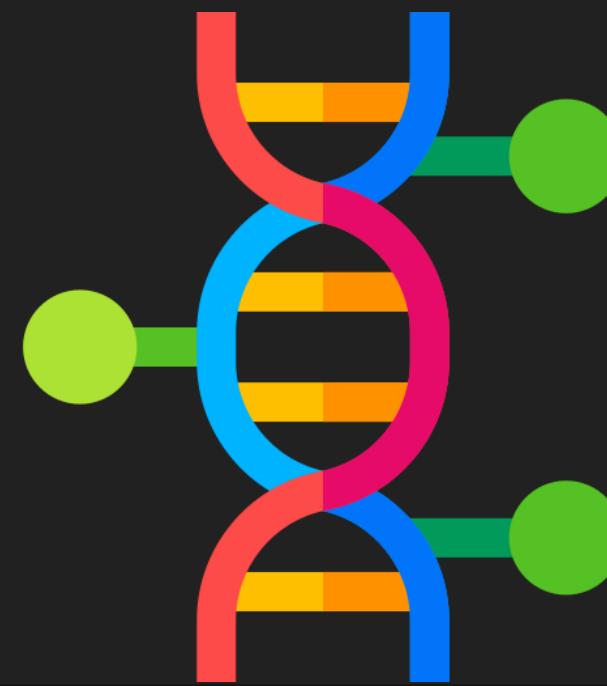
Aprendizado por tentativa e erro

Fonte:

<https://www.youtube.com/watch?v=NZI1Y1slAk>

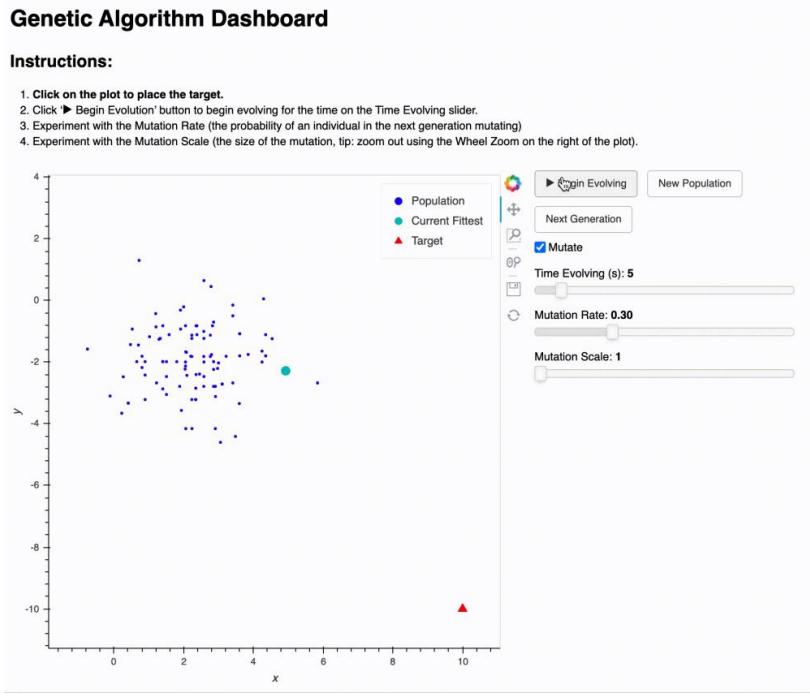
# Implementação

Prof. Dr. Diego Bruno



# Funcionamento na prática...

## Implementação do algoritmo no Colab



colab

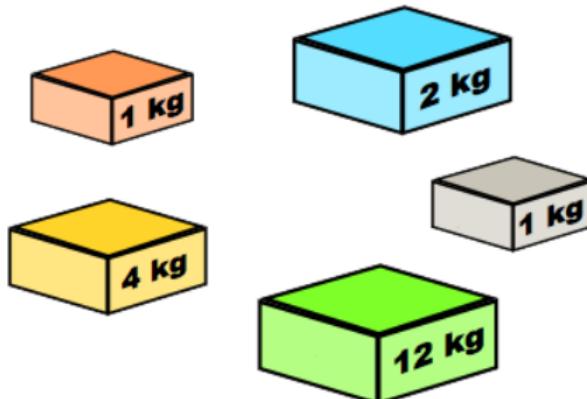
Fonte: [https://colab.research.google.com/github/scottire/fastpages/blob/master/\\_notebooks/2020-07-20-interactive-genetic-algorithm-dashboard-from-scratch-in-python.ipynb#scrollTo=TSrmSBdE7r0q](https://colab.research.google.com/github/scottire/fastpages/blob/master/_notebooks/2020-07-20-interactive-genetic-algorithm-dashboard-from-scratch-in-python.ipynb#scrollTo=TSrmSBdE7r0q)

# Funcionamento na prática...

## Algoritmo genético para resolver o problema da mochila

Instalação das bibliotecas necessárias.

O problema da mochila é um problema de optimização combinatório. Nesse caso, a mochila aguenta uma certa carga máxima e o objetivo é preenchê-la com uma certa quantidade de objetos. Cada objeto tem um peso e um valor. O objetivo central é preencher a mochila com o maior valor possível sem ultrapassar a carga máxima.



**Problema NP-Completo**

# Obrigado!

Prof. Dr. Diego Bruno



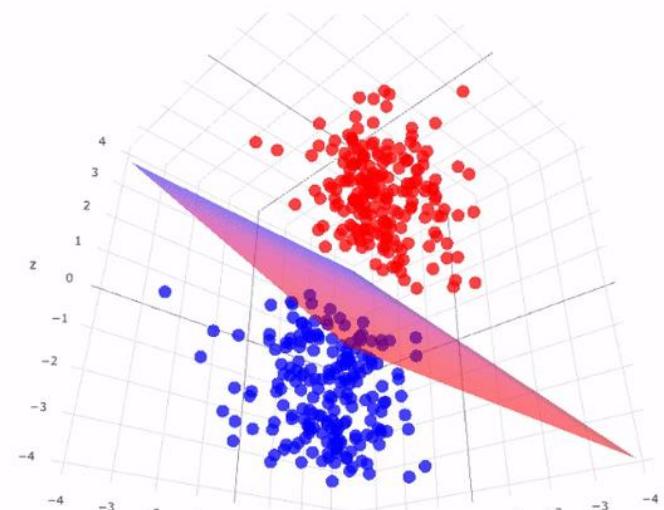
# Máquina de Vetores de Suporte

## Teoria e Prática

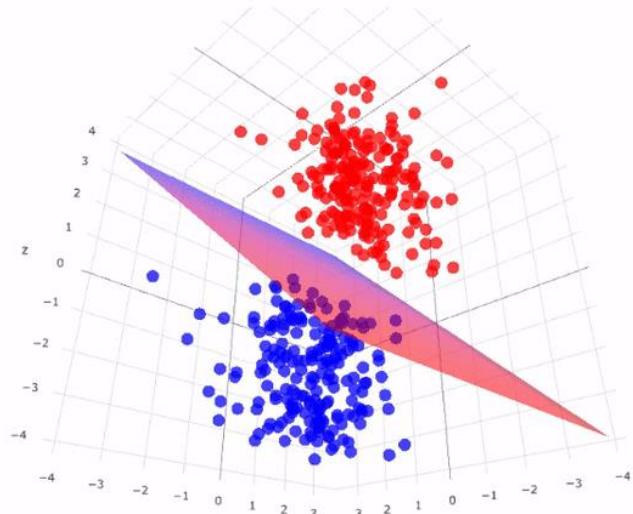
**Prof. Dr. Diego Bruno**

Education Tech Lead na DIO

Doutor em Robótica e *Machine Learning* pelo ICMC-USP

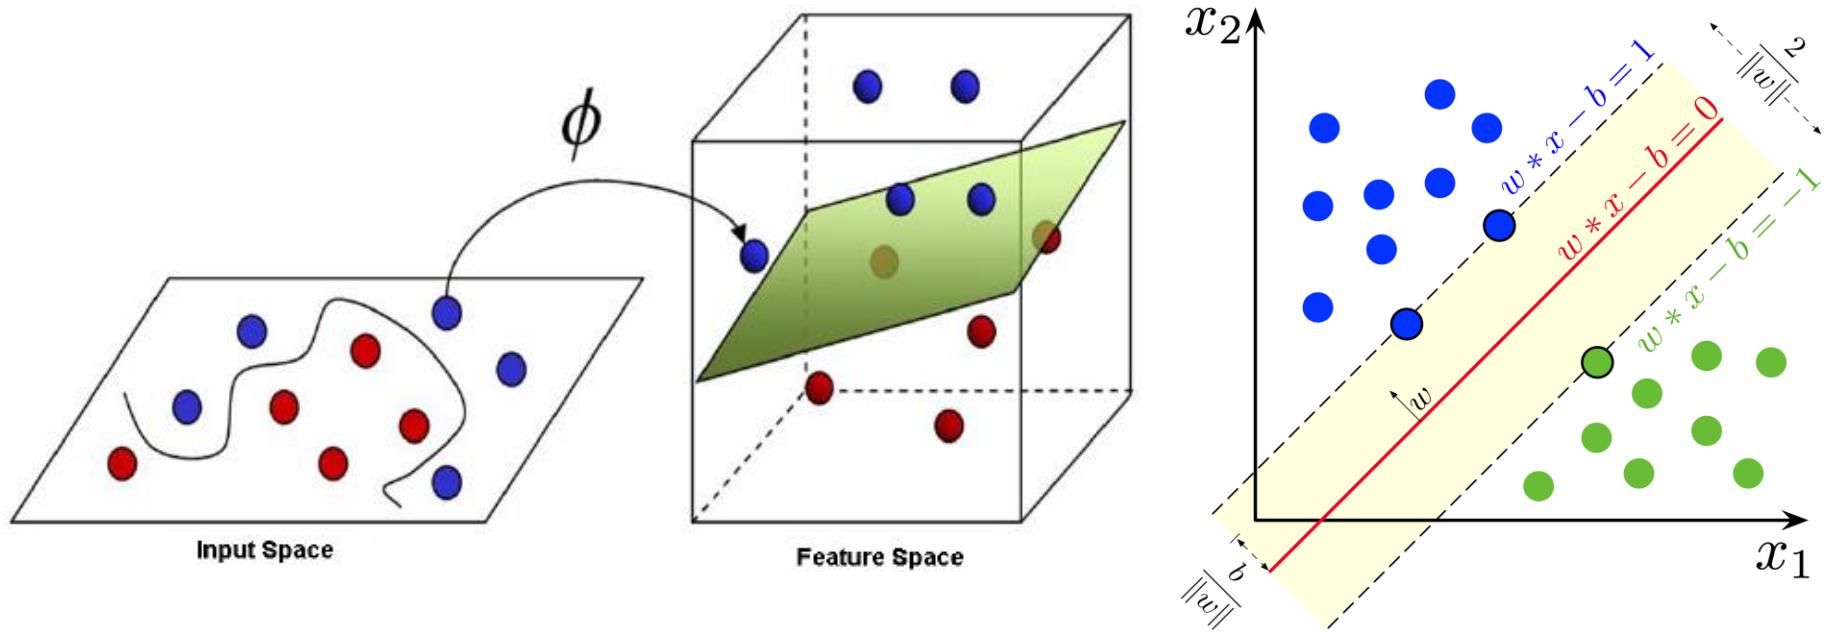


# Máquina de Vetores de Suporte (SVM)



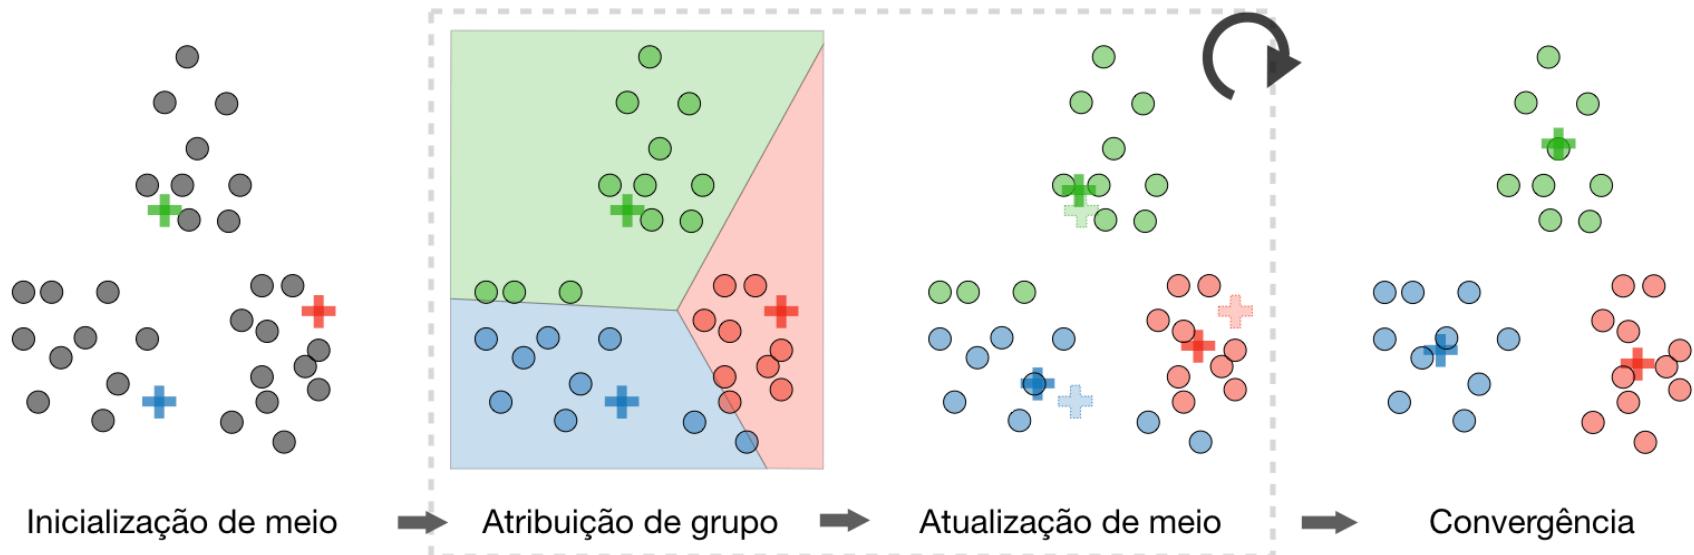
# O que são SVMs?

## Máquina de Vetores de Suporte



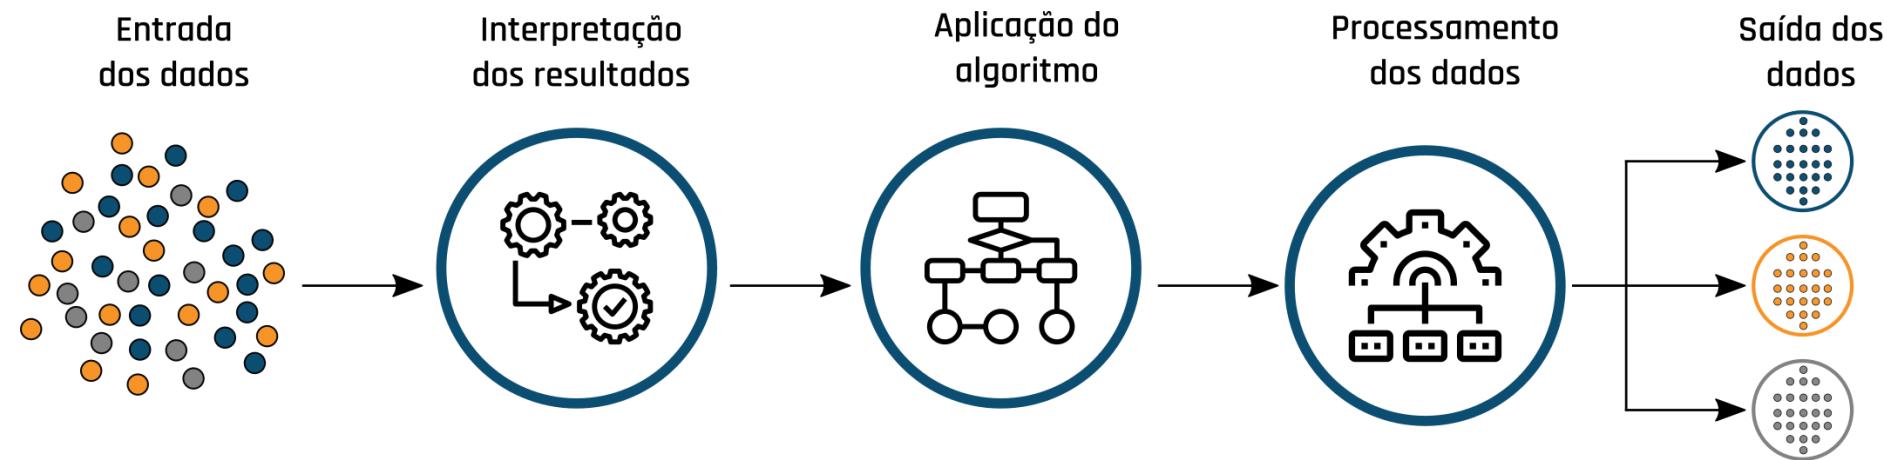
# Tipos de aprendizado

## Não supervisionado



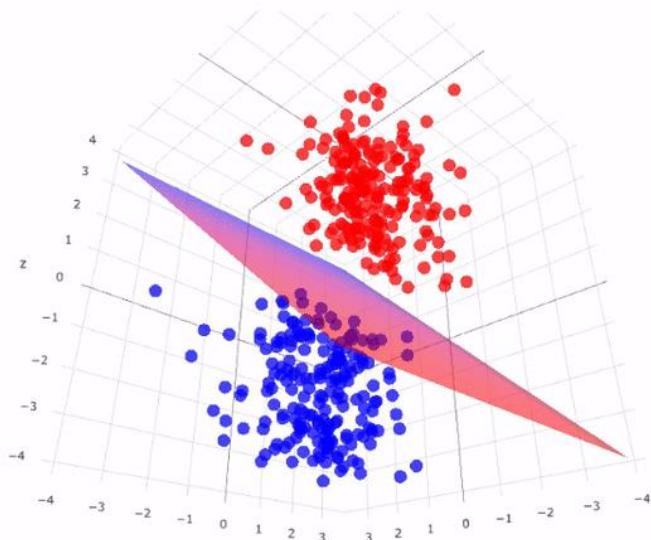
# Tipos de aprendizado

## Supervisionado



# Tipos de aprendizado

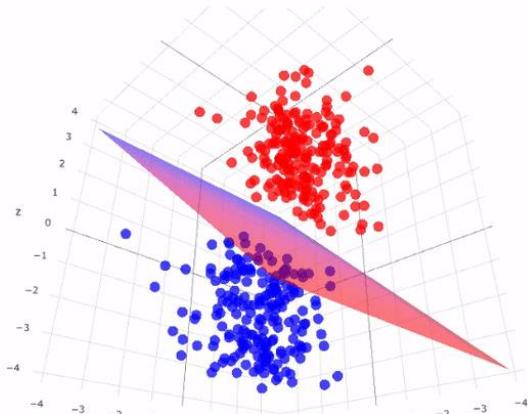
## Supervisionado



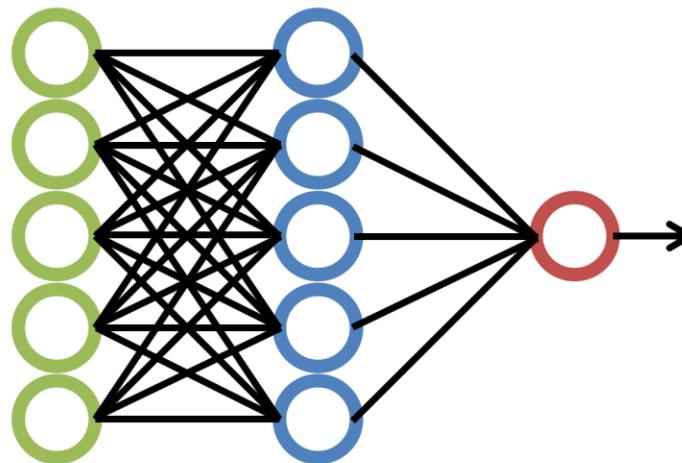
Os **algoritmos** de aprendizagem **supervisionada** relacionam uma saída com uma entrada com base em dados rotulados. Neste caso, o usuário alimenta ao **algoritmo** pares de entradas e saídas conhecidos.

# Diferenças entre RNA e SVM?

## Supervisionado



SVM

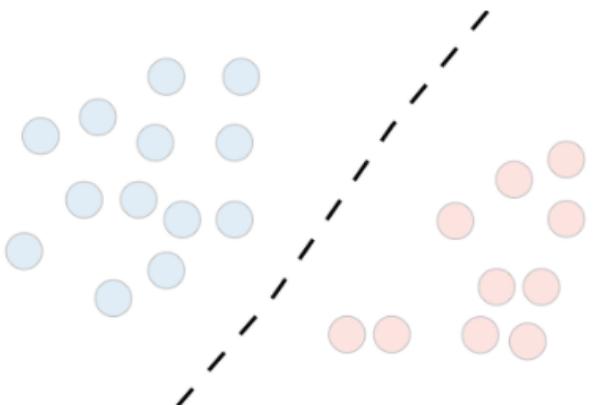


RNA

Na prática não há muita diferença... O principal fator é o modo de estabelecer o **hiperplano**.

**SVM** buscando a otimização das margens e a **RNA** buscando o mínimo global

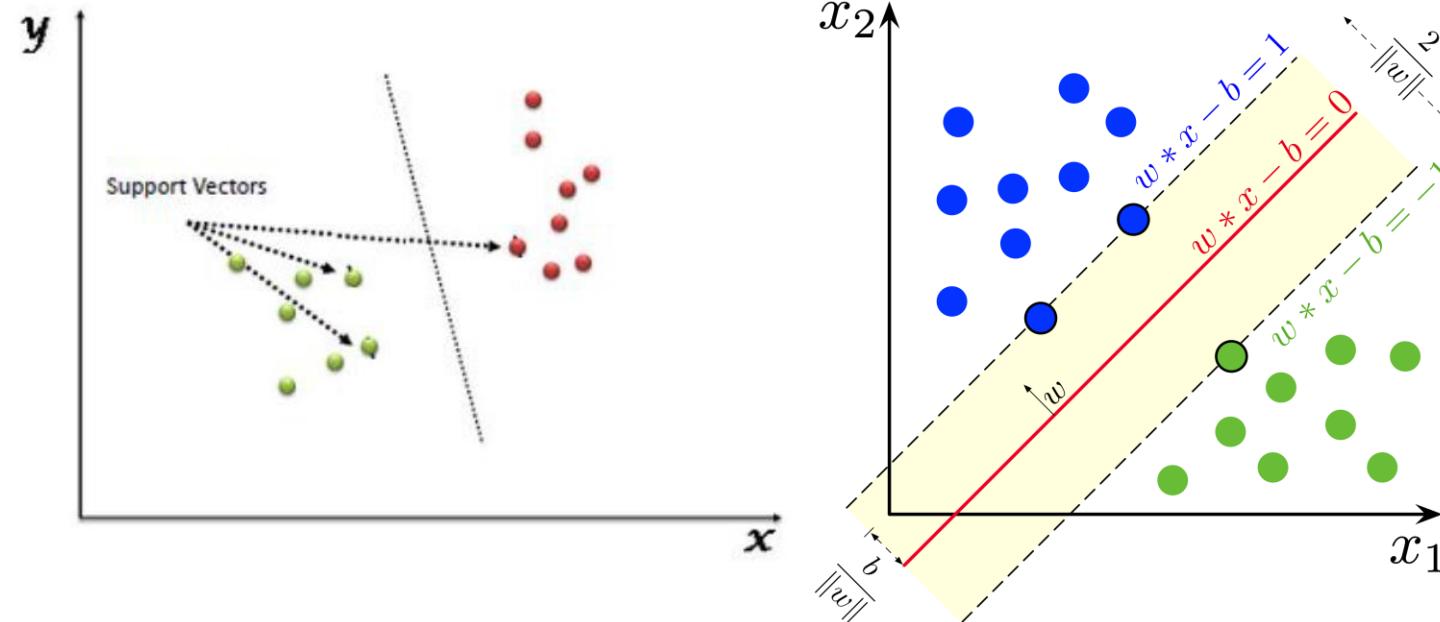
# Resultado esperado de uma SVM

	Modelo discriminativo
Objetivo	Estimar diretamente $P(y x)$
O que é aprendido	Fronteira de decisão
Ilustração	
Exemplos	Regressões, SVMs

**SVM** buscando a otimização das margens e a **RNA** buscando o mínimo global

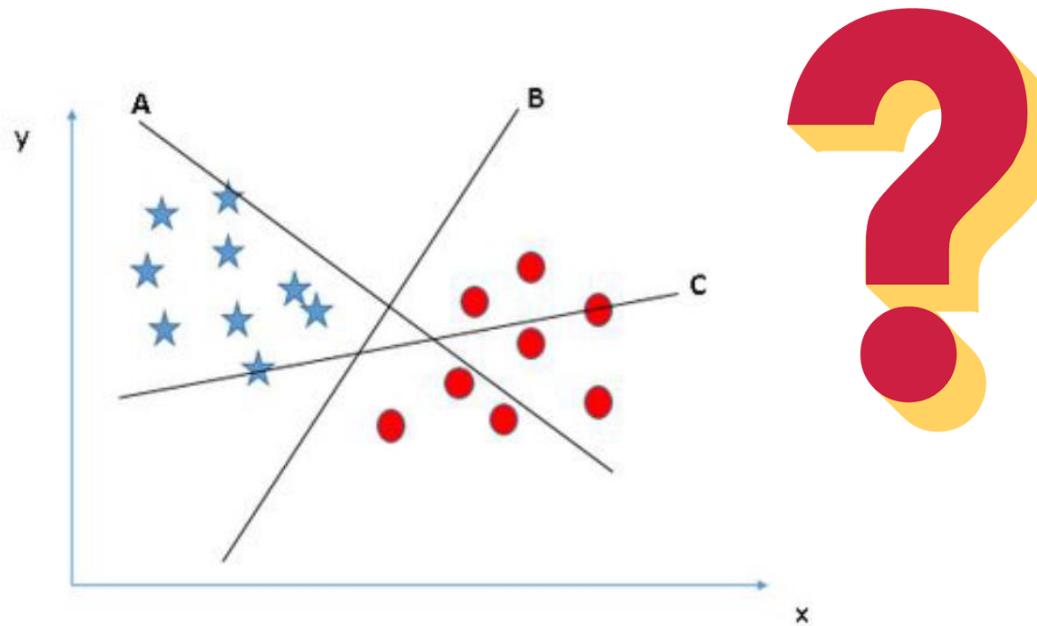
# Por que “Máquina de Vetores”?

Os “**Vetores de suporte**” são simplesmente as coordenadas da observação individual. Uma **SVM** é uma fronteira que melhor realiza as duas classes (hiperplano / linha).



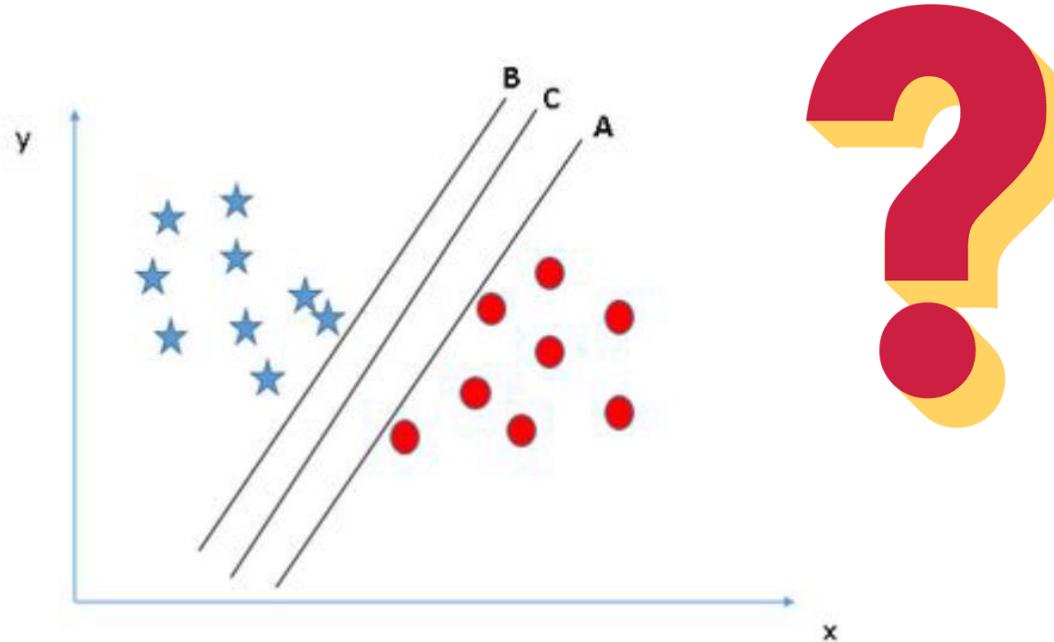
# Desenvolvendo a hipótese

**Desenvolvendo a hipótese:** Aqui, temos três hiperplanos (A, B e C). Mas qual o hiperplano certo para classificar estrela e círculo?



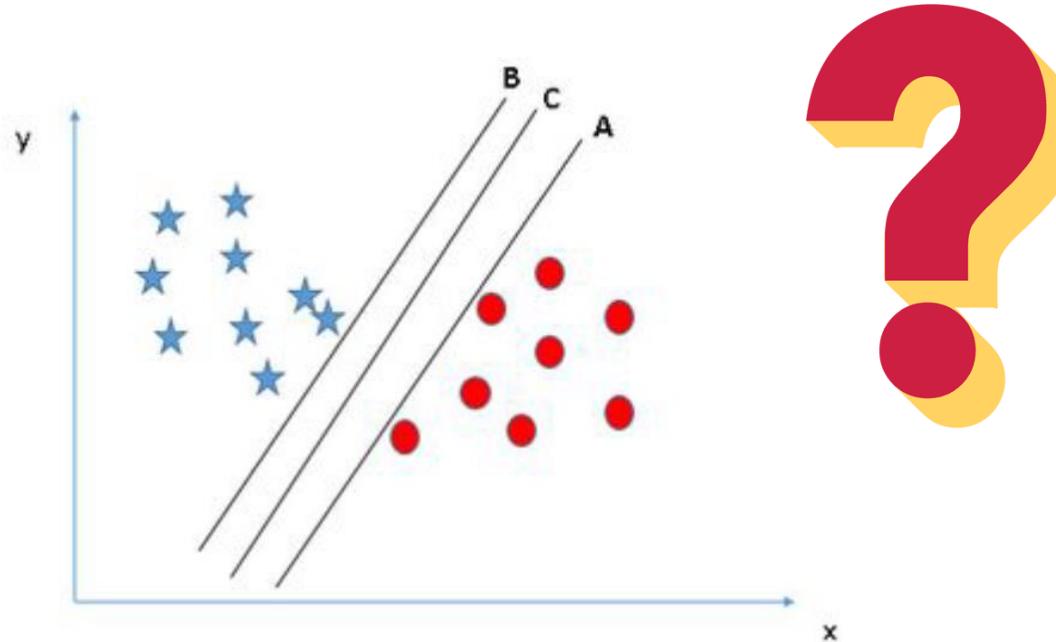
# Desenvolvendo a hipótese

Aqui, temos três **hiperplanos (A, B e C)** e todos estão dividindo bem as classes. Agora, como podemos identificar o hiperplano certo?



# Desenvolvendo a hipótese

Maximizar as distâncias entre o ponto de dados mais próximo (de qualquer classe) e o hiperplano nos ajudará a decidir o hiperplano correto



# Implementação

Prof. Dr. Diego Bruno

# Obrigado!

Prof. Dr. Diego Bruno

# DATASETs

## Teoria e Prática

**Prof. Dr. Diego Bruno**

Education Tech Lead na DIO

Doutor em Robótica e *Machine Learning* pelo ICMC-USP

# O que é um Dataset?

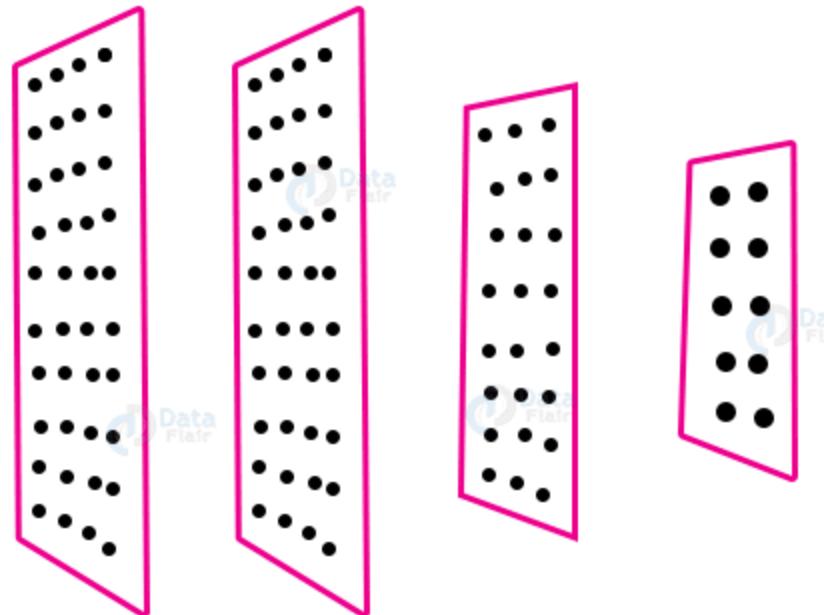


# Dataset

CAT



DOG



Fonte: [https://www.linkedin.com/pulse/cats-vs-dogs-image-classification-using-cnn-piyush-pareek/?trk=public\\_profile\\_article\\_view](https://www.linkedin.com/pulse/cats-vs-dogs-image-classification-using-cnn-piyush-pareek/?trk=public_profile_article_view)

# Dataset

## Como devem ser minhas amostras?

Predicted:Dog



Predicted:Cat



Predicted:Cat



Predicted:Dog



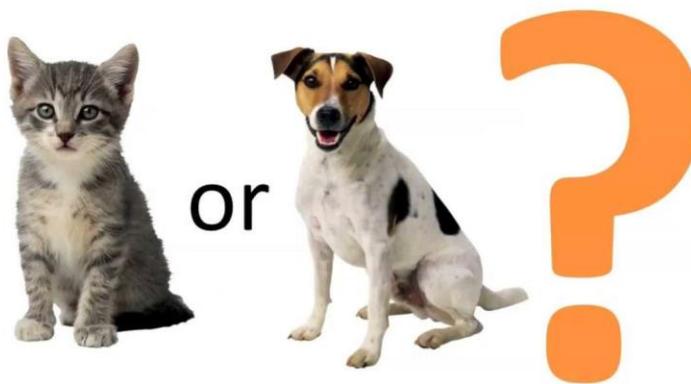
Predicted:Dog



Fonte: [https://www.linkedin.com/pulse/cats-vs-dogs-image-classification-using-cnn-piyush-pareek/?trk=public\\_profile\\_article\\_view](https://www.linkedin.com/pulse/cats-vs-dogs-image-classification-using-cnn-piyush-pareek/?trk=public_profile_article_view)

# Dataset

Como devem ser minhas amostras?



Fonte: [https://www.linkedin.com/pulse/cats-vs-dogs-image-classification-using-cnn-piyush-pareek/?trk=public\\_profile\\_article\\_view](https://www.linkedin.com/pulse/cats-vs-dogs-image-classification-using-cnn-piyush-pareek/?trk=public_profile_article_view)

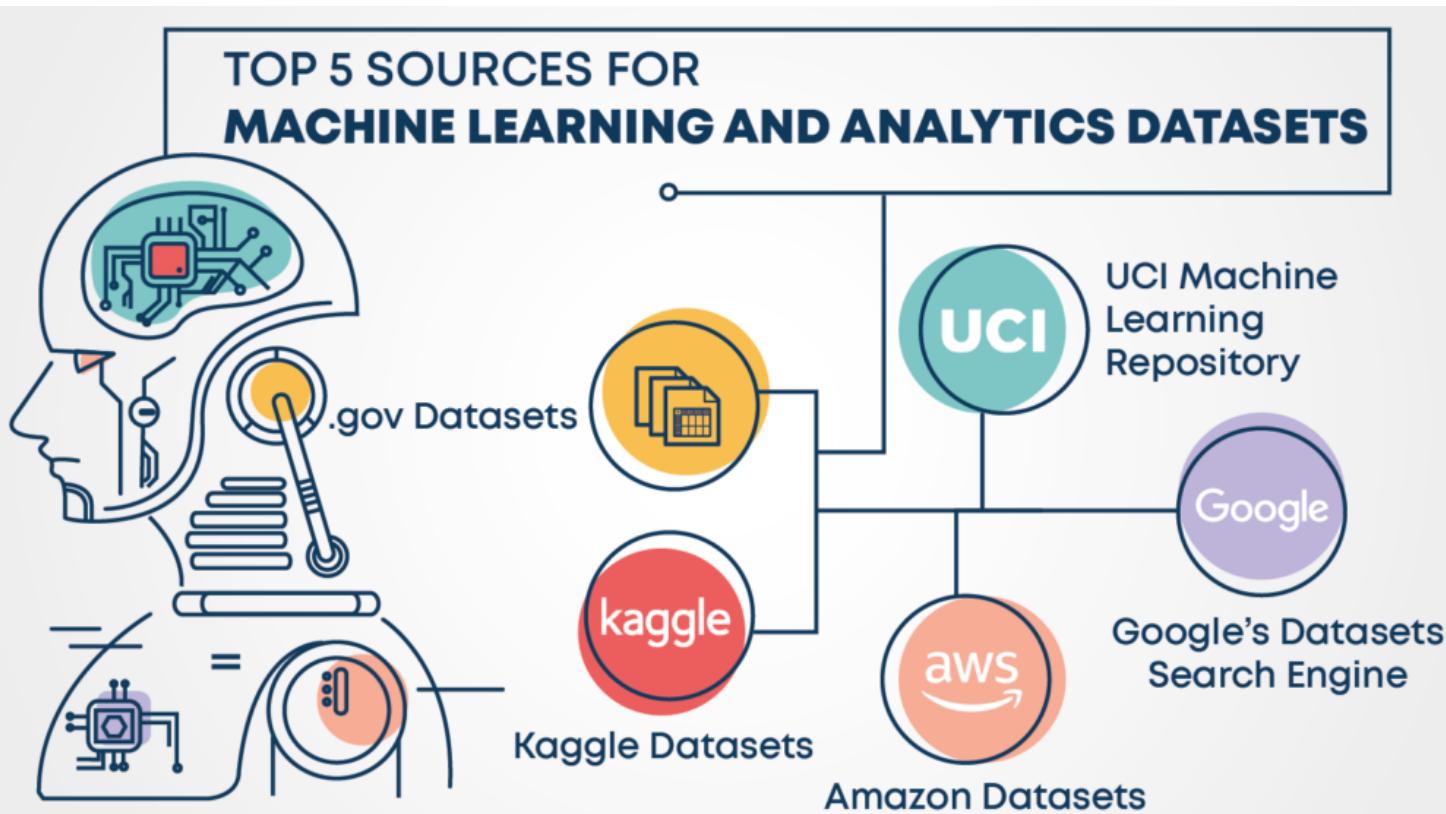
# Como criar um Dataset?

Como gerar uma base de dados...



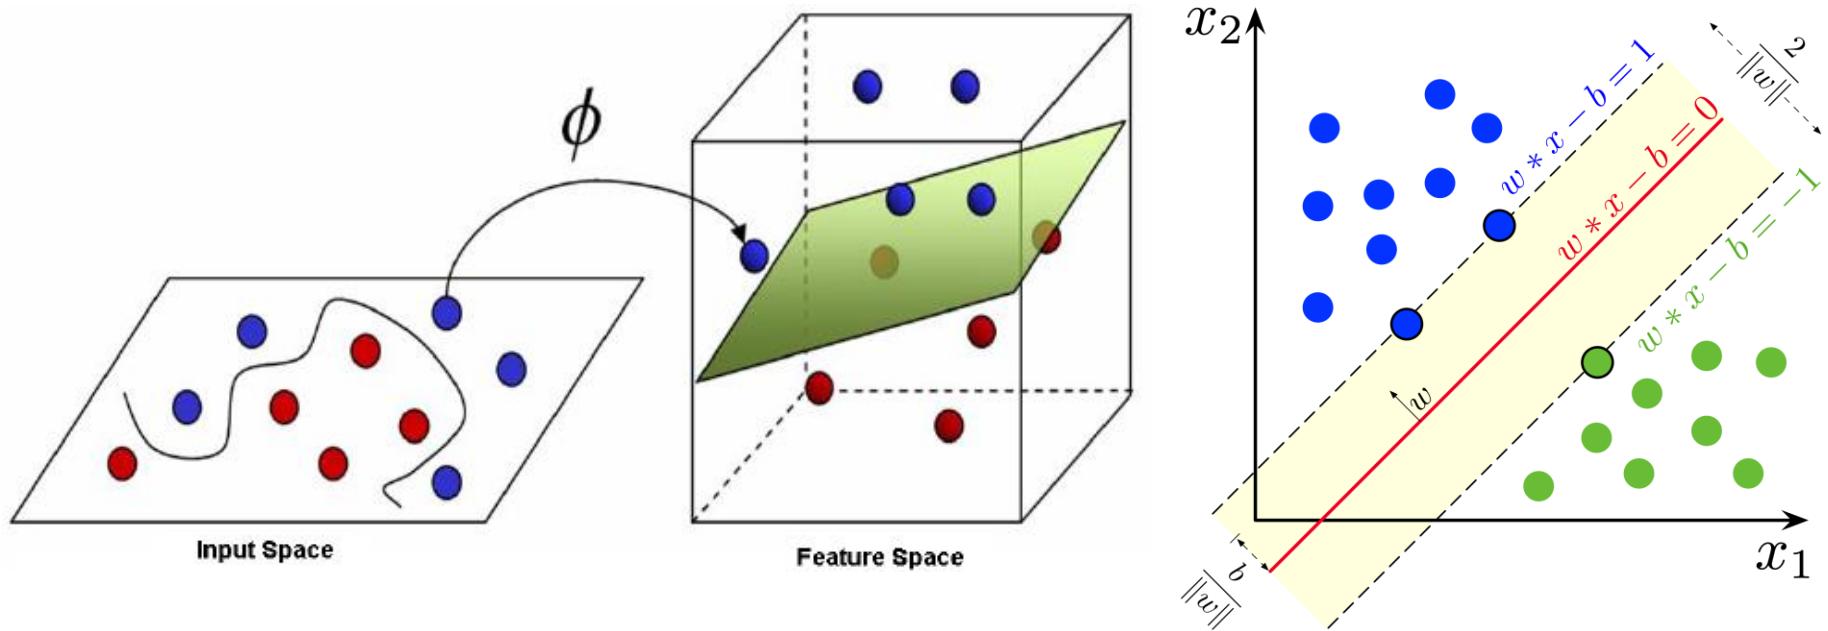
# Serviços de DATASETs?

## Bases de dados disponíveis

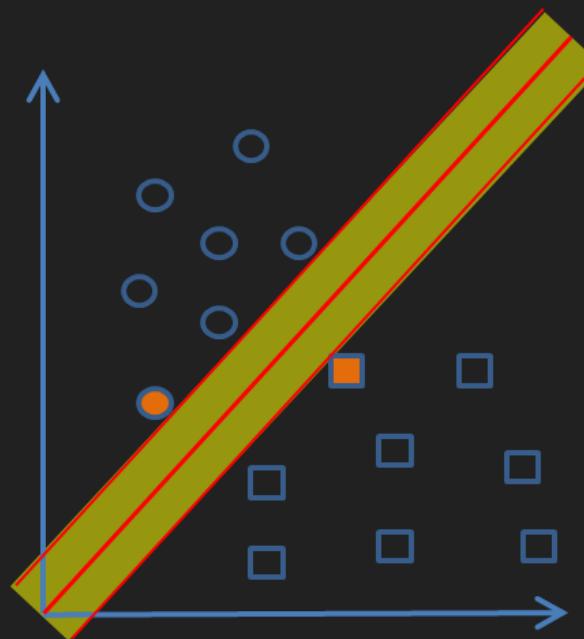


# O que são SVMs?

## Máquina de Vetores de Suporte

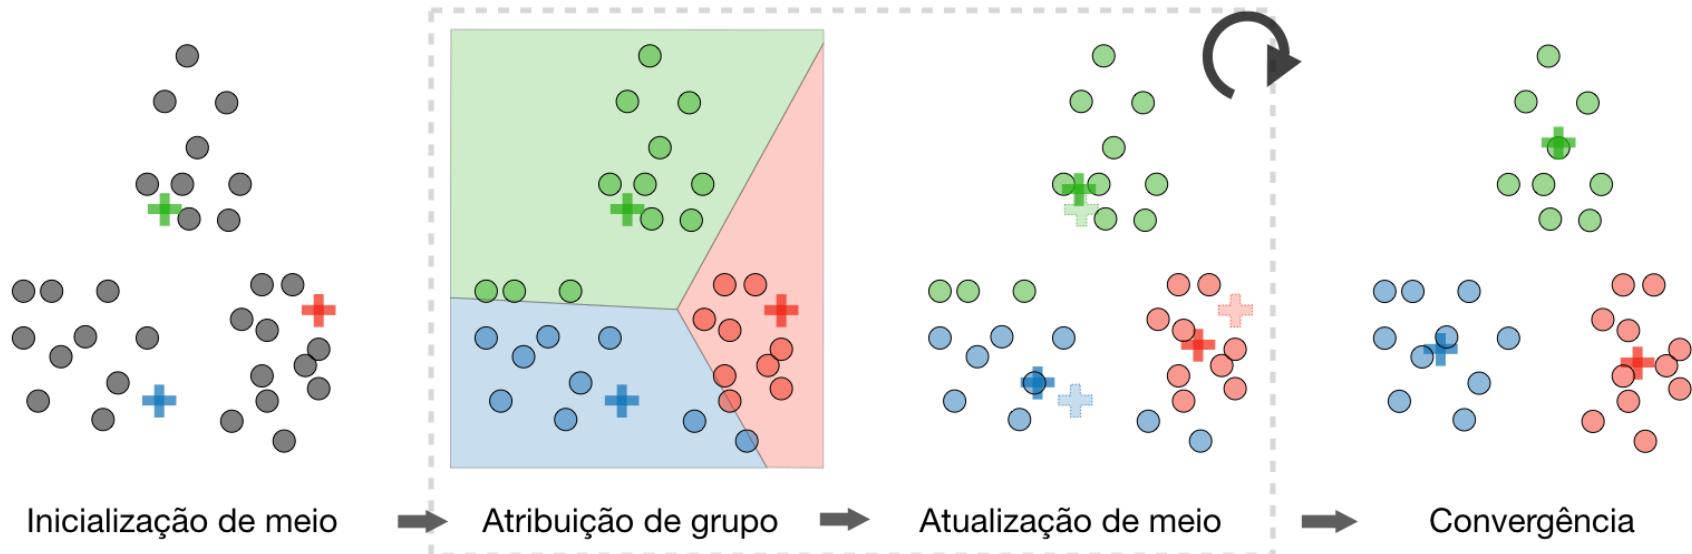


# Tipos de aprendizado



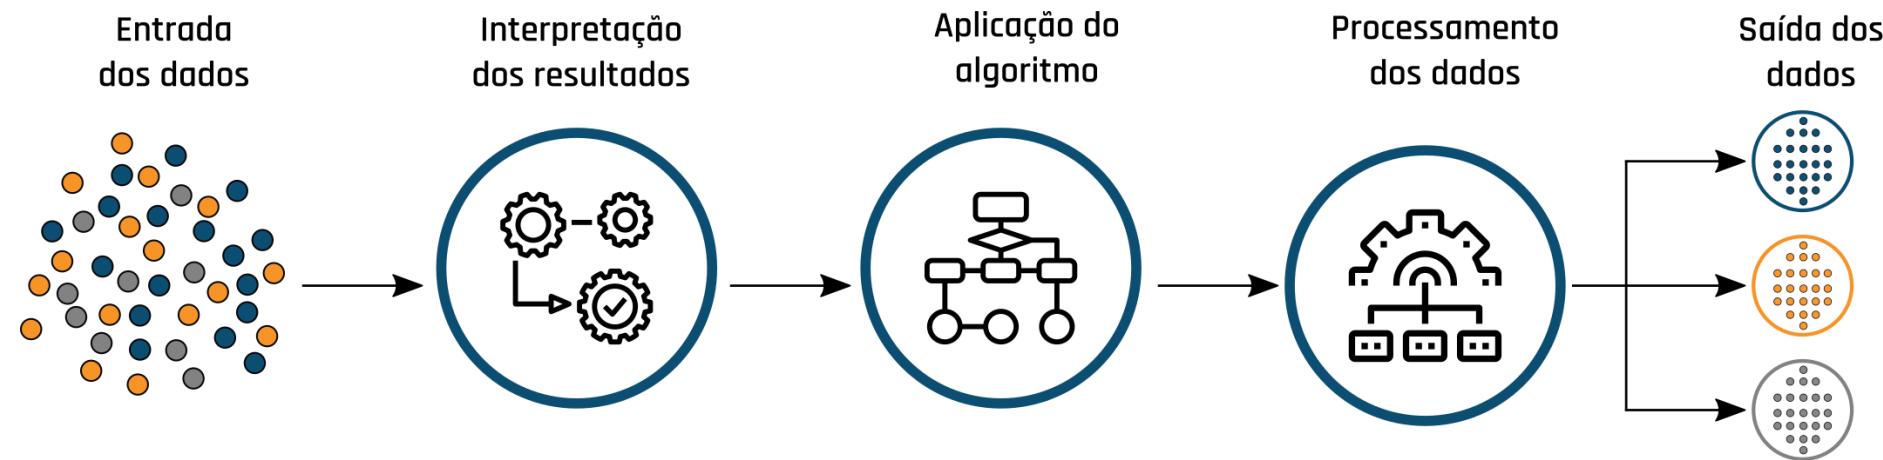
# Tipos de aprendizado

## Não supervisionado



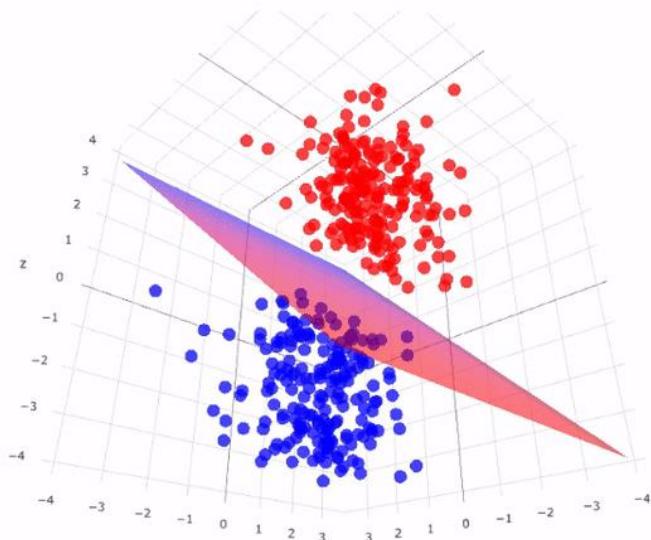
# Tipos de aprendizado

## Supervisionado



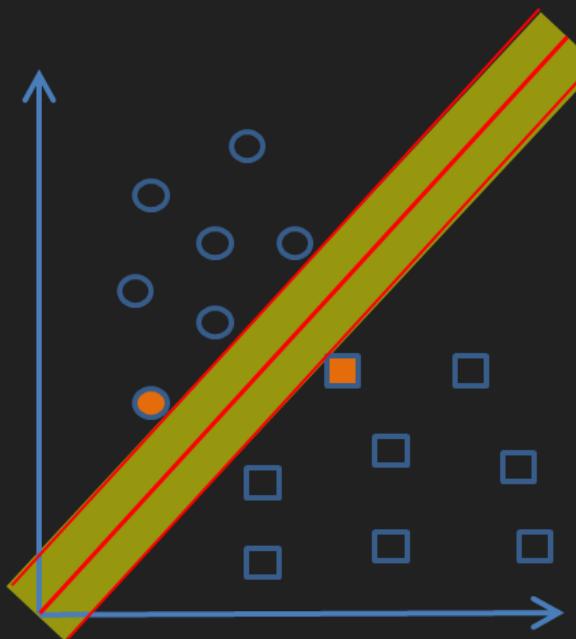
# Tipos de aprendizado

## Supervisionado



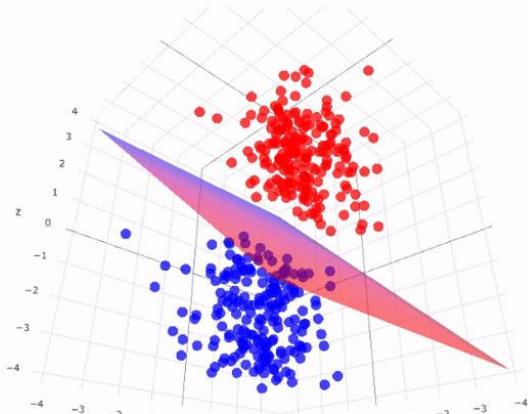
Os **algoritmos** de aprendizagem **supervisionada** relacionam uma saída com uma entrada com base em dados rotulados. Neste caso, o usuário alimenta ao **algoritmo** pares de entradas e saídas conhecidos.

# Diferença entre RNA e SVM

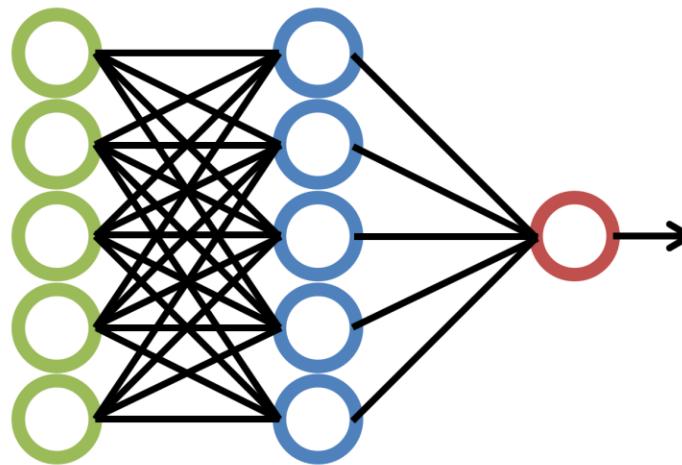


# Diferenças entre RNA e SVM?

## Supervisionado



SVM

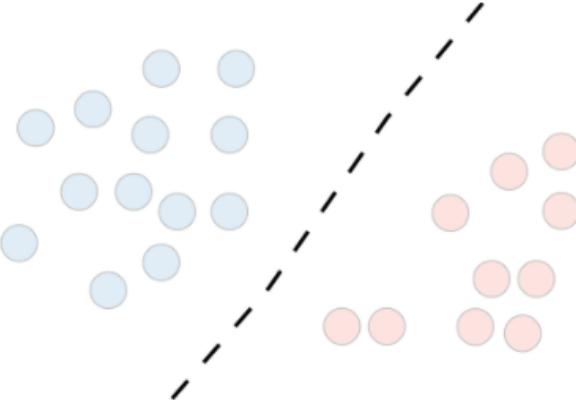


RNA

Na prática não há muita diferença... O principal fator é o modo de estabelecer o **hiperplano**.

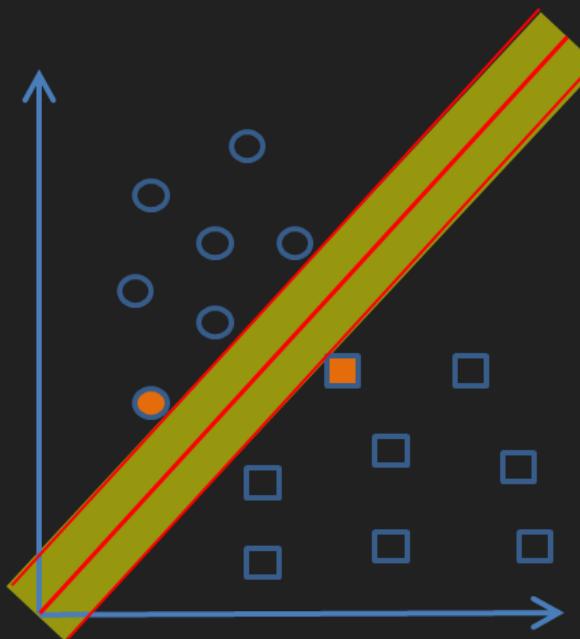
**SVM** buscando a otimização das margens e a **RNA** buscando o mínimo global

# Resultado esperado de uma SVM

	Modelo discriminativo
Objetivo	Estimar diretamente $P(y x)$
O que é aprendido	Fronteira de decisão
Ilustração	
Exemplos	Regressões, SVMs

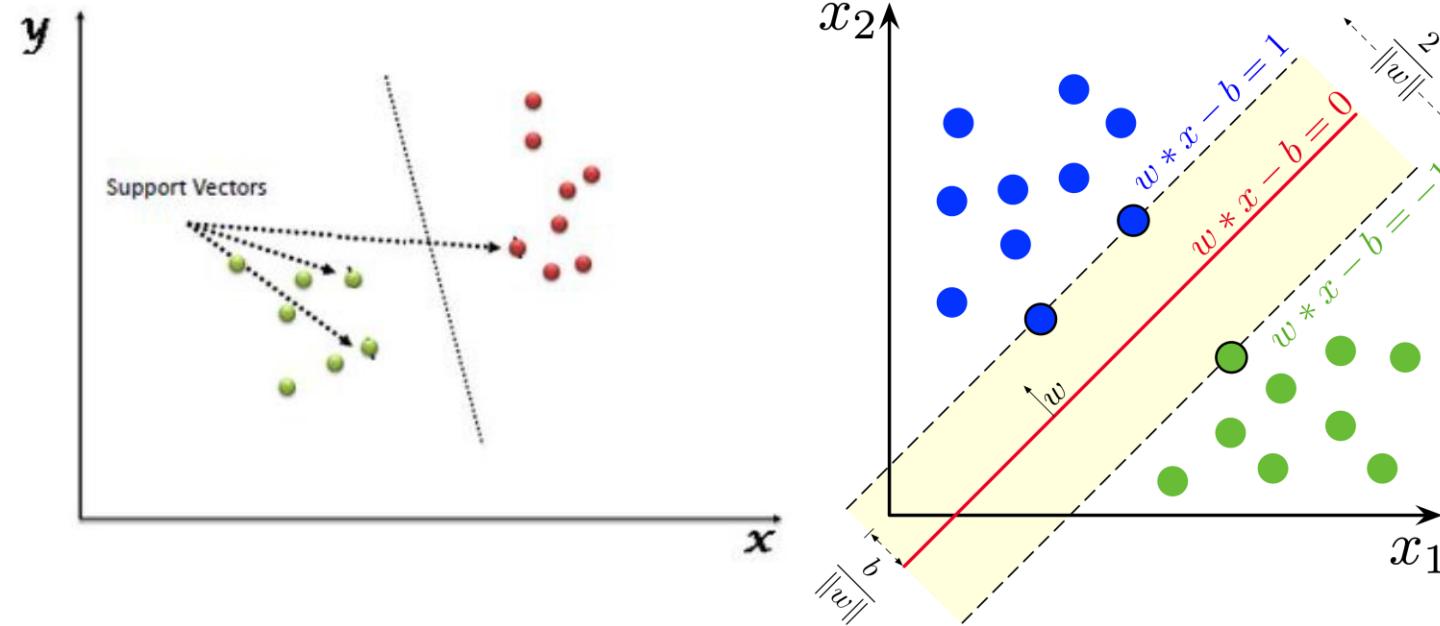
**SVM** buscando a otimização das margens e a **RNA** buscando o mínimo global

# Por que “Vetores”?

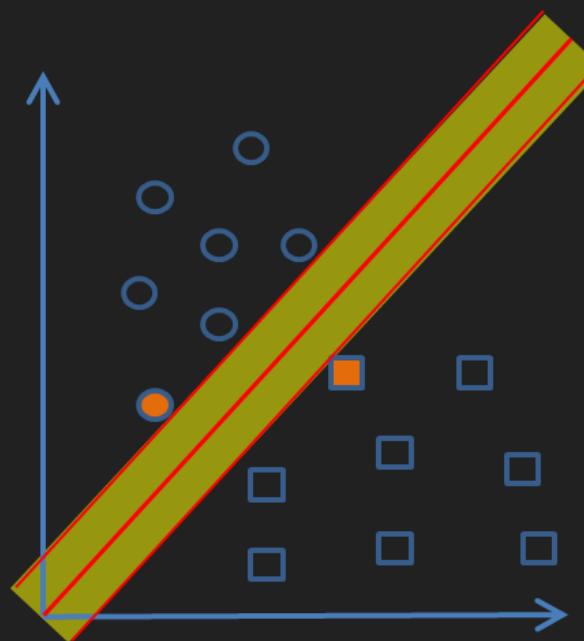


# Por que “Máquina de Vetores”?

Os “**Vetores de suporte**” são simplesmente as coordenadas da observação individual. Uma **SVM** é uma fronteira que melhor realiza as duas classes (hiperplano / linha).

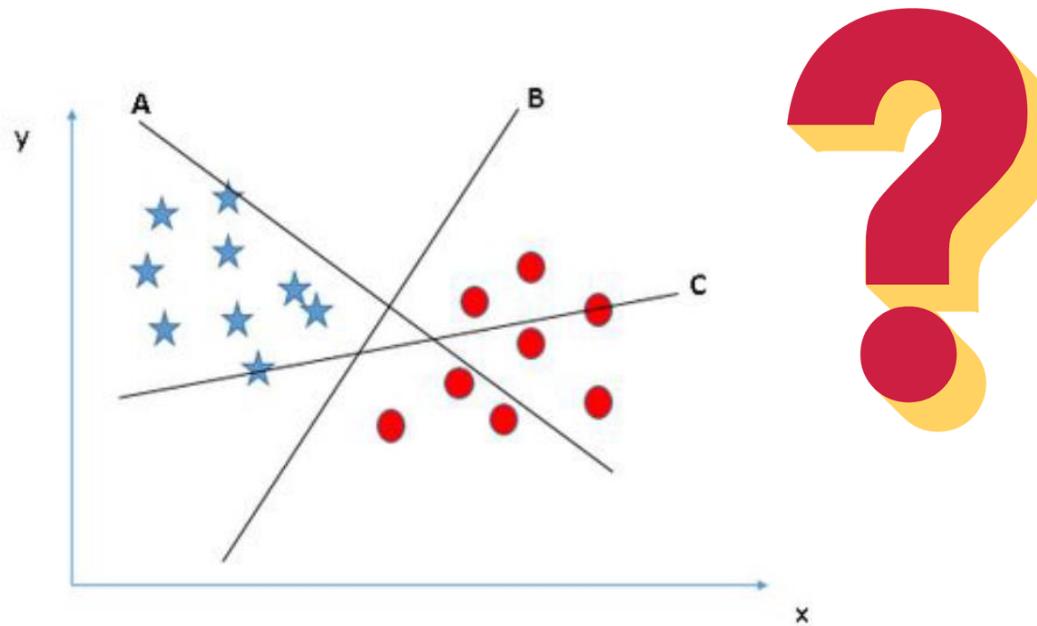


# Desenvolvimento



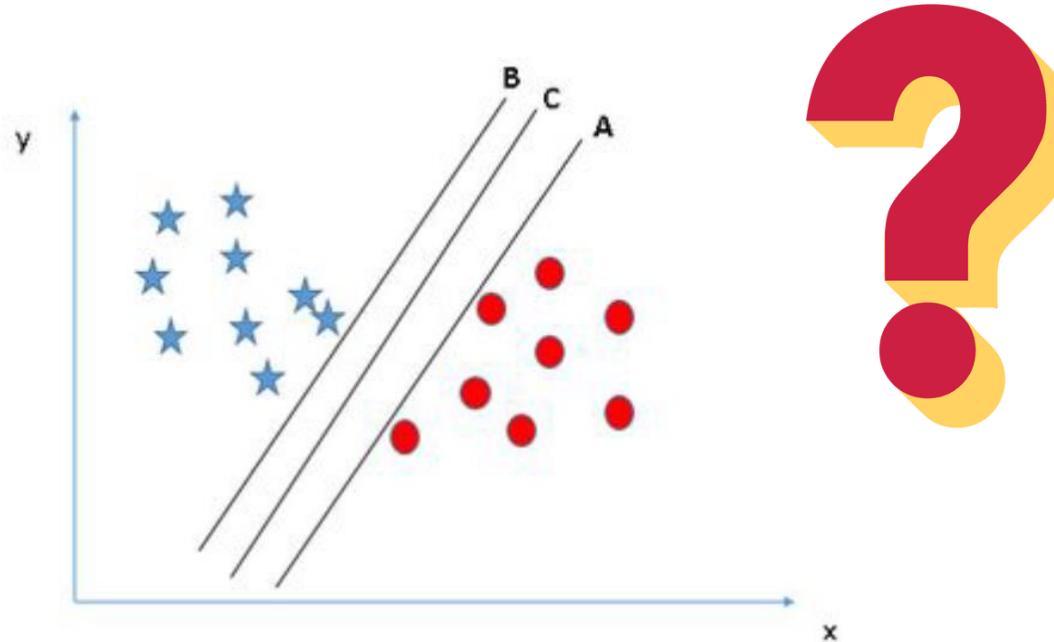
# Desenvolvendo a hipótese

**Desenvolvendo a hipótese:** Aqui, temos três hiperplanos (A, B e C). Mas qual o hiperplano certo para classificar estrela e círculo?



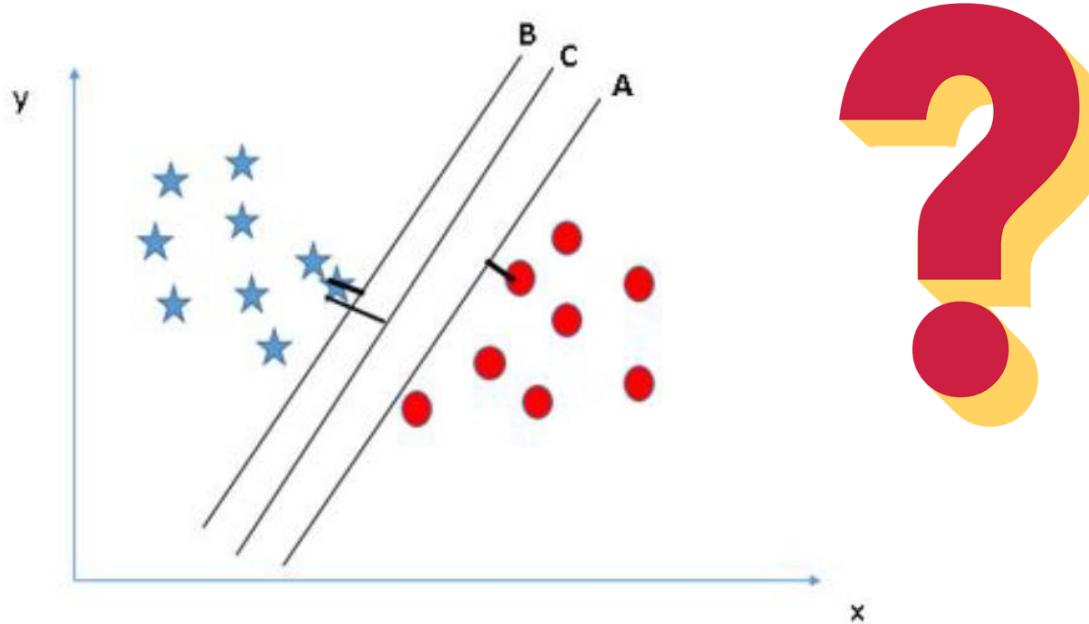
# Desenvolvendo a hipótese

Aqui, temos três **hiperplanos (A, B e C)** e todos estão dividindo bem as classes. Agora, como podemos identificar o hiperplano certo?



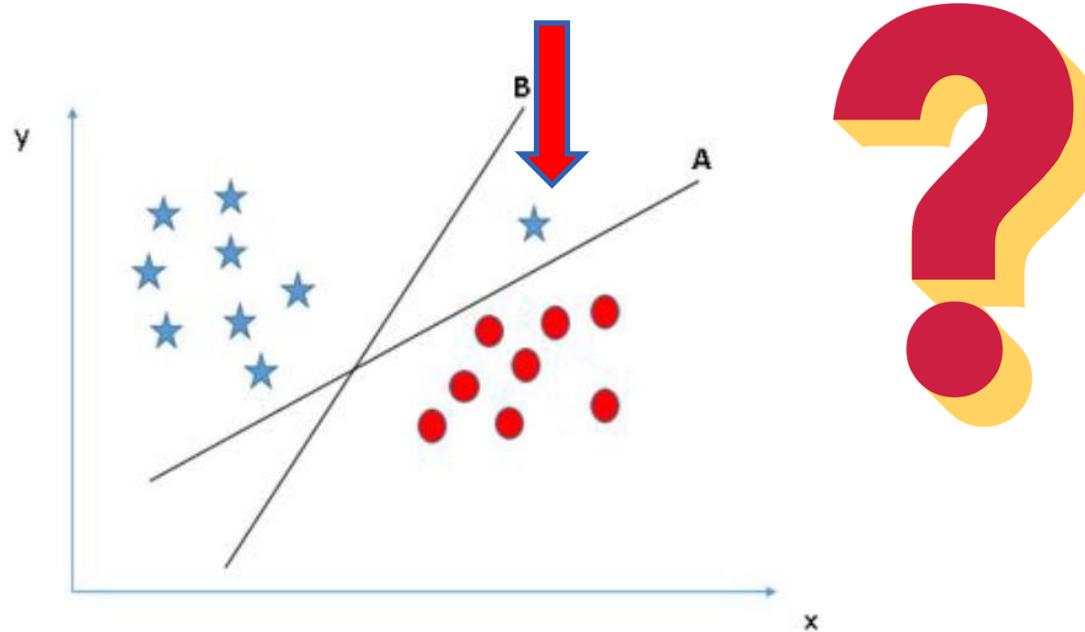
# Desenvolvendo a hipótese

**Maximizar** as distâncias entre o ponto de dados mais próximo (de qualquer classe) e o hiperplano nos ajudará a decidir o hiperplano correto.



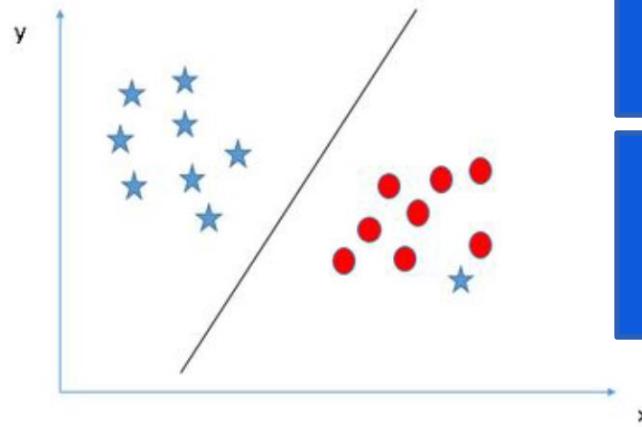
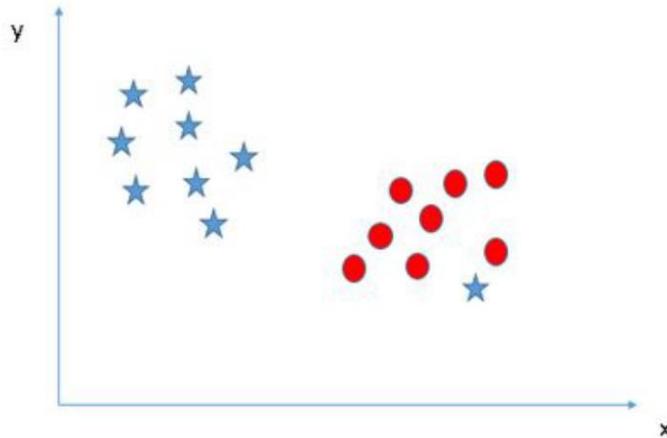
# Desenvolvendo a hipótese

Neste caso, o melhor hiperplano é o B ( já que ele tem uma margem maior em comparação a A)?



# Desenvolvendo a hipótese

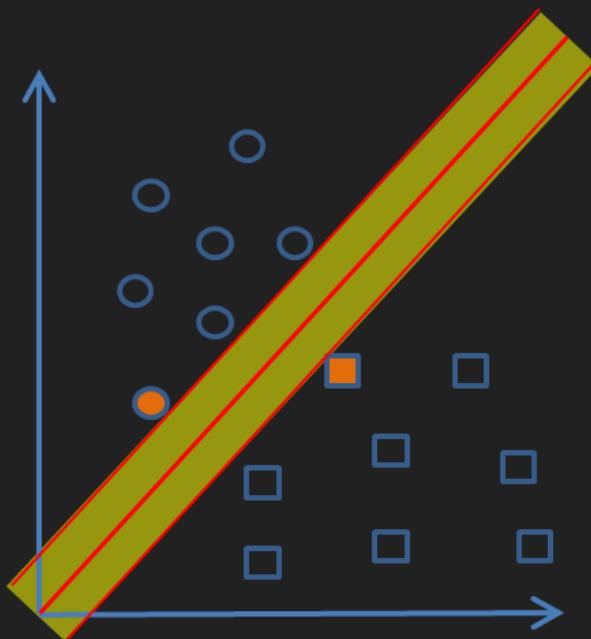
Existem casos onde não é possível separar as duas classes usando uma linha reta, pois uma das classes está no território de outra (**outlier**).



O **SVM** tem recursos para ignorar valores discrepantes

**SVM** é robusto para *outliers*

# Algoritmos



# Obrigado!

Prof. Dr. Diego Bruno